

Section 2.9 – Travaux Pratiques de Statistique

HAMLIL Mohamed

2024-09-01

Table des matières

1	Section 2.9 – Travaux Pratiques	1
1.1	Vue d'ensemble	1
1.2	2.9.1 Biais et Variance	1
1.2.1	Exercice 11 – Calcul de la Variance Empirique	1
1.2.2	Exercice 13 – Moyenne d'un Échantillon	2
1.2.3	Exercice 14 – Estimateur Sans Biais de la Variance	3
1.3	2.9.2 Comparaison des Estimateurs (Position)	3
1.3.1	Simulation de la convergence	4
1.4	2.9.4 Maximum de Vraisemblance	5

1 Section 2.9 – Travaux Pratiques

1.1 Vue d'ensemble

Ce notebook présente une série d'exercices pratiques en statistique, illustrés par des simulations et des analyses avec R.

Objectifs pédagogiques :

- Comprendre les concepts fondamentaux d'estimation (biais, variance, convergence)
 - Apprendre à comparer différents estimateurs
 - Maîtriser le calcul d'intervalles de confiance
 - Estimer les paramètres par maximum de vraisemblance
-

1.2 2.9.1 Biais et Variance

1.2.1 Exercice 11 – Calcul de la Variance Empirique

Rappel théorique : La variance empirique d'une série d'observations $(x_1, \dots, x_n)$ est définie par :

$$s_n'^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2$$

R utilise par défaut la variance corrigée (sans biais) :

$$s_n^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2$$

```
# Données de l'exemple
x <- c(4.2, 5.0, 3.8, 4.7, 5.3)

cat("=== Données ===\n")

=== Données ===

cat("Observations: ", x, "\n")

Observations: 4.2 5 3.8 4.7 5.3

cat("Moyenne: ", mean(x), "\n\n")

Moyenne: 4.6

# --- Variance corrigée de R (diviseur n-1) ---
var_R <- var(x)
cat("Variance corrigée (R avec n-1): ", var_R, "\n")

Variance corrigée (R avec n-1): 0.365

# --- Fonction variance empirique (diviseur n) ---
variance_empirique <- function(x) {
  n <- length(x)
  m <- mean(x)
  return(sum((x - m)^2) / n)
}

var_emp <- variance_empirique(x)
cat("Variance empirique (n): ", var_emp, "\n\n")

Variance empirique (n): 0.292

# --- Comparaison ---
cat("Ratio Var_corrigée / Var_empirique = ", var_R / var_emp, "\n")

Ratio Var_corrigée / Var_empirique = 1.25

cat("Facteur théorique n/(n-1) = ", length(x)/(length(x)-1), "\n")

Facteur théorique n/(n-1) = 1.25
```

1.2.2 Exercice 13 – Moyenne d'un Échantillon

La moyenne empirique est un estimateur **sans biais** de la moyenne théorique.

```
set.seed(42)

# Paramètres
n <- 1000
lambda <- 1/2

cat("=== Simulation: Loi Exponentielle(=1/2) ===\n")

=== Simulation: Loi Exponentielle(=1/2) ===

cat("Espérance théorique E(X) = 1/ =", 1/lambda, "\n")

Espérance théorique E(X) = 1/ = 2
```

```
# Génération
X <- rexp(n, rate = lambda)

# Calculs
mean_empirique <- mean(X)
mean_theo <- 1 / lambda

cat("Moyenne observée: ", round(mean_empirique, 4), "\n")

Moyenne observée: 2.1559

cat("Différence: ", round(mean_empirique - mean_theo, 4), "\n")

Différence: 0.1559
```

1.2.3 Exercice 14 – Estimateur Sans Biais de la Variance

Nous vérifions ici que la variance corrigée (utilisée par R) estime correctement en moyenne.

```
set.seed(123)
n <- 20
mu_theo <- 0
sigma_theo <- 1

# Échantillon Normal
X <- rnorm(n, mean = mu_theo, sd = sigma_theo)

# Calculs
var_empirique <- variance_empirique(X) # Biaisé
var_corrigee <- var(X)                 # Sans biais

cat("Variance empirique (n): ", round(var_empirique, 4), "\n")

Variance empirique (n): 0.8988

cat("Variance corrigée (n-1): ", round(var_corrigee, 4), "\n")

Variance corrigée (n-1): 0.9461

cat("Théorique 2: ", sigma_theo^2, "\n")

Théorique 2: 1
```

1.3 2.9.2 Comparaison des Estimateurs (Position)

Nous comparons trois estimateurs pour le paramètre de position d'une loi Normale :


1. La moyenne empirique
2. La médiane empirique
3. Le milieu de l'étendue (Mid-range) :

```
# Paramètres
n_sim <- 1000
mu <- 5
sigma <- 2 # car Variance = 4
```

```
# Simulation de l'échantillon de base
set.seed(100)
X_comp <- rnorm(n_sim, mean = mu, sd = sigma)

# Histogramme de vérification
hist(X_comp, breaks = 30, freq = FALSE, col = "lightblue",
     main = "Histogramme: Echantillon N(5, 4)", xlab = "Valeur")
curve(dnorm(x, mean = mu, sd = sigma), add = TRUE, col = "red", lwd = 2)
```

Histogramme: Echantillon N(5, 4)



1.3.1 Simulation de la convergence

Nous observons comment ces estimateurs évoluent quand la taille de l'échantillon augmente de à .

```
# Initialisation des vecteurs de résultats
est_mean <- numeric(n_sim)
est_median <- numeric(n_sim)
est_midrange <- numeric(n_sim)

# Calcul progressif
running_mean <- cumsum(X_comp) / (1:n_sim)

# Pour la médiane et le midrange, il faut recalculer à chaque étape
# (Note: cette boucle peut être lente pour de très grands n, mais ok pour 1000)
for(i in 1:n_sim) {
  sub_sample <- X_comp[1:i]
  est_median[i] <- median(sub_sample)
  est_midrange[i] <- (min(sub_sample) + max(sub_sample)) / 2
}

# --- Graphique de convergence ---
plot(1:n_sim, running_mean, type = "l", col = "blue", lwd = 2,
     ylim = c(mu - 3, mu + 3),
     xlab = "Taille de l'échantillon n", ylab = "Valeur de l'estimateur",
     main = "Convergence des Estimateurs vers = 5")

lines(1:n_sim, est_median, col = "green", lwd = 1)
```


```

lines(1:n_sim, est_midrange, col = "orange", lwd = 1, lty = 2)
abline(h = mu, col = "red", lty = 2, lwd = 2)

legend("topright",
      legend = c("Moyenne", "Médiane", "Mid-range", "Vraie valeur"),
      col = c("blue", "green", "orange", "red"),
      lty = c(1, 1, 2, 2), lwd = c(2, 1, 1, 2))

```

Convergence des Estimateurs vers $\mu = 5$



Interprétation :

- La **Moyenne** (bleu) converge rapidement et stablement vers 5.
- La **Médiane** (vert) converge aussi, mais avec une variance légèrement plus élevée que la moyenne (elle “oscille” un peu plus).
- Le **Mid-range** (orange) est très sensible aux valeurs extrêmes et converge beaucoup moins bien pour la loi Normale.

1.4 2.9.4 Maximum de Vraisemblance

Nous allons estimer le paramètre (ici noté **rate** ou λ) d'une loi Exponentielle.

L'estimateur du Maximum de Vraisemblance (EMV) pour une loi exponentielle est $\hat{\lambda} = 1/\bar{x}$. Nous allons utiliser une méthode numérique pour le vérifier.

```

library(stats4)

# 1. Génération des données
set.seed(50)
true_lambda <- 0.5
n_mle <- 200
data_exp <- rexp(n_mle, rate = true_lambda)

# 2. Définition de la fonction de Log-vraisemblance négative
# La fonction doit prendre le paramètre à estimer comme argument
nLL <- function(rate) {
  # log-vraisemblance négative = - somme(log(densité))
  # suppressWarnings pour éviter les alertes si l'algo teste des valeurs négatives

```

```

    -sum(dexp(data_exp, rate = rate, log = TRUE))
  }

# 3. Estimation numérique (MLE)
fit <- mle(nLL, start = list(rate = 1))

cat("=== Résultats Maximum de Vraisemblance ===\n")

=== Résultats Maximum de Vraisemblance ===

summary(fit)

Maximum likelihood estimation

Call:
mle(minuslogl = nLL, start = list(rate = 1))

Coefficients:
      Estimate Std. Error
rate 0.4585947 0.03242739

-2 log L: 711.8676

# Récupération du coefficient estimé
lambda_hat_mle <- coef(fit)
cat("\nLambda estimé par MLE (stats4):", lambda_hat_mle, "\n")

Lambda estimé par MLE (stats4): 0.4585947

# 4. Comparaison avec la Méthode des Moments (1/Moyenne)
lambda_hat_moments <- 1 / mean(data_exp)
cat("Lambda estimé par méthode des moments (1/mean):", lambda_hat_moments, "\n")

Lambda estimé par méthode des moments (1/mean): 0.4585578

cat("Vraie valeur:", true_lambda, "\n")


Vraie valeur: 0.5

# 5. Visualisation
hist(data_exp, freq = FALSE, breaks = 15, col = "lightgray",
      main = "Ajustement par Maximum de Vraisemblance",
      xlab = "Données")

# Superposition de la densité théorique avec le paramètre estimé
curve(dexp(x, rate = lambda_hat_mle), add = TRUE, col = "red", lwd = 2)
legend("topright", legend = paste("Exp(rate =", round(lambda_hat_mle, 3), ")"),
      col = "red", lwd = 2)

```

Ajustement par Maximum de Vraisemblance



Conclusion : Pour la loi exponentielle, l'estimateur du Maximum de Vraisemblance coïncide exactement avec l'estimateur de la méthode des moments (). La courbe rouge montre que le paramètre estimé permet de bien modéliser l'histogramme des données observées.