

Compléments de Mathématiques 2

Introduction au Machine Learning

Projet en groupe

Lola Etiévant

lola.etievant@univ-grenoble-alpes.fr

Projet de classification supervisée (60% de la note de l'UE)

- Par groupe de 3 ou 4
- Rapport écrit à rendre avant le 12/04 à 23h59 sur Moodle
 - 20% de la note de l'UE
 - 25 pages maximum (figures comprises)
 - En format PDF, obtenu à partir d'un Rmarkdown ou Sweave
 - Rendre le fichier source .Rmd ou .Rnw en plus du PDF généré

Projet de classification supervisée (60% de la note de l'UE)

- Présentation de votre jeu de données et résultats à la classe
 - Le 20 avril
 - 40% de la note de l'UE
 - $\approx$ 12 minutes de présentation + 5 minutes de questions
 - Ordre de passage aléatoire
 - Tout le monde doit parler
 - Les questions porteront sur votre compte-rendu, votre présentation, et le cours de manière plus générale

Objectifs du projet

- Sélectionner un jeu de données
 - Où vous souhaitez **prédire** une variable **binaire**
 - <https://www.kaggle.com/datasets>
 - À me faire valider
- Effectuer l'analyse préliminaire des données
- Considérer différents classifieurs supervisés
- Présenter et commenter vos résultats dans le rapport
 - En ayant un regard critique
 - En mentionnant/présentant éventuellement vos “échecs”

Analyse préliminaire des données

- Présentation générale

- Le contexte de votre jeu de données
- Le lien pour le télécharger (vos analyses doivent être reproductibles)
- Votre objectif
- Les variables que vous utiliserez (il y aura certainement les identifiants, des caractéristiques non liées au problème, etc.)

- Analyse univariée

- Analyse statistique descriptive de chacune des variables
- Analyse graphique univariée de chacune des variables

- Analyse multivariée

Au terme de l'analyse préliminaire des données :

- Avoir identifié quelles variables ont des valeurs manquantes
 - Avoir identifié quelles variables semblent être les plus importantes pour prédire votre target
- Savoir quel(s) classifieur(s) semblent le(s) plus pertinent(s)

Classifieurs

Sélectionner deux classifieurs vus dans le cours que vous souhaitez utiliser et pour chacun :

- Expliquer rapidement le fonctionnement de base
- Expliquer pourquoi vous pensez pouvoir l'utiliser avec vos données
 - S'il y a certaines variables explicatives que vous souhaitez transformer
 - Si vous devez gérer des données manquantes, et comment
- Expliquer comment vous planifiez l'analyse :
 - Potentiel(s) hyperparamètre(s) à calibrer
 - La ou les métrique(s) que vous considérez pour évaluer le classifieur et sélectionner la meilleure valeur de l'hyperparamètre
 - Split de votre jeu de données, validation croisée, etc.

Classifieurs

Pour chacun des classifieurs choisis :

- Écrire votre code
- Si nécessaire, choisir la valeur de l'hyperparamètre
 - Présenter les résultats vous ayant conduit à ce choix
- Évaluer la performance du classifieur final

Au final, quel classifieur vous souhaiteriez utiliser pour vos futures prédictions

- Meilleure performance ?
- Avantages par rapport aux autres ?
- Potentiels inconvénients ?

Exemple

Je considère la méthode des K plus proches voisins :

- ① Je rappelle le fonctionnement de base de l'algorithme
 - ② Je n'ai que des variables prédictives qualitatives donc ça me semble une bonne option
 - ③ Je souhaite prédire une maladie et préfère éviter les faux négatifs, donc je vais considérer le recall comme métrique d'évaluation
 - ④ Je mets une partie de mon jeu de données de côté et l'utiliserai pour évaluer le classifieur final
 - ⑤ J'utilise le reste du jeu de donnée pour choisir le nombre de voisins avec une procédure de cross-validation et faire "l'apprentissage"
- Je fais attention à la normalisation des variables prédictives et à l'imputation des valeurs manquantes

À la fin de votre rapport

- Vous pouvez spécifier s'il y a des pistes que vous auriez souhaitées explorer, et pourquoi, si vous aviez eu plus de temps
- Vous ajoutez une bibliographie pour les références utilisées
- Vous écrivez un paragraphe pour spécifier les tâches pour lesquelles vous avez utilisé l'IA, et à quel pourcentage
- Vous écrivez un paragraphe pour spécifier les contributions de chacun.e au projet*

* Par exemple : A.B. et B.C. ont trouvé le jeu de données ; B.C. a rédigé la description du jeu de données ; C.D. a effectué l'analyse univariée ; C.D. ont effectué l'analyse multivariée ; A.B. a proposé le design de l'analyse avec le classifieur 1 ; B.C. a effectué l'analyse avec le classifieur 1 ; B.C. a proposé le design et effectué l'analyse avec le classifieur 2 ; C.D a interprété les résultats ; A.B. et B.C. ont rédigé le rapport

- Rappel de la note : 20% sur le rapport, 40 % sur l'oral
- Tous les points mentionnés ci-avant seront pris en compte dans la note
- ⚠ Les solutions “exotiques”, à moins qu'elles soient très bien justifiées, seront pénalisées