

Prédiction de la Satisfaction Client pour les Parfums

Compléments de Mathématiques 2 — L3 MIASHS — Université Grenoble Alpes

ANZID Keltoum, EL KORAICHI Mohamed Yassine, HAMLIL Mohamed, PARDO TERAN German

2025–2026

Contents

1	Introduction	3
1.1	Contexte : le monde de la parfumerie	3
1.2	Problématique	3
2	Données	3
2.1	Présentation du jeu de données	3
2.2	Chargement des données	3
2.3	Valeurs manquantes	4
3	Analyse Exploratoire	4
3.1	Construction de la variable cible	4
3.2	Distribution des variables numériques	4
3.3	Distribution par année	5
3.4	Variables catégoriques	5
3.5	Accords et notes olfactives	6
3.6	Analyse bivariée : satisfaction et prédicteurs	6
3.7	Matrice de corrélation	7
4	Feature Engineering	7
4.1	Mapping des accords vers les familles olfactives	7
4.2	Satisfaction par famille olfactive	8
4.3	Encodage du genre	8
4.4	Partition entraînement / test	8
5	Régression Logistique Régularisée (Elastic Net)	9
5.1	Principe du modèle	9
5.2	Entraînement	9
6	Arbre de Décision	11
6.1	Principe	11
6.2	Entraînement et élagage	11
7	Forêt Aléatoire	12
7.1	Principe	12
7.2	Entraînement	12
8	k Plus Proches Voisins (kNN)	14
8.1	Principe	14
8.2	Entraînement et tuning	14
9	Comparaison des quatre modèles	15
9.1	Récapitulatif des performances	15

9.2	Courbes ROC comparées	16
9.3	Analyse comparative	16
10	Pistes non explorées	16
10.1	Naive Bayes	16
10.2	Clustering K-means	17
11	Regard critique et limites	19
12	Synthèse et conclusion	19
12.1	Retour sur la problématique	19
12.2	Bilan des méthodes	19
12.3	Ouverture et perspectives	19
13	Utilisation de l'IA	19
13.1	Contributions individuelles	20
14	Références	20

Abstract

Ce projet vise à prédire la satisfaction des consommateurs vis-à-vis des parfums à partir de leurs caractéristiques olfactives. À partir du jeu de données *Fragrantica* (~24 000 parfums, 14 variables), nous construisons une variable cible binaire (satisfaction Oui/Non) en seuillant la note moyenne à la médiane (3.97). Après une analyse exploratoire approfondie et un *feature engineering* basé sur 10 familles olfactives, nous entraînons quatre classifieurs — la régression logistique régularisée (Elastic Net/LASSO), l'arbre de décision élagué, la forêt aléatoire et le k plus proches voisins (kNN) — évalués par AUC sur validation croisée 5-fold. La forêt aléatoire obtient les meilleures performances (AUC test ≈ 0.69), suivie de la régression logistique (0.67), de l'arbre de décision et du kNN (0.65). Nous explorons également le Naive Bayes et le clustering K-means comme pistes complémentaires. Les résultats restent modestes, illustrant la difficulté de prédire une variable subjective à partir de descripteurs olfactifs seuls.

1 Introduction

1.1 Contexte : le monde de la parfumerie

L'industrie de la parfumerie représente un marché mondial de plus de **50 milliards de dollars**. Avant d'entrer dans l'analyse statistique, il est essentiel de comprendre le **vocabulaire du domaine**, car la parfumerie possède sa propre terminologie :

- **Note olfactive** : un ingrédient individuel perçu dans un parfum (ex. : bergamote, jasmin, musc). Chaque parfum est composé de dizaines de notes.
- **Pyramide olfactive** : structure en trois niveaux décrivant l'évolution temporelle d'un parfum :
 - *Notes de tête* (Top) : premières perçues, volatiles, disparaissent en 15–30 min (agrumes, herbes fraîches).
 - *Notes de cœur* (Middle) : le « caractère » du parfum, perceptibles pendant 2–4 h (floraux, épicés).
 - *Notes de fond* (Base) : les plus persistantes, durent 6–24 h (bois, musc, vanille).
- **Accord** : combinaison de plusieurs notes créant une impression olfactive cohérente. Un parfum possède typiquement 3 à 5 accords principaux.
- **Famille olfactive** : grande catégorie regroupant des accords similaires (ex. : florale, boisée, orientale). La classification en familles est standardisée par la Société Française des Parfumeurs.

La France occupe une place centrale dans cette industrie, avec **Grasse** (Alpes-Maritimes) comme capitale historique du parfum depuis le XVII^e siècle, et des maisons comme Chanel, Dior, Guerlain et Hermès.

1.2 Problématique

Avec l'essor des plateformes communautaires en ligne comme **Fragrantica** — le plus grand site mondial dédié à la parfumerie —, il devient possible d'analyser les préférences olfactives à grande échelle. Notre objectif est de répondre à la question : **Peut-on prédire la satisfaction des consommateurs vis-à-vis d'un parfum à partir de ses caractéristiques olfactives ?**

Plus précisément, nous souhaitons :

1. Exploiter les variables de familles olfactives comme prédicteurs.
2. Comparer quatre approches supervisées : régression logistique régularisée, arbre de décision, forêt aléatoire et k plus proches voisins.
3. Évaluer honnêtement la performance de généralisation par validation croisée.
4. Explorer des pistes complémentaires (Naive Bayes, clustering K-means) et justifier leur non-rétention.

Le jeu de données est librement téléchargeable sur Kaggle (Fragrantica Fragrance Dataset).

2 Données

2.1 Présentation du jeu de données

Le jeu de données Fragrantica contient les informations suivantes pour chaque parfum :

Variable	Type	Description
Rating_Value	Numérique	Note moyenne attribuée par les utilisateurs (1–5)
Rating_Count	Numérique	Nombre d'évaluations reçues
Year	Numérique	Année de sortie du parfum
Gender	Catégorielle	Genre cible (men, women, unisex)
Country	Catégorielle	Pays d'origine de la marque
Top / Middle / Base	Texte	Notes olfactives par phase de la pyramide
mainaccord1–5	Texte	Les 5 accords principaux du parfum

2.2 Chargement des données

Dimensions : 24063 lignes, 18 colonnes

Les données brutes comprennent 24063 parfums et 18 variables. Nous excluons **Name**, **Brand**, **url**, **Perfumer1** et **Perfumer2** car ce sont des identifiants à cardinalité trop élevée pour être directement intégrés dans un modèle de classification.

2.3 Valeurs manquantes




Figure 1: Pourcentage de valeurs manquantes par variable

Perfumer2 est absent dans plus de 80 % des cas et sera exclu. **Year** manque dans environ 8 % des cas — ces valeurs seront imputées par la médiane. Les accords secondaires (**mainaccord3–5**) présentent 5–15 % de valeurs manquantes. La variable **Rating_Value** est quasi-complète, permettant la construction fiable de la variable cible.

3 Analyse Exploratoire

3.1 Construction de la variable cible

La variable **Rating_Value** (continue, 1–5) est transformée en variable binaire **Satisfaction** en utilisant la **médiane** comme seuil. Ce choix pragmatique maximise l'équilibre des classes et évite les problèmes liés au déséquilibre.




Figure 2: Distribution de la variable Satisfaction


La médiane (3.97) produit une répartition quasi-équilibrée (**50.7 % Oui**), favorable pour l'apprentissage statistique.

3.2 Distribution des variables numériques

Le jeu de données contient deux variables numériques clés qu'il ne faut pas confondre :

- **Rating_Value** : la **note moyenne** attribuée au parfum (échelle 1–5). Mesure de *qualité perçue*. Distribution quasi-symétrique.
- **Rating_Count** : le **nombre total d'évaluations**. Mesure de *popularité*. Distribution très asymétrique → transformation $\log(1 + x)$.

Rating_Value sert à construire la variable cible et est donc **exclue des prédictors**. **Rating_Count** est conservé comme prédicteur.

Figure 3: Distribution de Rating_Value et $\log(1+\text{Rating_Count})$

Les notes sont concentrées autour de 3.5–4.0. La popularité brute est extrêmement asymétrique : la majorité des parfums ont moins de 50 évaluations, tandis que quelques parfums iconiques (*Sauvage* de Dior, *Bleu de Chanel*) en cumulent des milliers. Après transformation logarithmique, la distribution devient quasi-normale.

3.3 Distribution par année




Figure 4: Nombre de parfums par année de sortie

On observe une croissance exponentielle des sorties à partir des années 2000, liée à la démocratisation de la parfumerie. Les parfums anciens (avant 1990) sont sous-représentés, ce qui introduit un **effet de survivance** : seuls les parfums ayant survécu commercialement restent référencés sur Fragrantica.

3.4 Variables catégoriques




Figure 5: Distribution par genre et par pays d'origine

Les parfums pour femmes et unisex dominant. La **France** arrive en tête (~30 %), héritage historique de Grasse et des grandes maisons (Chanel, Dior, Guerlain, Hermès). Les **États-Unis** (~19 %) reflètent les marques designer, et l'**Italie** (~14 %) sa tradition mode-luxe. Les pays < 5 % seront regroupés en « Other ».

3.5 Accords et notes olfactives




Figure 6: Accords olfactifs les plus fréquents

Les accords **woody**, **citrus** et **aromatic** dominent. Les 84 accords distincts seront regroupés en 10 familles olfactives au chapitre suivant.




Figure 7: Notes olfactives les plus fréquentes par phase

La répartition des notes confirme la **pyramide olfactive** classique : tête dominée par les agrumes volatils (bergamote, citron), cœur par les floraux (jasmin, rose, iris), fond par les ingrédients tenaces (musc, santal, cèdre, vanille).

3.6 Analyse bivariée : satisfaction et prédicteurs




Figure 8: Variables numériques selon la satisfaction

Les parfums satisfaisants ont significativement plus d'évaluations (**biais de popularité** : les utilisateurs notent préférentiellement les parfums qu'ils apprécient) et sont légèrement plus anciens (**effet de survivance**).




Figure 9: Taux de satisfaction par genre et par pays

Le genre est peu discriminant. Par pays, certaines origines (maisons de niche, parfumeurs des Émirats spécialisés dans le oud) affichent des taux plus élevés, leur public étant passionné et averti.

3.7 Matrice de corrélation




Figure 10: Matrice de corrélation des variables numériques

Les corrélations entre les variables numériques sont très faibles (toutes inférieures à 0.15), indiquant l'absence de multicollinéarité problématique.

4 Feature Engineering

4.1 Mapping des accords vers les familles olfactives

Plutôt que d'utiliser les 84 accords individuels, nous les regroupons en **10 familles olfactives** standardisées, inspirées de la classification de la Société Française des Parfumeurs (Ellena, 2007) :

Famille	Accords regroupés (exemples)
Fruity	fruity, citrus, tropical
Floral	floral, rose, white floral, yellow floral
Woody	woody, earthy, mossy
Sweet	sweet, vanilla, caramel, powdery, gourmand
Oriental	oriental, amber, balsamic, warm, musky
Fresh	fresh, aquatic, ozonic, marine, clean
Spicy	spicy, warm spicy, cinnamon
Herbal	herbal, aromatic, green, lavender

Famille	Accords regroupés (exemples)
Leather	leather, animalic
Smoky	smoky, tobacco

Par exemple, un parfum dont les accords sont « *citrus, floral, vanilla, woody, amber* » sera classé dans 5 familles simultanément : **fruity** (via citrus), **floral**, **sweet** (via vanilla), **woody** et **oriental** (via amber).

Table 3: Distribution des familles olfactives (accords)

Famille	Parfums	%
fruity	14252	59.2
sweet	13331	55.4
woody	12803	53.2
floral	11760	48.9
herbal	9469	39.4
oriental	8497	35.3
spicy	6120	25.4
fresh	4495	18.7
leather	1703	7.1
smoky	861	3.6

Les pourcentages totalisent plus de 100 % car un parfum peut appartenir à plusieurs familles. Les familles **fruity**, **woody** et **sweet** dominent.

4.2 Satisfaction par famille olfactive




Figure 11: Taux de satisfaction par famille olfactive

Les écarts entre familles sont modestes (~47 % à ~54 %). Les familles *smoky*, *spicy* et *leather* (niches) affichent les taux les plus élevés. *Fresh*, *floral* et *fruity* (très répandues) sont légèrement en dessous, leur grande variabilité interne tirant la moyenne vers le bas.

4.3 Encodage du genre

4.4 Partition entraînement / test

Le split 70/30 est un compromis standard. **Toutes les transformations impliquant des statistiques apprises** (top-10 des notes, regroupement des pays, imputation médiane) sont calculées **après le split, uniquement sur le train**, pour éviter toute fuite d'information vers le test.

Table 4: Pays après regroupement (seuil 5 %, calculé sur train)

Pays	Effectif	%
France	5093	30.2
USA	3165	18.8
Other	2414	14.3
Italy	2314	13.7
UK	1190	7.1
Brazil	919	5.5
Spain	907	5.4
UAE	843	5.0

Table 5: Répartition entraînement / test (stratifié)

Ensemble	Observations	Variables	Prop. Oui
Entraînement	16845	53	0.507
Test	7218	53	0.507

Le pipeline produit 53 variables explicatives. La stratification garantit une évaluation non biaisée.

5 Régression Logistique Régularisée (Elastic Net)

5.1 Principe du modèle

LASSO et Elastic Net. Le modèle LASSO minimise :

$$\mathcal{L}(\beta) = -\frac{1}{n} \sum_{i=1}^n \log P(y_i | x_i, \beta) + \lambda \|\beta\|_1$$

où λ est le paramètre de régularisation. La pénalité ℓ_1 force certains coefficients à exactement zéro, réalisant une **sélection de variables** automatique. Nous utilisons l'**Elastic Net** (Zou & Hastie, 2005) qui combine ℓ_1 (sélection) et ℓ_2 (rétrécissement), contrôlées par $\alpha \in [0, 1]$.

5.2 Entraînement

La grille explore l'ensemble du spectre Elastic Net : $\alpha \in \{0, 0.25, 0.5, 0.75, 1\}$ et 10 valeurs de $\lambda \in [10^{-4}, 10^{-1}]$ en échelle logarithmique. Validation croisée 5-fold (Kohavi, 1995) — chaque fold contient $\sim 3\,400$ observations.

5.2.1 Sélection des hyperparamètres




Figure 12: AUC en validation croisée selon alpha et lambda

Le meilleur modèle correspond à $\alpha = 1$ et $\lambda = 0.002154$. $\alpha = 1$ optimal signifie que le modèle retenu est un **LASSO pur** : la sélection de variables est plus bénéfique que le simple rétrécissement Ridge.

5.2.2 Performance sur le jeu test

Table 6: Métriques de la régression logistique

Metric	Valeur
alpha	1.000000
lambda	0.002154
AUC (CV)	0.667000
AUC (test)	0.669300
Accuracy	0.625000
Sensibilité	0.635400
Spécificité	0.614200
F1	0.632300

La proximité entre AUC CV et AUC test confirme l'absence de surapprentissage.

5.2.3 Matrice de confusion




Figure 13: Matrice de confusion — Régression logistique

Le classifieur est légèrement biaisé vers la classe positive : sensibilité > spécificité.

5.2.4 Interprétation des coefficients




Figure 14: Coefficients non-nuls de la régression logistique (LASSO)

Le LASSO retient **41 variables sur 53**. `Rating_Count` conserve un coefficient positif fort, confirmant le **bias de popularité**. Les variables de pays et d'année sont également sélectionnées. Parmi les familles, `fam_fruity` et `fam_fresh` reçoivent des coefficients négatifs — cohérent avec leurs taux de satisfaction inférieurs à la moyenne.

Bilan — LASSO retenu, AUC test = 0.669, 41/53 variables actives. Baseline linéaire interprétable.

6 Arbre de Décision

6.1 Principe

Indice de Gini et élagage. L'arbre partitionne récursivement l'espace des features en régions homogènes. À chaque nœud, l'algorithme sélectionne la variable et le seuil qui maximisent la pureté, mesurée par l'indice de Gini :

$$\text{Gini}(t) = 1 - \sum_c p_c^2$$

L'arbre est ensuite **élagué** par validation croisée : on sélectionne le paramètre de complexité c_p qui minimise l'erreur CV.

6.2 Entraînement et élagage




Figure 15: Arbre de décision élagué — règles de classification interprétables

L'arbre élagué offre une **transparence totale** : la variable racine est `gender_women`, et chaque feuille indique la classe prédite + sa pureté. $AUC = 0.649$ — inférieur à la forêt aléatoire, illustrant la **variance** des arbres individuels.

Table 7: Métriques de l'arbre de décision élagué

	Metric	Value
	AUC (test)	0.6488
Accuracy	Accuracy	0.6146
Sensitivity	Sensibilité	0.5939
Specificity	Spécificité	0.6358
F1	F1	0.6099

Bilan — Arbre élagué retenu, $AUC_{test} = 0.649$. Variance élevée → passage à la forêt au chapitre suivant.

7 Forêt Aléatoire

7.1 Principe


Bagging et décorrélation des arbres. La forêt aléatoire (Breiman, 2001) est un ensemble de 500 arbres entraînés sur des échantillons bootstrap. À chaque nœud, seul un sous-ensemble de `mtry` variables est considéré, ce qui **décorrèle** les arbres. Elle capture les **interactions non-linéaires** sans les modéliser explicitement, et réduit la **variance** par moyennage.

7.2 Entraînement

La grille optimise conjointement deux hyperparamètres :

- `mtry` ∈ {3, 5, 7, 10, 15, 20} : centré autour de $\sqrt{p} \approx 7$ (recommandation de Breiman).
- `min.node.size` ∈ {1, 5, 10} : taille minimale des feuilles.

7.2.1 Sélection de `mtry`

Figure 16: AUC en validation croisée selon `mtry`

L'optimum est atteint pour `mtry` = 5 et `min.node.size` = 10. L'AUC décroît avec des valeurs élevées de `mtry` : trop de variables ajoutent du bruit, la décorrélation maximale (faible `mtry`) est plus bénéfique.

7.2.2 Performance sur le jeu test

Table 8: Métriques de la forêt aléatoire

Metric	Value
<code>mtry</code>	5.0000
<code>min.node.size</code>	10.0000
AUC (CV)	0.6875

Metrique	Valeur
AUC (test)	0.6926
Accuracy	0.6333
Sensibilité	0.6551
Spécificité	0.6108
F1	0.6445

La forêt aléatoire surpasse le LASSO sur l'AUC test. Le bagging agit comme un régulateur naturel.

7.2.3 Matrice de confusion




Figure 17: Matrice de confusion — Forêt aléatoire

7.2.4 Importance des variables




Figure 18: Importance des variables (Top 15)

Rating_Count et **Year** dominent massivement l'importance, suivis des familles olfactives. Cette hiérarchie soulève une question fondamentale : **le modèle prédit-il la satisfaction olfactive, ou capture-t-il un effet de popularité ?** Les deux sont mêlés dans les données communautaires.

Bilan — Forêt aléatoire = **meilleur modèle**, AUC test = 0.693, mtry = 5, 500 arbres.

8 k Plus Proches Voisins (kNN)

8.1 Principe

Classifieur paresseux par voisinage. Le kNN (Cover & Hart, 1967) est non-paramétrique et **paresseux** : pas de modèle explicite, classification par vote majoritaire des k voisins les plus proches (distance euclidienne après standardisation).

Avantages théoriques : aucune hypothèse sur la distribution, capture les frontières non-linéaires complexes.

Risque a priori (Séance 5) : avec 53 features dont la majorité binaires, les distances euclidiennes deviennent peu discriminantes en haute dimension — c'est la **malédiction de la dimensionnalité**.

8.2 Entraînement et tuning

Nous testons 8 valeurs de $k \in \{3, 5, 7, 11, 15, 21, 31, 51\}$. La standardisation est appliquée pour que **Rating_Count** (échelle $\sim 0-10\,000$) ne domine pas les variables binaires.

8.2.1 Sélection de k




Figure 19: AUC en validation croisée selon k — comparaison avec LR et RF

L'AUC augmente **monotoniquement** avec k , de 0.592 ($k=3$) à 0.652 ($k=51$). Le modèle bénéficie systématiquement du lissage — le **signal local est noyé dans le bruit dimensionnel**. Même au meilleur k , le kNN reste sous LR et RF.

8.2.2 Performance sur le jeu test

Table 9: Métriques finales du kNN

Métrique	Valeur
Meilleur k	51.0000
AUC (CV)	0.6520
AUC (test)	0.6541
Accuracy	0.6114
Sensibilité	0.5871
Spécificité	0.6364
F1	0.6052

8.2.3 Matrice de confusion




Figure 20: Matrice de confusion — kNN

8.2.4 Diagnostic : la malédiction de la dimensionnalité

Le fait que $k=51$ soit optimal (le plus grand testé) est révélateur : avec 53 dimensions dont ~ 50 binaires, les distances euclidiennes se concentrent autour de leur moyenne et les observations deviennent **équidistantes**. Le kNN perd sa capacité discriminante. C'est un cas d'école de la **malédiction de la dimensionnalité** étudiée en **Séance 5**.

Bilan — kNN retenu pour illustration pédagogique, AUC test = 0.654 ($k = 51$). Démontre empiriquement la malédiction de la dimensionnalité.

9 Comparaison des quatre modèles

9.1 Récapitulatif des performances

Table 10: Comparaison des quatre modèles supervisés

Modele	AUC_Test	Accuracy	Sensibilite	Specificite	F1
Rég. Logistique (LASSO)	0.6693	0.6250	0.6354	0.6142	0.6323
Arbre de Décision	0.6488	0.6146	0.5939	0.6358	0.6099
Forêt Aléatoire	0.6926	0.6333	0.6551	0.6108	0.6445
kNN ($k=51$)	0.6541	0.6114	0.5871	0.6364	0.6052

La hiérarchie est claire : **Forêt Aléatoire** > **Régression Logistique** > **kNN** > **Arbre de Décision**. L'écart RF/kNN (3.9 points d'AUC) est substantiel. Le gain forêt vs arbre seul (4.4 points) illustre l'avantage du bagging.

9.2 Courbes ROC comparées




Figure 21: Courbes ROC comparées — quatre modèles supervisés

Les quatre courbes s'écartent de la diagonale, confirmant une discrimination réelle. La forêt aléatoire domine sur toute la plage de seuils. L'AUC la plus élevée (0.693) signifie que le modèle classe correctement une paire aléatoire (satisfaisant, non-satisfaisant) dans **69 % des cas** (Fawcett, 2006).

9.3 Analyse comparative

Pourquoi la forêt aléatoire domine-t-elle ? Trois raisons : (1) **interactions non-linéaires** capturées sans modélisation explicite ; (2) **bagging** + restriction de `mtry` qui décorrèlent les arbres, régularisation absente du kNN ; (3) **sélection implicite** des variables pertinentes à chaque nœud. Le kNN échoue à cause de la **malédiction de la dimensionnalité**.

10 Pistes non explorées

Au-delà des quatre modèles supervisés retenus, nous avons exploré deux pistes complémentaires non intégrées comme modèles principaux.

10.1 Naive Bayes

Le classificateur Naive Bayes applique le théorème de Bayes avec l'hypothèse d'**indépendance conditionnelle** entre les features :

$$P(Y = c \mid X_1, \dots, X_p) \propto P(Y = c) \prod_{j=1}^p P(X_j \mid Y = c)$$

Table 11: Métriques du Naive Bayes — modèle non retenu

Métrique	Valeur
AUC (CV)	0.6481
AUC (test)	0.6464
Accuracy	0.5540
Sensibilité	0.2002
Spécificité	0.9184

Raisons de la non-rétention :

1. **AUC la plus faible** (0.646) : inférieure à tous les modèles retenus.
2. **Classificateur dégénéré** : sensibilité extrêmement basse (0.2) → le modèle prédit presque tous les parfums comme « Non ». Inutilisable en pratique.
3. **Violation de l'hypothèse d'indépendance** : les familles olfactives sont corrélées entre elles (voir figure ci-dessous).

Corrélations entre familles olfactives




Figure 22: Corrélations entre familles olfactives — violation de l'hypothèse d'indépendance du Naive Bayes

Plusieurs paires de familles présentent des corrélations non négligeables, traduisant la spécialisation des compositions. Ces dépendances violent l'hypothèse d'indépendance conditionnelle, dégradant l'estimation des probabilités jointes.

10.2 Clustering K-means

En complément, clustering **non-supervisé** K-means sur les 10 familles olfactives, pour découvrir des profils-types.




Figure 23: Méthode du coude — choix du nombre de clusters

La méthode du coude suggère **k=3** clusters.




Figure 24: Profils olfactifs des 3 clusters K-means

Trois profils-types émergent :

Table 12: Taux de satisfaction par profil olfactif

Profil	Effectif	Satisfaction (%)	Rating moyen
Aromatique-Frais	7937	51.2	3.96
Boisé-Oriental	6006	62.0	4.03
Floral-Gourmand	10120	43.7	3.92




Figure 25: Taux de satisfaction par profil olfactif

- **Aromatique-Frais** (7937 parfums) : herbal, fruity, woody. Fougères masculines classiques. Satisfaction : 51.2 %.
- **Floral-Gourmand** (10120 parfums) : sweet, floral, fruity. Compositions féminines accessibles. Satisfaction : 43.7 % — le plus bas.
- **Boisé-Oriental** (6006 parfums) : woody, oriental, sweet. Parfums de niche (oud, santal, ambre). Satisfaction : 62 % — le plus élevé.

L'écart Boisé-Oriental vs Floral-Gourmand est de **18.3 points**. Explication : les parfums boisés-orientaux sont des **niches** achetées par des passionnés sélectifs ; les floraux-gourmands sont **grand public** et reçoivent des avis plus mitigés. C'est un **biais de sélection** classique. L'écart est statistiquement significatif (χ^2 , $p < 0.001$) mais l'effet est faible (V de Cramér ≈ 0.15). L'ajout du cluster comme variable dans la forêt aléatoire ne modifie pas l'AUC — les familles individuelles capturent déjà cette information.

11 Regard critique et limites

1. **Biais de sélection** : `Rating_Count` domine les prédicteurs. Les parfums populaires attirent plus d'évaluateurs *et* ces évaluateurs notent préférentiellement les parfums qu'ils apprécient. Corrélation, pas causalité.
2. **Multicolinéarité des familles** : les familles olfactives ne sont pas mutuellement exclusives, ce qui peut biaiser les coefficients LASSO. RF et kNN sont moins sensibles.
3. **Validité externe** : Fragrantica = public auto-sélectionné de passionnés en ligne, non représentatif.
4. **Perte d'information** : la binarisation à la médiane perd le gradient (un parfum à 4.8 et un à 4.0 sont tous deux « Oui »).
5. **Malédiction de la dimensionnalité** : le kNN illustre concrètement la dégradation des classificateurs basés sur les distances en haute dimension ($p = 53$), phénomène théorique étudié en **Séance 5** vérifié empiriquement.

12 Synthèse et conclusion

12.1 Retour sur la problématique

Les caractéristiques olfactives permettent-elles de prédire la satisfaction ? Partiellement. Les familles olfactives contribuent ($AUC > 0.50$), mais l' AUC plafonne à ~ 0.69 , dominée par les variables non-olfactives. Ce projet illustre les concepts clés du cours :

- La **validation croisée** (TP3) pour une estimation honnête de la performance.
- La **régularisation** (TP5) pour gérer un espace de 53 prédicteurs — le LASSO a éliminé les variables redondantes.
- La **comparaison de modèles** (TP6-7) : le gain de la forêt aléatoire est réel mais modéré.
- La **classification par voisinage** (TP5) : le kNN échoue en haute dimension.
- Le **regard critique** : Naive Bayes (Séance 6) écarté, K-means (Séance 10) exploré pour un éclairage complémentaire.

12.2 Bilan des méthodes

Méthode	AUC test	Statut	Justification
Forêt Aléatoire	0.693	Retenu	Meilleure performance, interactions non-linéaires
Rég. Logistique	0.669	Retenu	Interprétable, sélection de variables
Arbre de Décision	0.649	Retenu	Interprétable, justifie le passage à la forêt
kNN (k=51)	0.654	Retenu	Illustration malédiction dimensionnalité
Naive Bayes	0.646	Non retenu	Hypothèse violée, classificateur dégénéré
K-means (k=3)	—	Exploratoire	3 profils significatifs (χ^2 , $p < 0.001$), effet faible ($V = 0.15$)

12.3 Ouverture et perspectives

Ce travail ouvre plusieurs pistes : encodage **TF-IDF** sur les notes individuelles (analogue NLP), ajout de la **concentration du parfum** (EdT/EdP/Extrait, absente du dataset) comme prédicteur de tenue, **méthodes d'ensemble hybrides** (stacking) ou réseaux de neurones, modèle entraîné **séparément par cluster K-means**, et **régression ordinale** pour préserver le gradient de satisfaction perdu par la binarisation.

13 Utilisation de l'IA

Nous avons utilisé Claude et GitHub Copilot pour :

1. **Debugging du code R** ($\sim 15\%$ du temps) : résolution d'erreurs de syntaxe et de compatibilité entre packages (ex. : l'IA avait suggéré `randomForest` au lieu de `ranger`, corrigé après des temps d'exécution $10\times$ supérieurs).
2. **Mise en forme du rapport** ($\sim 10\%$) : aide à la structuration LaTeX (gestion des marges via `geometry`, espacement avec `linespread` et `parskip`, placement des figures avec `float` et `\floatplacement{figure}{H}`, table des matières automatique).

Toutes les sorties ont été systématiquement vérifiées. L'analyse des données, le choix des hyperparamètres, l'interprétation des résultats et le regard critique sont entièrement le fruit de notre travail.

13.1 Contributions individuelles

Membre	Contributions
ANZID Keltoum	Analyse exploratoire, interprétation des résultats, rédaction des sections contextuelles, présentation orale
EL KORAICHI Mohamed Yassine	Feature engineering (familles olfactives, notes), kNN et pistes non explorées, réécriture du rapport, validation et relecture critique
HAMLIL Mohamed	Code R et modélisation (régression logistique, arbre de décision, forêt aléatoire), feature engineering, pipeline anti data leakage
PARDO TERAN German	Recherche des données (Fragrantica), visualisations, aide à l'interprétation, présentation orale

14 Références

1. Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32.
2. Zou, H. & Hastie, T. (2005). *Regularization and Variable Selection via the Elastic Net*. JRSS-B, 67(2), 301–320.
3. Fawcett, T. (2006). *An Introduction to ROC Analysis*. Pattern Recognition Letters, 27(8), 861–874.
4. Kohavi, R. (1995). *A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection*. IJCAI.
5. Ellena, J.-C. (2007). *Que sais-je ? Le parfum*. Presses Universitaires de France.
6. Fragrantica Fragrance Dataset. Kaggle. <https://www.kaggle.com/datasets/olgagmiufana1/fragrantica-com-fragrance-dataset>
7. Cover, T. & Hart, P. (1967). *Nearest Neighbor Pattern Classification*. IEEE Transactions on Information Theory, 13(1), 21–27.