

Partie 1 : Analyse Exploratoire des Données

Compléments de Mathématiques 2 – Introduction au Machine Learning

HAMLIL Mohamed

Invalid Date

Table des matières

1	Introduction	2
1.1	Contexte	2
1.2	Variables utilisées	2
2	Chargement des données	3
3	Analyse préliminaire des données	4
3.1	Aperçu général	4
3.2	Gestion des valeurs manquantes	4
3.3	Création de la variable cible : Satisfaction	6
3.4	Analyse univariée	9
3.4.1	Rating_Value (avant binarisation)	9
3.4.2	Release_Year	10
3.4.3	Rating_Count	10
3.4.4	Concentration	11
3.4.5	Main_Accords (accords les plus fréquents)	12
3.5	Analyse multivariée	15
3.5.1	Satisfaction vs. Rating_Count	15
3.5.2	Satisfaction vs. Release_Year	16
3.5.3	Satisfaction vs. Concentration	17
3.5.4	Corrélation entre variables numériques	18
4	Sauvegarde des données	20

1 Introduction

1.1 Contexte

Ce projet s'inscrit dans le cadre du cours de Compléments de Mathématiques 2 (Introduction au Machine Learning). L'objectif est de réaliser une classification supervisée binaire à partir d'un jeu de données réel.

Nous avons choisi un jeu de données de parfums issu de **Parfumo**, une communauté en ligne dédiée aux parfums. Ce dataset contient des informations sur près de 60 000 parfums : leur marque, année de sortie, concentration, notes olfactives, accords principaux et évaluations des utilisateurs.

Lien de téléchargement : [Parfumo Dataset sur Kaggle](#)

i Objectif

Prédire la **satisfaction des utilisateurs** (variable binaire : Oui / Non) à partir des caractéristiques d'un parfum. La satisfaction est définie par la note attribuée par les utilisateurs (**Rating_Value**) : un parfum est considéré comme satisfaisant si sa note est supérieure ou égale à la médiane.

1.2 Variables utilisées

Variable	Type	Description
Release_Year	Numérique	Année de sortie du parfum
Concentration	Catégorielle	Type de concentration (EDP, EDT, etc.)
Rating_Count	Numérique	Nombre d'évaluations reçues
Main_Accords	Texte	Accords olfactifs principaux
Top_Notes	Texte	Notes de tête
Middle_Notes	Texte	Notes de cœur
Base_Notes	Texte	Notes de fond
Satisfaction	Binaire	Variable cible (Oui / Non)

2 Chargement des données

```
data_raw <- read.csv(here::here("data", "parfumo_data_clean.csv"),  
                     stringsAsFactors = FALSE,  
                     na.strings = c("NA", ""))  
  
cat("Dimensions du dataset brut :", nrow(data_raw), "lignes,", ncol(data_raw), "colonnes\n")
```

Dimensions du dataset brut : 59325 lignes, 13 colonnes

3 Analyse préliminaire des données

3.1 Aperçu général

```
str(data_raw)
```

```
'data.frame':  59325 obs. of  13 variables:
 $ Number      : chr  "455" "0071" "0154" "0162" ...
 $ Name        : chr  "Tabac Écarlate" "Tidal Pool" "Pumpkin Pie" "Wet Stone" ...
 $ Brand       : chr  "Le Ré Noir" "CB I Hate Perfume" "CB I Hate Perfume" "CB I Hate Perfume" ...
 $ Release_Year : int   NA 2004 1998 2006 NA 1975 NA NA NA NA ...
 $ Concentration: chr   NA NA NA NA ...
 $ Rating_Value : num   NA NA NA NA NA NA NA NA NA NA ...
 $ Rating_Count : int   NA NA NA NA NA NA NA NA NA NA ...
 $ Main_Accords : chr   NA NA "Green, Leathery, Chypre, Animal" NA ...
 $ Top_Notes   : chr   NA "Bergamot" NA NA ...
 $ Middle_Notes: chr   NA "French lavender" NA NA ...
 $ Base_Notes  : chr   NA "Musk, Foulness" NA NA ...
 $ Perfumers    : chr   "Valery Sokolov /" "Harry Frémont" NA NA ...
 $ URL         : chr   "https://www.parfumo.com/Perfumes/Le_Re_Noir/455-tabac-ecarlate" "https://www.parfumo.com/Perfumes/CB_I_Hate_Perfume/0071-Tidal_Pool" "https://www.parfumo.com/Perfumes/CB_I_Hate_Perfume/0154-Pumpkin_Pie" ...
```

```
summary(data_raw[, c("Release_Year", "Rating_Value", "Rating_Count")])
```

Release_Year	Rating_Value	Rating_Count
Min. :1709	Min. : 0.000	Min. : 2.00
1st Qu.:2005	1st Qu.: 6.900	1st Qu.: 6.00
Median :2013	Median : 7.400	Median : 19.00
Mean :2006	Mean : 7.347	Mean : 60.65
3rd Qu.:2018	3rd Qu.: 7.900	3rd Qu.: 62.00
Max. :2024	Max. :10.000	Max. :2732.00
NA's :20316	NA's :29279	NA's :29279

3.2 Gestion des valeurs manquantes

```
na_counts <- sapply(data_raw, function(x) sum(is.na(x)))
na_pct <- round(100 * na_counts / nrow(data_raw), 1)
```

```
na_df <- data.frame(
  Variable = names(na_counts),
  Manquantes = na_counts,
  Pourcentage = na_pct
)
na_df <- na_df[order(-na_df$Pourcentage), ]
rownames(na_df) <- NULL

kable(na_df, booktabs = TRUE)
```

TABLE 2 : Valeurs manquantes par variable

Variable	Manquantes	Pourcentage
Number	57905	97.6
Concentration	46842	79.0
Perfumers	38781	65.4
Rating_Value	29279	49.4
Rating_Count	29279	49.4
Top_Notes	28186	47.5
Middle_Notes	28176	47.5
Base_Notes	28171	47.5
Main_Accords	27100	45.7
Release_Year	20316	34.2
Name	1	0.0
Brand	1	0.0
URL	0	0.0

```
ggplot(na_df, aes(x = reorder(Variable, Pourcentage), y = Pourcentage)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  coord_flip() +
  labs(x = "Variable", y = "% de valeurs manquantes",
       title = "Valeurs manquantes par variable") +
  theme_minimal()
```




FIGURE 1 : Pourcentage de valeurs manquantes par variable

Comme le montre la Figure 1, certaines variables présentent un taux élevé de valeurs manquantes.

3.3 Création de la variable cible : Satisfaction

Nous conservons uniquement les parfums ayant une note (`Rating_Value` non manquante) et créons la variable binaire **Satisfaction** :

- **Oui** : `Rating_Value` $\geq$ médiane
- **Non** : `Rating_Value` $<$ médiane

```
data Rated <- data_raw %>%
  filter(!is.na(Rating_Value))

cat("Parfums avec une note :", nrow(data Rated), "\n")
```

Parfums avec une note : 30046

```
mediane_rating <- median(data Rated$Rating_Value, na.rm = TRUE)
cat("Médiane de Rating_Value :", mediane_rating, "\n")
```

Médiane de Rating_Value : 7.4

```
data Rated <- data Rated %>%
  mutate(Satisfaction = factor(ifelse(Rating_Value >= mediane_rating, "Oui", "Non"),
                                levels = c("Non", "Oui")))

table(data Rated$Satisfaction)
```

Non	Oui
13716	16330

```
prop.table(table(data Rated$Satisfaction))
```

Non	Oui
0.4565	0.5435

```
ggplot(data Rated, aes(x = Satisfaction, fill = Satisfaction)) +
  geom_bar() +
  scale_fill_manual(values = c("Non" = "#E74C3C", "Oui" = "#2ECC71")) +
  labs(x = "Satisfaction", y = "Nombre de parfums",
       title = "Distribution de la variable cible") +
  theme_minimal() +
  theme(legend.position = "none")
```




FIGURE 2 : Distribution de la variable Satisfaction

i Observation

La variable cible est relativement équilibrée grâce à l'utilisation de la médiane comme seuil de binarisation.

3.4 Analyse univariée

3.4.1 Rating_Value (avant binarisation)

```
ggplot(data Rated, aes(x = Rating_Value)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white", alpha = 0.8) +
  geom_vline(xintercept = mediane_rating, color = "red", linetype = "dashed", linewidth = 1) +
  annotate("text", x = mediane_rating + 0.3, y = Inf, vjust = 2,
    label = paste("Médiane =", mediane_rating), color = "red") +
  labs(x = "Note", y = "Fréquence",
    title = "Distribution des notes de parfums") +
  theme_minimal()
```




FIGURE 3 : Distribution de Rating_Value

3.4.2 Release_Year

```
data Rated %>%
  filter(!is.na(Release_Year), Release_Year >= 1900) %>%
  ggplot(aes(x = Release_Year)) +
  geom_histogram(bins = 50, fill = "steelblue", color = "white", alpha = 0.8) +
  labs(x = "Année de sortie", y = "Fréquence",
       title = "Distribution des années de sortie") +
  theme_minimal()
```




FIGURE 4 : Distribution de Release_Year

3.4.3 Rating_Count

```
data Rated %>%
  filter(!is.na(Rating_Count), Rating_Count > 0) %>%
  ggplot(aes(x = log1p(Rating_Count))) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white", alpha = 0.8) +
  labs(x = "log(1 + Rating_Count)", y = "Fréquence",
       title = "Distribution du nombre d'évaluations (échelle log)") +
  theme_minimal()
```




FIGURE 5 : Distribution de Rating_Count (échelle log)

3.4.4 Concentration

```
data Rated %>%
  filter(!is.na(Concentration)) %>%
  count(Concentration, sort = TRUE) %>%
```

```
head(10) %>%
  ggplot(aes(x = reorder(Concentration, n), y = n)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  coord_flip() +
  labs(x = "Concentration", y = "Nombre de parfums",
       title = "Top 10 des types de concentration") +
  theme_minimal()
```




FIGURE 6 : Distribution des types de concentration

3.4.5 Main_Accords (accords les plus fréquents)

```
n_parfums <- sum(!is.na(data Rated$Main_Accords))

accords_all <- data Rated %>%
  filter(!is.na(Main_Accords)) %>%
```

```

pull(Main_Accords) %>%
str_split(",\\s*") %>%
unlist() %>%
str_trim()

accords_freq <- as.data.frame(table(accords_all), stringsAsFactors = FALSE)
colnames(accords_freq) <- c("Accord", "Freq")
accords_freq <- accords_freq %>%
  mutate(Pct = Freq / n_parfums * 100) %>%
  arrange(desc(Freq))

n_total_accords <- nrow(accords_freq)
cat("Nombre total d'accords distincts :", n_total_accords, "\n")

```

Nombre total d'accords distincts : 21

```

accords_freq %>%
  filter(Pct >= 5) %>%
  ggplot(aes(x = reorder(Accord, Freq), y = Freq)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  coord_flip() +
  labs(x = "Accord", y = "Fréquence",
       title = paste0("Accords avec occurrence >= 5% (sur ", n_total_accords, " accords distincts)"),
  theme_minimal()

```




FIGURE 7 : Accords olfactifs avec une occurrence d'au moins 5%

3.5 Analyse multivariée

3.5.1 Satisfaction vs. Rating_Count

```
data_rated %>%
  filter(!is.na(Rating_Count)) %>%
  ggplot(aes(x = Satisfaction, y = log1p(Rating_Count), fill = Satisfaction)) +
  geom_boxplot(alpha = 0.7) +
  scale_fill_manual(values = c("Non" = "#E74C3C", "Oui" = "#2ECC71")) +
  labs(x = "Satisfaction", y = "log(1 + Rating_Count)",
       title = "Nombre d'évaluations selon la satisfaction") +
  theme_minimal() +
  theme(legend.position = "none")
```




FIGURE 8 : Rating_Count selon la Satisfaction

3.5.2 Satisfaction vs. Release_Year

```
data_rated %>%
  filter(!is.na(Release_Year), Release_Year >= 1900) %>%
  ggplot(aes(x = Satisfaction, y = Release_Year, fill = Satisfaction)) +
  geom_boxplot(alpha = 0.7) +
  scale_fill_manual(values = c("Non" = "#E74C3C", "Oui" = "#2ECC71")) +
  labs(x = "Satisfaction", y = "Année de sortie",
       title = "Année de sortie selon la satisfaction") +
  theme_minimal() +
  theme(legend.position = "none")
```




FIGURE 9 : Année de sortie selon la Satisfaction

3.5.3 Satisfaction vs. Concentration

```
data Rated %>%
  filter(!is.na(Concentration)) %>%
  group_by(Concentration) %>%
  filter(n() >= 50) %>%
  summarise(
    n = n(),
    taux_satisfaction = mean(Satisfaction == "Oui"),
    .groups = "drop"
  ) %>%
  ggplot(aes(x = reorder(Concentration, taux_satisfaction), y = taux_satisfaction)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  coord_flip() +
  scale_y_continuous(labels = scales::percent) +
  labs(x = "Concentration", y = "Taux de satisfaction",
       title = "Taux de satisfaction par concentration (n >= 50)") +
  theme_minimal()
```




FIGURE 10 : Taux de satisfaction par type de concentration

3.5.4 Corrélation entre variables numériques

```
num_vars <- data Rated %>%
  select(Release_Year, Rating_Count, Rating_Value) %>%
  filter(complete.cases())

cor_matrix <- cor(num_vars)
corrplot(cor_matrix, method = "color", type = "upper",
  addCoef.col = "black", tl.col = "black",
  title = "Corrélation entre variables numériques",
  mar = c(0, 0, 2, 0))
```




FIGURE 11 : Matrice de corrélation

4 Sauvegarde des données

```
saveRDS(data Rated, here::here("output", "data Rated.rds"))  
cat("data Rated sauvegardé dans output/data Rated.rds\n")
```

data Rated sauvegardé dans output/data Rated.rds

```
cat("Dimensions :", nrow(data Rated), "x", ncol(data Rated), "\n")
```

Dimensions : 30046 x 14