

Partie 3 : Régression Logistique

Compléments de Mathématiques 2 – Introduction au Machine Learning

HAMLIL Mohamed PARDO TERAN German
EL KORAICHI Mohamed Yassine ANZID Keltoum

1736895600000

Table des matières

1	Chargement des données	1
2	Régression Logistique	2
2.1	Principe	2
2.2	Justification	2
2.3	Transformation des variables	2
2.4	Hyperparamètres	2
2.5	Résultats de la validation croisée	3
2.6	Évaluation sur le jeu de test	4
3	Sauvegarde	6

1 Chargement des données

```
train_data <- readRDS(here::here("output", "train_data.rds"))  
test_data <- readRDS(here::here("output", "test_data.rds"))  
cat("Train :", nrow(train_data), "| Test :", nrow(test_data), "\n")
```

Train : 21033 | Test : 9013

2 Régression Logistique

2.1 Principe

Définition

La régression logistique est un modèle linéaire généralisé qui modélise la probabilité d'appartenance à une classe via la fonction logistique :

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}}$$

C'est un modèle simple, interprétable et bien adapté à la classification binaire. Nous utilisons ici une régularisation **Elastic Net** (via `glmnet`) qui combine les pénalités L1 (Lasso) et L2 (Ridge) pour éviter le surapprentissage (Zou et Hastie 2005).

2.2 Justification

- **Interprétabilité** : les coefficients indiquent l'effet de chaque variable sur la satisfaction.
- **Robustesse** : la régularisation gère bien les cas où le nombre de variables est élevé.
- **Baseline solide** : c'est un classifieur de référence pour comparer avec des méthodes plus complexes (Hastie, Tibshirani, et Friedman 2009).

2.3 Transformation des variables

- Les variables numériques sont centrées-réduites pour la régularisation.
- La variable **Concentration** est encodée en indicatrices (dummy encoding via la formule `model.matrix`).

2.4 Hyperparamètres

Nous optimisons deux hyperparamètres :

- **alpha** : mélange L1/L2 (0 = Ridge, 1 = Lasso)
- **lambda** : force de la régularisation

Nous utilisons la **validation croisée 5-fold** avec l'**AUC** (aire sous la courbe ROC) comme métrique.

```

model_file <- here::here("output", "model_logistic.rds")

if (file.exists(model_file)) {
  model_logistic <- readRDS(model_file)
} else {
  ctrl <- trainControl(
    method = "cv",
    number = 5,
    classProbs = TRUE,
    summaryFunction = twoClassSummary,
    savePredictions = "final"
  )

  grid_glmnet <- expand.grid(
    alpha = c(0, 0.25, 0.5, 0.75, 1),
    lambda = 10^seq(-4, -1, length.out = 10)
  )

  set.seed(42)
  model_logistic <- train(
    Satisfaction ~ .,
    data = train_data,
    method = "glmnet",
    trControl = ctrl,
    tuneGrid = grid_glmnet,
    metric = "ROC",
    preProcess = c("center", "scale")
  )
}

```

2.5 Résultats de la validation croisée

```
cat("Meilleurs hyperparamètres :\n")
```

Meilleurs hyperparamètres :

```
cat("  alpha =", model_logistic$bestTune$alpha, "\n")
```

alpha = 0.25

```
cat("  lambda =", model_logistic$bestTune$lambda, "\n")
```

```
lambda = 0.004641589
```

```
cat("  AUC (CV) =", round(max(model_logistic$results$ROC), 4), "\n")
```

```
AUC (CV) = 0.7319
```

```
plot(model_logistic, main = "Régression Logistique - Tuning")
```




FIGURE 1 : Performance de la régression logistique selon les hyperparamètres

2.6 Évaluation sur le jeu de test

```

pred_logistic <- predict(model_logistic, test_data)
prob_logistic <- predict(model_logistic, test_data, type = "prob")

cm_logistic <- confusionMatrix(pred_logistic, test_data$Satisfaction, positive = "Oui")
print(cm_logistic)

```

Confusion Matrix and Statistics

```

      Reference
Prediction Non  Oui
      Non 2261 1077
      Oui 1853 3822

      Accuracy : 0.6749
      95% CI : (0.6651, 0.6846)
      No Information Rate : 0.5435
      P-Value [Acc > NIR] : < 2.2e-16

      Kappa : 0.3348

      Mcnemar's Test P-Value : < 2.2e-16

      Sensitivity : 0.7802
      Specificity : 0.5496
      Pos Pred Value : 0.6735
      Neg Pred Value : 0.6774
      Prevalence : 0.5435
      Detection Rate : 0.4241
      Detection Prevalence : 0.6296
      Balanced Accuracy : 0.6649

      'Positive' Class : Oui

```

```

roc_logistic <- roc(test_data$Satisfaction, prob_logistic$Oui)

plot(roc_logistic, col = "blue", main = "Courbe ROC - Régression Logistique",
     print.auc = TRUE, print.auc.x = 0.4, print.auc.y = 0.3)

```




FIGURE 2 : Courbe ROC – Régression Logistique

3 Sauvegarde

```
saveRDS(model_logistic, here::here("output", "model_logistic.rds"))
saveRDS(cm_logistic, here::here("output", "cm_logistic.rds"))
saveRDS(roc_logistic, here::here("output", "roc_logistic.rds"))
cat("Modèle et résultats sauvegardés dans output/\n")
```

Modèle et résultats sauvegardés dans output/

Hastie, Trevor, Robert Tibshirani, et Jerome Friedman. 2009. *The Elements of Statistical Learning*. Springer.

Zou, Hui, et Trevor Hastie. 2005. « Regularization and Variable Selection via the Elastic Net ». *Journal of the Royal Statistical Society : Series B* 67 (2) : 301-20.