

Partie 5 : Comparaison des Classifieurs et Conclusion

Compléments de Mathématiques 2 – Introduction au Machine Learning

HAMLIL Mohamed PARDO TERAN German
EL KORAICHI Mohamed Yassine ANZID Keltoum

1736895600000

Table des matières

1	Chargement des résultats	1
2	Comparaison des classifieurs	2
2.1	Tableau récapitulatif	2
2.2	Courbes ROC comparées	3
2.3	Validation croisée comparée	4
2.4	Choix final et justification	5
3	Conclusion	7
3.1	Pistes non explorées	7
3.2	Utilisation de l'IA	7
3.3	Contributions individuelles	7
	Références	8

1 Chargement des résultats

```
model_logistic <- readRDS(here::here("output", "model_logistic.rds"))  
model_rf <- readRDS(here::here("output", "model_rf.rds"))  
cm_logistic <- readRDS(here::here("output", "cm_logistic.rds"))  
cm_rf <- readRDS(here::here("output", "cm_rf.rds"))  
roc_logistic <- readRDS(here::here("output", "roc_logistic.rds"))
```

```
roc_rf <- readRDS(here::here("output", "roc_rf.rds"))
cat("Tous les résultats chargés.\n")
```

Tous les résultats chargés.

2 Comparaison des classifieurs

2.1 Tableau récapitulatif

```
results_df <- data.frame(
  Modèle = c("Régression Logistique", "Forêt Aléatoire"),
  AUC_CV = c(round(max(model_logistic$results$ROC), 4),
             round(max(model_rf$results$ROC), 4)),
  AUC_Test = c(round(auc(roc_logistic), 4),
               round(auc(roc_rf), 4)),
  Accuracy = c(round(cm_logistic$overall["Accuracy"], 4),
               round(cm_rf$overall["Accuracy"], 4)),
  Sensibilité = c(round(cm_logistic$byClass["Sensitivity"], 4),
                 round(cm_rf$byClass["Sensitivity"], 4)),
  Spécificité = c(round(cm_logistic$byClass["Specificity"], 4),
                 round(cm_rf$byClass["Specificity"], 4)),
  F1 = c(round(cm_logistic$byClass["F1"], 4),
         round(cm_rf$byClass["F1"], 4))
)

kable(results_df, booktabs = TRUE)
```

TABLE 1 : Comparaison des performances des classifieurs

Modèle	AUC_CV	AUC_Test	Accuracy	Sensibilité	Spécificité	F1
Régression Logistique	0.7319	0.7337	0.6749	0.7802	0.5496	0.7229
Forêt Aléatoire	0.7483	0.7566	0.7010	0.7746	0.6133	0.7380

Le Table 1 résume les performances des deux classifieurs sur le jeu de test.

2.2 Courbes ROC comparées

```
plot(roc_logistic, col = "blue", main = "Comparaison des courbes ROC")
plot(roc_rf, col = "darkgreen", add = TRUE)
legend("bottomright",
      legend = c(
        paste0("Rég. Logistique (AUC = ", round(auc(roc_logistic), 3), ")",
        paste0("Forêt Aléatoire (AUC = ", round(auc(roc_rf), 3), ")",
      ),
      col = c("blue", "darkgreen"),
      lwd = 2)
```




FIGURE 1 : Comparaison des courbes ROC

2.3 Validation croisée comparée

```
resamps <- resamples(list(
  Logistique = model_logistic,
  RandomForest = model_rf
))
summary(resamps)
```

Call:

```
summary.resamples(object = resamps)
```

Models: Logistique, RandomForest

Number of resamples: 5

ROC

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
Logistique	0.7264224	0.7285935	0.7345216	0.7319348	0.7347910	0.7353453	0
RandomForest	0.7418470	0.7438574	0.7486023	0.7482929	0.7487526	0.7584053	0

Sens

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
Logistique	0.5104167	0.5419053	0.5473958	0.5404067	0.5489583	0.5533576	0
RandomForest	0.5609375	0.5770833	0.5963542	0.5894570	0.6002082	0.6127017	0

Spec

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
Logistique	0.7786527	0.7844338	0.7860892	0.7869830	0.7895888	0.7961505	0
RandomForest	0.7567804	0.7621338	0.7891514	0.7791984	0.7930884	0.7948381	0

```
bwplot(resamps, metric = "ROC", main = "Comparaison des AUC (5-fold CV)")
```




FIGURE 2 : Comparaison des AUC par validation croisée

2.4 Choix final et justification

```
if (auc(roc_rf) > auc(roc_logistic)) {
  cat("Le modèle retenu est la Forêt Aléatoire.\n")
  cat("Justification : meilleure AUC sur le jeu de test, capacité à capturer\n")
  cat("les relations non-linéaires entre les notes olfactives et la satisfaction.\n")
} else {
  cat("Le modèle retenu est la Régression Logistique.\n")
  cat("Justification : performance comparable ou supérieure avec une meilleure\n")
  cat("interprétabilité des résultats.\n")
}
```

Le modèle retenu est la Forêt Aléatoire.

Justification : meilleure AUC sur le jeu de test, capacité à capturer les relations non-linéaires entre les notes olfactives et la satisfaction.

! Modèle retenu

Le choix du modèle final repose sur la comparaison de l'AUC sur le jeu de test, combinée à l'analyse de la sensibilité, de la spécificité et du score F1. Voir la Figure 1 pour la visualisation des courbes ROC.

3 Conclusion

Dans ce projet, nous avons construit un pipeline complet de classification supervisée pour prédire la satisfaction des utilisateurs vis-à-vis des parfums.

Résumé des étapes :

1. **Analyse exploratoire** : nous avons identifié les distributions des variables, les valeurs manquantes et les relations avec la variable cible.
2. **Feature engineering** : les variables textuelles (accords, notes) ont été transformées en indicatrices binaires. Des variables de comptage (nombre de notes) ont été ajoutées.
3. **Modélisation** : deux classifieurs ont été entraînés et comparés :
 - La **régression logistique** avec régularisation Elastic Net offre un modèle interprétable (Zou et Hastie 2005).
 - La **forêt aléatoire** capture les interactions non-linéaires entre variables (Breiman 2001).
4. **Évaluation** : les modèles ont été évalués par validation croisée 5-fold et sur un jeu de test indépendant (30%), en utilisant l'AUC, l'accuracy, la sensibilité et la spécificité (Kuhn 2008).

3.1 Pistes non explorées

- **Autres classifieurs** : SVM, XGBoost, ou réseaux de neurones pourraient améliorer les performances.
- **NLP plus avancé** : un encodage TF-IDF ou des embeddings des notes olfactives pourrait mieux capturer l'information textuelle.
- **Données supplémentaires** : le nom de la marque et le parfumeur pourraient être des prédicteurs utiles après encodage adéquat.

3.2 Utilisation de l'IA

[À compléter : préciser les tâches pour lesquelles l'IA a été utilisée et le pourcentage estimé.]

3.3 Contributions individuelles

[À compléter : préciser la contribution de chaque membre du groupe.]

Références

- Breiman, Leo. 2001. « Random Forests ». *Machine Learning* 45 (1) : 5-32.
- Kuhn, Max. 2008. « Building Predictive Models in R Using the caret Package ». *Journal of Statistical Software* 28 (5).
- Zou, Hui, et Trevor Hastie. 2005. « Regularization and Variable Selection via the Elastic Net ». *Journal of the Royal Statistical Society : Series B* 67 (2) : 301-20.