

Partie 1 : Analyse Exploratoire des Données

Compléments de Mathématiques 2 – Introduction au Machine Learning

HAMLIL Mohamed PARDO TERAN German
EL KORAICHI Mohamed Yassine ANZID Keltoum

15 janvier 2025

Table des matières

1	Introduction	2
1.1	Contexte	2
1.2	Variables utilisées	2
2	Chargement des données	3
3	Analyse préliminaire des données	4
3.1	Aperçu général	4
3.2	Gestion des valeurs manquantes	4
3.3	Création de la variable cible : Satisfaction	5
3.4	Analyse univariée	6
3.4.1	Rating_Value (avant binarisation)	6
3.4.2	Release_Year	6
3.4.3	Rating_Count	6
3.4.4	Concentration	6
3.4.5	Main_Accords (accords les plus fréquents)	7
3.5	Analyse multivariée	8
3.5.1	Satisfaction vs. Rating_Count	8
3.5.2	Satisfaction vs. Release_Year	8
3.5.3	Satisfaction vs. Concentration	8
3.5.4	Corrélation entre variables numériques	9
4	Sauvegarde des données	10

1 Introduction

1.1 Contexte

Ce projet s'inscrit dans le cadre du cours de Compléments de Mathématiques 2 (Introduction au Machine Learning). L'objectif est de réaliser une classification supervisée binaire à partir d'un jeu de données réel.

Nous avons choisi un jeu de données de parfums issu de **Parfumo**, une communauté en ligne dédiée aux parfums. Ce dataset contient des informations sur près de 60 000 parfums : leur marque, année de sortie, concentration, notes olfactives, accords principaux et évaluations des utilisateurs.

Lien de téléchargement : [Parfumo Fragrance Dataset – TidyTuesday](#)

i Objectif

Prédire la **satisfaction des utilisateurs** (variable binaire : Oui / Non) à partir des caractéristiques d'un parfum. La satisfaction est définie par la note attribuée par les utilisateurs (**Rating_Value**) : un parfum est considéré comme satisfaisant si sa note est supérieure ou égale à la médiane.

1.2 Variables utilisées

Variable	Type	Description
Release_Year	Numérique	Année de sortie du parfum
Concentration	Catégorielle	Type de concentration (EDP, EDT, etc.)
Rating_Count	Numérique	Nombre d'évaluations reçues
Main_Accords	Texte	Accords olfactifs principaux
Top_Notes	Texte	Notes de tête
Middle_Notes	Texte	Notes de cœur
Base_Notes	Texte	Notes de fond
Satisfaction	Binaire	Variable cible (Oui / Non)

2 Chargement des données

```
data_raw <- read.csv(here::here("data", "parfumo_data_clean.csv"),  
                    stringsAsFactors = FALSE,  
                    na.strings = c("NA", ""))  
  
cat("Dimensions du dataset brut :", nrow(data_raw), "lignes,", ncol(data_raw), "colonnes\n")
```

TABLE 2 : Valeurs manquantes par variable

```
na_counts <- sapply(data_raw, function(x) sum(is.na(x)))
na_pct <- round(100 * na_counts / nrow(data_raw), 1)

na_df <- data.frame(
  Variable = names(na_counts),
  Manquantes = na_counts,
  Pourcentage = na_pct
)
na_df <- na_df[order(-na_df$Pourcentage), ]
rownames(na_df) <- NULL

kable(na_df, booktabs = TRUE)
```

3 Analyse préliminaire des données

3.1 Aperçu général

```
str(data_raw)
```

```
summary(data_raw[, c("Release_Year", "Rating_Value", "Rating_Count")])
```

3.2 Gestion des valeurs manquantes

```
ggplot(na_df, aes(x = reorder(Variable, Pourcentage), y = Pourcentage)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  coord_flip() +
  labs(x = "Variable", y = "% de valeurs manquantes",
       title = "Valeurs manquantes par variable") +
  theme_minimal()
```

Comme le montre la **fig-missing-plot**, certaines variables présentent un taux élevé de valeurs manquantes.

3.3 Création de la variable cible : Satisfaction

Nous conservons uniquement les parfums ayant une note (`Rating_Value` non manquante) et créons la variable binaire **Satisfaction** :

- **Oui** : `Rating_Value` $\geq$ médiane
- **Non** : `Rating_Value` $<$ médiane

```
data_rated <- data_raw %>%
  filter(!is.na(Rating_Value))

cat("Parfums avec une note :", nrow(data_rated), "\n")

mediane_rating <- median(data_rated$Rating_Value, na.rm = TRUE)
cat("Médiane de Rating_Value :", mediane_rating, "\n")

data_rated <- data_rated %>%
  mutate(Satisfaction = factor(ifelse(Rating_Value >= mediane_rating, "Oui", "Non"),
                                levels = c("Non", "Oui")))

table(data_rated$Satisfaction)
prop.table(table(data_rated$Satisfaction))

ggplot(data_rated, aes(x = Satisfaction, fill = Satisfaction)) +
  geom_bar() +
  scale_fill_manual(values = c("Non" = "#E74C3C", "Oui" = "#2ECC71")) +
  labs(x = "Satisfaction", y = "Nombre de parfums",
       title = "Distribution de la variable cible") +
  theme_minimal() +
  theme(legend.position = "none")
```

i Observation

La variable cible est relativement équilibrée grâce à l'utilisation de la médiane comme seuil de binarisation.

3.4 Analyse univariée

3.4.1 Rating_Value (avant binarisation)

```
ggplot(data Rated, aes(x = Rating_Value)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white", alpha = 0.8) +
  geom_vline(xintercept = mediane_rating, color = "red", linetype = "dashed", linewidth = 1)
  annotate("text", x = mediane_rating + 0.3, y = Inf, vjust = 2,
           label = paste("Médiane =", mediane_rating), color = "red") +
  labs(x = "Note", y = "Fréquence",
       title = "Distribution des notes de parfums") +
  theme_minimal()
```

3.4.2 Release_Year

```
data Rated %>%
  filter(!is.na(Release_Year), Release_Year >= 1900) %>%
  ggplot(aes(x = Release_Year)) +
  geom_histogram(bins = 50, fill = "steelblue", color = "white", alpha = 0.8) +
  labs(x = "Année de sortie", y = "Fréquence",
       title = "Distribution des années de sortie") +
  theme_minimal()
```

3.4.3 Rating_Count

```
data Rated %>%
  filter(!is.na(Rating_Count), Rating_Count > 0) %>%
  ggplot(aes(x = log1p(Rating_Count))) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white", alpha = 0.8) +
  labs(x = "log(1 + Rating_Count)", y = "Fréquence",
       title = "Distribution du nombre d'évaluations (échelle log)") +
  theme_minimal()
```

3.4.4 Concentration

```
data Rated %>%
  filter(!is.na(Concentration)) %>%
  count(Concentration, sort = TRUE) %>%
  head(10) %>%
  ggplot(aes(x = reorder(Concentration, n), y = n)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  coord_flip() +
  labs(x = "Concentration", y = "Nombre de parfums",
       title = "Top 10 des types de concentration") +
  theme_minimal()
```

3.4.5 Main_Accords (accords les plus fréquents)

```
n_parfums <- sum(!is.na(data Rated$Main_Accords))

accords_all <- data Rated %>%
  filter(!is.na(Main_Accords)) %>%
  pull(Main_Accords) %>%
  str_split(",\\s*") %>%
  unlist() %>%
  str_trim()

accords_freq <- as.data.frame(table(accords_all), stringsAsFactors = FALSE)
colnames(accords_freq) <- c("Accord", "Freq")
accords_freq <- accords_freq %>%
  mutate(Pct = Freq / n_parfums * 100) %>%
  arrange(desc(Freq))

n_total_accords <- nrow(accords_freq)
cat("Nombre total d'accords distincts :", n_total_accords, "\n")

accords_freq %>%
  filter(Pct >= 5) %>%
  ggplot(aes(x = reorder(Accord, Freq), y = Freq)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  coord_flip() +
  labs(x = "Accord", y = "Fréquence",
       title = paste0("Accords avec occurrence >= 5% (sur ", n_total_accords, " accords distincts)")) +
  theme_minimal()
```

3.5 Analyse multivariée

3.5.1 Satisfaction vs. Rating_Count

```
data_rated %>%
  filter(!is.na(Rating_Count)) %>%
  ggplot(aes(x = Satisfaction, y = log1p(Rating_Count), fill = Satisfaction)) +
  geom_boxplot(alpha = 0.7) +
  scale_fill_manual(values = c("Non" = "#E74C3C", "Oui" = "#2ECC71")) +
  labs(x = "Satisfaction", y = "log(1 + Rating_Count)",
       title = "Nombre d'évaluations selon la satisfaction") +
  theme_minimal() +
  theme(legend.position = "none")
```

3.5.2 Satisfaction vs. Release_Year

```
data_rated %>%
  filter(!is.na(Release_Year), Release_Year >= 1900) %>%
  ggplot(aes(x = Satisfaction, y = Release_Year, fill = Satisfaction)) +
  geom_boxplot(alpha = 0.7) +
  scale_fill_manual(values = c("Non" = "#E74C3C", "Oui" = "#2ECC71")) +
  labs(x = "Satisfaction", y = "Année de sortie",
       title = "Année de sortie selon la satisfaction") +
  theme_minimal() +
  theme(legend.position = "none")
```

3.5.3 Satisfaction vs. Concentration

```
data_rated %>%
  filter(!is.na(Concentration)) %>%
  group_by(Concentration) %>%
  filter(n() >= 50) %>%
  summarise(
    n = n(),
    taux_satisfaction = mean(Satisfaction == "Oui"),
    .groups = "drop"
  ) %>%
```



```
ggplot(aes(x = reorder(Concentration, taux_satisfaction), y = taux_satisfaction)) +  
  geom_bar(stat = "identity", fill = "steelblue") +  
  coord_flip() +  
  scale_y_continuous(labels = scales::percent) +  
  labs(x = "Concentration", y = "Taux de satisfaction",  
       title = "Taux de satisfaction par concentration (n >= 50)") +  
  theme_minimal()
```

3.5.4 Corrélation entre variables numériques

```
num_vars <- data_rated %>%  
  select(Release_Year, Rating_Count, Rating_Value) %>%  
  filter(complete.cases(.))  
  
cor_matrix <- cor(num_vars)  
corrplot(cor_matrix, method = "color", type = "upper",  
         addCoef.col = "black", tl.col = "black",  
         title = "Corrélation entre variables numériques",  
         mar = c(0, 0, 2, 0))
```

4 Sauvegarde des données

```
saveRDS(data Rated, here::here("output", "data Rated.rds"))  
cat("data Rated sauvegardé dans output/data Rated.rds\n")  
cat("Dimensions :", nrow(data Rated), "x", ncol(data Rated), "\n")
```