

Prédiction de la Satisfaction Client pour les Parfums

Compléments de Mathématiques 2 – Introduction au Machine Learning

HAMLIL Mohamed PARDO TERAN German
EL KORAICHI Mohamed Yassine ANZID Keltoum

24 mars 2026

Table des matières

Introduction	3
1 Partie 1 : Analyse Exploratoire des Données	4
1.1 Chargement et variables	4
1.2 Analyse préliminaire	4
1.3 Analyse univariée	6
1.4 Analyse multivariée	8
1.5 Sauvegarde	9
2 Partie 2 : Préparation des Données	10
2.1 Chargement des données	10
2.2 Feature Engineering par familles olfactives	10
2.3 Variables catégorielles	11
2.4 Jeu de données final	11
2.5 Imputation et split	13
2.6 Choix des classifieurs	13
2.7 Sauvegarde	13
3 Partie 3 : Régression Logistique	14
3.1 Chargement des données	14
3.2 Principe	14
3.3 Entraînement	14
3.4 Résultats	15
4 Partie 4 : Forêt Aléatoire	17
4.1 Chargement des données	17
4.2 Principe	17
4.3 Entraînement	17
4.4 Résultats	18
5 Partie 5 : Comparaison et Conclusion	20
5.1 Chargement des résultats	20
5.2 Comparaison des classifieurs	20
5.3 Regard critique	21
5.4 Utilisation de l'IA	22
5.5 Contributions individuelles	22
Références	23

Introduction

Ce projet s'inscrit dans le cadre du cours de **Compléments de Mathématiques 2** (Introduction au Machine Learning), L3 MIASHS, Université Grenoble Alpes.

Objectif

Réaliser une **classification supervisée binaire** à partir d'un jeu de données réel : prédire la **satisfaction des utilisateurs** vis-à-vis de parfums à partir de leurs caractéristiques olfactives, de leur origine et de leur genre cible.

Données

Le dataset utilisé provient de [Fragrantica Fragrance Dataset – Kaggle](#) et contient environ 24 000 parfums avec leurs accords, notes olfactives, marque, pays d'origine et évaluations des utilisateurs.

Plan du rapport

1. **Analyse exploratoire** : présentation des données, analyse univariée et multivariée
2. **Préparation** : feature engineering par familles olfactives, traitement des valeurs manquantes
3. **Régression logistique** : modèle linéaire avec régularisation Elastic Net
4. **Forêt aléatoire** : modèle non-linéaire par ensemble d'arbres
5. **Comparaison** : évaluation comparative, choix final et conclusion

1 Partie 1 : Analyse Exploratoire des Données

1.1 Chargement et variables

Variable	Type	Description
Year	Numérique	Année de sortie du parfum
Gender	Catégorielle	Genre cible (men, women, unisex)
Country	Catégorielle	Pays d'origine de la marque
Rating_Count	Numérique	Nombre d'évaluations reçues
mainaccord1-mainaccord5	Catégorielle	Accords olfactifs principaux
Top, Middle, Base	Texte	Notes de tête, cœur, fond
Satisfaction	Binaire	Variable cible (Oui / Non)

1.2 Analyse préliminaire

1.2.1 Valeurs manquantes




FIGURE 1.1 : Valeurs manquantes par variable

`Perfumer2` et `Base` ont les taux les plus élevés. `Rating_Value` est quasi complète, ce qui permet la construction de la variable cible.

1.2.2 Création de la variable cible

La variable **Satisfaction** est binaire : *Oui* si `Rating_Value` $\geq$ médiane, *Non* sinon.




FIGURE 1.2 : Distribution de la variable Satisfaction

La médiane (3.97) produit une répartition quasi équilibrée (50.7% *Oui*), évitant les biais de déséquilibre.

1.3 Analyse univariée

1.3.1 Rating_Value et Rating_Count




FIGURE 1.3 : Distribution des variables numériques

Les notes sont unimodales et légèrement asymétriques à gauche. Le nombre d'évaluations est fortement asymétrique : la majorité des parfums ont peu de votes.

1.3.2 Year




FIGURE 1.5 : Nombre de parfums par année de sortie

Croissance exponentielle des sorties à partir des années 2000. Les parfums anciens (avant 1980) sont sous-représentés.

1.3.3 Gender et Country




FIGURE 1.6 : Distribution par genre et pays d’origine ($\geq 5\%$)

Les parfums unisex et pour femmes dominant. La France est le premier pays d’origine, suivie des USA et de l’Italie. Les pays $< 5\%$ seront regroupés en “Autre” lors de la préparation.

1.3.4 Accords et notes olfactives




FIGURE 1.8 : Accords olfactifs ($\geq 5\%$ des parfums)

Les accords **woody**, **citrus** et **aromatic** dominant. Ces 84 accords distincts seront regroupés par famille olfactive lors de la préparation.




FIGURE 1.9 : Notes olfactives les plus fréquentes par phase ($\geq 5\%$)

Tête : agrumes (bergamote, citron). Coeur : floraux (jasmin, rose). Fond : boisés/musqués (musc, santal, cèdre). Ce profil justifie le regroupement par familles olfactives.

1.4 Analyse multivariée

1.4.1 Satisfaction vs. variables numériques




FIGURE 1.10 : Variables numériques selon la Sa-FIGURE 1.11 : Variables numériques selon la Sa-tisfaction

Les parfums satisfaisants ont plus d’évaluations (biais de popularité) et sont légèrement plus anciens (effet de survivance).

1.4.2 Satisfaction vs. variables catégorielles





FIGURE 1.12 : Taux de satisfaction par genre et par pays

Le genre est peu discriminant. Certains pays (marques de niche) affichent des taux plus élevés, justifiant l'inclusion du pays comme variable prédictive.

1.4.3 Corrélations




FIGURE 1.14 : Matrice de corrélation

Corrélations faibles : pas de multicolinéarité, chaque variable apporte une information distincte.

1.5 Sauvegarde

2 Partie 2 : Préparation des Données

2.1 Chargement des données

2.2 Feature Engineering par familles olfactives

Plutôt que d’extraire les notes individuelles les plus fréquentes (approche arbitraire), nous regroupons accords et notes par **famille olfactive** selon une roue des parfums. Cette approche est soutenue par Kumar et al. (2015) qui montrent que les descripteurs olfactifs se regroupent naturellement en communautés perceptuelles (« fruit », « floral », « wood », « sweet », « green » sont des *hubs* dominants dans toutes les bases de données étudiées). Nos 10 familles : Citrus, Green, Aquatic, Floral, Fruity, Spicy, Woody, Gourmand, Leather/Smoky, Powdery/Amber.

2.2.1 Accords → familles

Chaque accord (mainaccord1 à mainaccord5) est mappé vers sa famille. Les accords non reconnus → “autre”.

TABLE 2.1 : Distribution des familles olfactives (accords)

Famille	Parfums	%
woody	15919	66.2
floral	13386	55.6
powdery_amber	12500	51.9
spicy	10541	43.8
gourmand	10264	42.7
citrus	9493	39.5
fruity	7433	30.9
aquatic	4495	18.7
green	3760	15.6
leather_smoky	2322	9.6
autre	592	2.5

Les familles **woody**, **gourmand** et **floral** couvrent la majorité des parfums, cohérent avec les tendances du marché.

2.2.2 Notes → familles

Chaque note individuelle (tête, cœur, fond) est classée par correspondance de mots-clés → 30 indicatrices (10 familles x 3 phases).

2.3 Variables catégorielles

2.3.1 Gender

2.3.2 Country (regroupement < 5%)

Les pays rares sont regroupés en “Autre” pour éviter des indicatrices trop creuses.

TABLE 2.2 : Pays après regroupement (seuil 5%)

Pays	Effectif	%
France	7261	30.2
USA	4473	18.6
Autre	3422	14.2
Italy	3310	13.8
UK	1724	7.2
Brazil	1338	5.6
Spain	1307	5.4
UAE	1228	5.1

2.4 Jeu de données final

54 variables explicatives | 24063 observations

TABLE 2.3 : Variables retenues pour la modélisation

Variable	Catégorie
Year	Numérique
Rating_Count	Numérique
gender_women	Genre (binaire)
gender_men	Genre (binaire)
gender_unisex	Genre (binaire)
country_France	Pays (binaire)
country_USA	Pays (binaire)
country_Autre	Pays (binaire)

TABLE 2.3 : Variables retenues pour la modélisation

Variable	Catégorie
country_Italy	Pays (binaire)
country_UK	Pays (binaire)
country_Brazil	Pays (binaire)
country_Spain	Pays (binaire)
country_UAE	Pays (binaire)
fam_citrus	Famille accord (binaire)
fam_green	Famille accord (binaire)
fam_aquatic	Famille accord (binaire)
fam_floral	Famille accord (binaire)
fam_fruity	Famille accord (binaire)
fam_spicy	Famille accord (binaire)
fam_woody	Famille accord (binaire)
fam_gourmand	Famille accord (binaire)
fam_leather_smoky	Famille accord (binaire)
fam_powdery_amber	Famille accord (binaire)
fam_autre	Famille accord (binaire)
top_citrus	Famille note tête (binaire)
top_green	Famille note tête (binaire)
top_aquatic	Famille note tête (binaire)
top_floral	Famille note tête (binaire)
top_fruity	Famille note tête (binaire)
top_spicy	Famille note tête (binaire)
top_woody	Famille note tête (binaire)
top_gourmand	Famille note tête (binaire)
top_leather_smoky	Famille note tête (binaire)
top_powdery_amber	Famille note tête (binaire)
mid_citrus	Famille note cœur (binaire)
mid_green	Famille note cœur (binaire)
mid_aquatic	Famille note cœur (binaire)
mid_floral	Famille note cœur (binaire)
mid_fruity	Famille note cœur (binaire)
mid_spicy	Famille note cœur (binaire)
mid_woody	Famille note cœur (binaire)
mid_gourmand	Famille note cœur (binaire)
mid_leather_smoky	Famille note cœur (binaire)
mid_powdery_amber	Famille note cœur (binaire)
base_citrus	Famille note fond (binaire)
base_green	Famille note fond (binaire)
base_aquatic	Famille note fond (binaire)
base_floral	Famille note fond (binaire)
base_fruity	Famille note fond (binaire)

TABLE 2.3 : Variables retenues pour la modélisation

Variable	Catégorie
base_spicy	Famille note fond (binaire)
base_woody	Famille note fond (binaire)
base_gourmand	Famille note fond (binaire)
base_leather_smoky	Famille note fond (binaire)
base_powdery_amber	Famille note fond (binaire)

2.5 Imputation et split

L'imputation par la **médiane** est robuste aux valeurs extrêmes (**Rating_Count**).

TABLE 2.4 : Répartition train / test

Ensemble	Observations	Prop. Oui
Train	16845	0.507
Test	7218	0.507

2.6 Choix des classifieurs

Données binaires/numériques, cible équilibrée, pas de valeurs manquantes → deux classifieurs complémentaires :

1. **Régression logistique (Elastic Net)** : baseline interprétable, sélection automatique de variables par régularisation.
2. **Forêt aléatoire** : capture les interactions non-linéaires entre familles olfactives, classement d'importance des variables.

Métrique principale : **AUC** (capacité discriminante indépendante du seuil).

2.7 Sauvegarde

3 Partie 3 : Régression Logistique

3.1 Chargement des données

3.2 Principe

Définition

La régression logistique modélise la probabilité d'appartenance à une classe :

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}}$$

Nous utilisons une régularisation **Elastic Net** (`glmnet`) combinant pénalités L1 et L2 (Zou et Hastie 2005). Ce modèle est interprétable (coefficients), robuste (régularisation) et sert de baseline (Hastie, Tibshirani, et Friedman 2009).

3.3 Entraînement

Variables numériques centrées-réduites. Hyperparamètres **alpha** (mélange L1/L2) et **lambda** (force) optimisés par validation croisée 5-fold (métrique : AUC).

3.4 Résultats




FIGURE 3.1 : AUC selon alpha et lambda

TABLE 3.1 : Métriques (Régression Logistique)

Métrique	Valeur
alpha	1.000000
lambda	0.002154
AUC (CV)	0.668300
AUC (test)	0.669500
Accuracy	0.622600
Sensibilité	0.640100
Spécificité	0.604600
F1	0.632500




FIGURE 3.2 : Courbe ROC – Régression Logistique

La performance est modeste mais réelle, ce qui est attendu pour la prédiction d'une variable subjective comme la satisfaction à partir de caractéristiques olfactives.

4 Partie 4 : Forêt Aléatoire

4.1 Chargement des données

4.2 Principe

Définition

La forêt aléatoire est un ensemble de B arbres de décision entraînés sur des échantillons bootstrap. À chaque nœud, seul un sous-ensemble de m variables est considéré. Prédiction par **vote majoritaire** (Breiman 2001).

Avantages : capture des interactions non-linéaires entre familles olfactives, robustesse, classement d'importance des variables. Pas de prétraitement nécessaire. Ce choix est validé par Kumar et al. (2015) qui obtiennent des $AUC > 0.7$ avec un random forest pour la prédiction de qualités perceptuelles olfactives à partir de descripteurs similaires aux nôtres.

4.3 Entraînement

Hyperparamètre **mtry** optimisé par validation croisée 5-fold (métrique : AUC). 500 arbres.

4.4 Résultats




FIGURE 4.1 : Performance selon mtry




FIGURE 4.2 : Importance des variables (Top 15)

TABLE 4.1 : Métriques (Forêt Aléatoire)

Métrique	Valeur
mtry	3.0000
AUC (CV)	0.6904
AUC (test)	0.6934

TABLE 4.1 : Métriques (Forêt Aléatoire)

Métrique	Valeur
Accuracy	0.6424
Sensibilité	0.6810
Spécificité	0.6026
F1	0.6590




FIGURE 4.3 : Courbe ROC – Forêt Aléatoire

Le classement d'importance confirme le rôle prédictif des familles olfactives et du nombre d'évaluations. La forêt aléatoire exploite les interactions non-linéaires pour améliorer la discrimination.

5 Partie 5 : Comparaison et Conclusion

5.1 Chargement des résultats

5.2 Comparaison des classifieurs

TABLE 5.1 : Comparaison des performances

Modèle	AUC_CV	AUC_Test	Accuracy	F1
Rég. Logistique	0.6683	0.6695	0.6226	0.6325
Forêt Aléatoire	0.6904	0.6934	0.6424	0.6590





FIGURE 5.1 : Courbes ROC comparées et distribution des AUC (5-fold CV)

FIGURE 5.2 : Courbes ROC comparées et distribution des AUC (5-fold CV)

L'écart entre AUC CV et test indique la généralisation. Un modèle dont la courbe ROC enveloppe l'autre est uniformément meilleur.

5.2.1 Choix final

Modèle retenu : Forêt Aléatoire (AUC test = 0.6934 vs 0.6695).

La forêt aléatoire capture les interactions non-linéaires entre familles olfactives.

Critère	Rég. Logistique	Forêt Aléatoire
Interprétabilité	Coefficients lisibles	Importance uniquement
Non-linéarité	Non	Oui
Temps d'entraînement	Rapide	Plus lent
Surapprentissage	Régularisation	Bagging + mtry

5.3 Regard critique

5.3.1 Limites

- **Variable cible construite** : le seuil (médiane) est arbitraire. Un autre seuil produirait des classes déséquilibrées.
- **Perte d'information** : le regroupement par familles traite “rose” et “iris” (tous deux “floral”) de la même façon. Néanmoins, Kumar et al. (2015) montrent que les descripteurs olfactifs forment naturellement des communautés perceptuelles via un réseau de co-occurrence, ce qui soutient la validité de ce regroupement.
- **Accords tronqués** : seulement 5 accords sur 10+ disponibles dans les données brutes.
- **Marque absente** : forte influence probable, mais cardinalité trop élevée pour un encodage simple.

5.3.2 Ce qui conforte notre approche

- Les communautés détectées par Kumar et al. (2015) (Fig. 3) correspondent à nos familles : les *hubs* « fruit », « floral », « wood », « sweet », « green » dominant dans 6 bases de données indépendantes.
- Les auteurs obtiennent des $AUC > 0.7$ avec un random forest sur des descripteurs perceptuels, ce qui est cohérent avec nos résultats.
- Le réseau olfactif est **disassortatif** (les descripteurs larges se connectent aux spécifiques), ce qui justifie de regrouper les accords spécifiques en familles larges.

5.3.3 Pistes d'amélioration

- Pondération par rang d'accord (1er = plus dominant)
- Target encoding de la marque par segment (luxe, niche, mass-market)
- Autres classifieurs : SVM, XGBoost, KNN
- Text mining : TF-IDF sur les descriptions textuelles
- Approche par réseau de co-occurrence des notes, comme proposé par Kumar et al. (2015), pour capturer les relations entre descripteurs

5.4 Utilisation de l'IA

[À compléter]

5.5 Contributions individuelles

[À compléter]

Références

- Breiman, Leo. 2001. « Random Forests ». *Machine Learning* 45 (1) : 5-32.
- Hastie, Trevor, Robert Tibshirani, et Jerome Friedman. 2009. *The Elements of Statistical Learning*. Springer.
- Kumar, Ritesh, Rishemjit Kaur, Benjamin Auffarth, et Amol P. Bhondekar. 2015. « Understanding the Odour Spaces : A Step towards Solving Olfactory Stimulus-Percept Problem ». *PLoS ONE* 10 (10) : e0141263. <https://doi.org/10.1371/journal.pone.0141263>.
- Zou, Hui, et Trevor Hastie. 2005. « Regularization and Variable Selection via the Elastic Net ». *Journal of the Royal Statistical Society : Series B* 67 (2) : 301-20.