



Prédiction de la Satisfaction Client pour les Parfums

Compléments de Mathématiques 2 – Introduction au Machine Learning

L3 MIASHS – Université Grenoble Alpes

HAMLIL Mohamed PARDO TERAN German
EL KORAICHI Mohamed Yassine ANZID Keltoum

25 mars 2026

Table des matières

Introduction	3
1 Partie 1 : Analyse Exploratoire des Données	4
1.1 Chargement et variables	4
1.2 Analyse préliminaire	5
1.3 Analyse univariée	6
1.4 Analyse multivariée	10
2 Partie 2 : Préparation des Données	13
2.1 Feature Engineering par familles olfactives	13
2.2 Variables catégorielles	15
2.3 Jeu de données final	15
2.4 Imputation et split	16
2.5 Choix des classifieurs	16
3 Partie 3 : Régression Logistique	18
3.1 Principe	18
3.2 Entraînement	18
3.3 Résultats	18
4 Partie 4 : Forêt Aléatoire	20
4.1 Principe	20
4.2 Entraînement	20
4.3 Résultats	20
5 Partie 5 : Comparaison et Conclusion	22
5.1 Comparaison des classifieurs	22
5.2 Regard critique	23
5.3 Utilisation de l'IA	23
5.4 Contributions individuelles	23
Références	24

Introduction

Ce projet s'inscrit dans le cadre du cours de **Compléments de Mathématiques 2** (Introduction au Machine Learning), L3 MIASHS, Université Grenoble Alpes.

Contexte

L'industrie de la parfumerie est un domaine où la perception subjective joue un rôle central. Chaque parfum est caractérisé par une architecture olfactive complexe, reposant sur trois notions fondamentales qu'il convient de distinguer :

- **Note olfactive**¹ : un ingrédient ou une matière première individuelle (ex. : bergamote, jasmin, musc). Les notes sont organisées en trois phases selon leur volatilité : les *notes de tête* (premières perçues, légères et éphémères), les *notes de cœur* (le corps du parfum, apparaissant après quelques minutes) et les *notes de fond* (les plus persistantes, perçues en dernier).
- **Accord olfactif**² : une combinaison harmonieuse de plusieurs notes qui, ensemble, produisent une impression olfactive distincte (ex. : « woody », « floral », « citrus »). Un parfum possède généralement plusieurs accords dominants.
- **Famille olfactive**³ : une grande catégorie qui regroupe des accords et des notes partageant un caractère olfactif commun. Par exemple, la famille *boisée* englobe les accords « woody », « aromatic », « oud » et « patchouli ».

La question que nous posons est la suivante : **peut-on prédire si un parfum sera bien noté par les utilisateurs à partir de ses caractéristiques olfactives, de son origine et de son genre cible ?**

Objectif

Réaliser une **classification supervisée binaire** à partir d'un jeu de données réel : prédire la **satisfaction des utilisateurs** vis-à-vis de parfums à partir de leurs caractéristiques olfactives, de leur origine et de leur genre cible.

Données

Le dataset utilisé provient de [Fragrantica Fragrance Dataset](#) – Kaggle et contient environ 24 000 parfums avec leurs accords, notes olfactives, marque, pays d'origine et évaluations des utilisateurs. Fragrantica est une encyclopédie en ligne de référence dans le monde de la parfumerie, alimentée par les avis de millions d'utilisateurs.

Plan du rapport

1. **Analyse exploratoire** : présentation des données, analyse univariée et multivariée
2. **Préparation** : feature engineering par familles olfactives, traitement des valeurs manquantes
3. **Régression logistique** : modèle linéaire avec régularisation Elastic Net
4. **Forêt aléatoire** : modèle non-linéaire par ensemble d'arbres
5. **Comparaison** : évaluation comparative, choix final et conclusion

1. Ingrédient individuel perçu dans un parfum, par exemple la bergamote, le jasmin ou le musc.

2. Combinaison harmonieuse de plusieurs notes qui crée une impression olfactive distincte, par exemple « boisé » ou « floral ».

3. Grande catégorie regroupant des accords et notes partageant un caractère olfactif commun (ex. : la famille « boisée » regroupe les accords woody, aromatic, oud, patchouli, etc.).

1 Partie 1 : Analyse Exploratoire des Données

1.1 Chargement et variables

Nous utilisons la version **nettoyée** (*cleaned*) du dataset Fragrantica. Ce fichier corrige les incohérences des données brutes : noms de marques et de pays standardisés, catégories de genre unifiées, notes numériques au format décimal, notes olfactives parsées et séparées. Le dataset contient environ 24 000 parfums et les variables suivantes :

TABLE 1.1 : Description des variables du dataset

Variable	Type	Description
Perfume	Texte	Nom du parfum (identifiant, non utilisé en modélisation)
Brand	Catégorielle	Marque du parfum (standardisée, non retenue car trop de modalités)
Year	Numérique	Année de sortie du parfum
Gender	Catégorielle	Genre cible du parfum : <i>men</i> , <i>women</i> ou <i>unisex</i>
Country	Catégorielle	Pays d'origine de la marque (noms standardisés)
Rating_Value	Numérique	Note moyenne attribuée par les utilisateurs (échelle continue)
Rating_Count	Numérique	Nombre total d'évaluations reçues
Perfumer1, Perfumer2	Catégorielle	Parfumeurs créateurs (séparés et standardisés)
mainaccord1-mainaccord5	Catégorielle	Les 5 accords olfactifs ¹ principaux du parfum
Top, Middle, Base	Texte	Notes de tête, de cœur et de fond ² (parsées et standardisées)
Satisfaction	Binaire	Variable cible construite (Oui / Non) — voir section suivante

Parmi ces variables, **Perfume**, **Brand**, **URL** et **Perfumer1/Perfumer2** ne sont pas retenues pour la modélisation : elles servent d'identifiants ou présentent une cardinalité³ trop élevée. La variable **Rating_Value** est utilisée pour **construire** la variable cible **Satisfaction**, mais n'est pas incluse comme variable explicative (ce serait une fuite d'information⁴).

1. Accord olfactif : impression olfactive dominante d'un parfum (ex. : *woody*, *floral*, *citrus*). Voir l'introduction pour la distinction avec les notes et les familles.

2. Les notes de **tête** sont les premières perçues (fraîches, volatiles) ; les notes de **cœur** forment le corps du parfum ; les notes de **fond** sont les plus persistantes.

3. Cardinalité : nombre de modalités distinctes d'une variable catégorielle. Une cardinalité élevée (ex. : des milliers de marques) rend l'encodage difficile et le modèle instable.

4. Fuite d'information (*data leakage*) : inclusion dans le modèle d'une variable qui contient directement ou indirectement l'information de la cible, ce qui gonfle artificiellement les performances.

1.2 Analyse préliminaire

1.2.1 Valeurs manquantes




FIGURE 1.1 : Valeurs manquantes par variable

Perfumer2 (le second parfumeur associé au parfum) et **Base** (les notes de fond) présentent les taux de valeurs manquantes les plus élevés. Cela s'explique naturellement : la majorité des parfums n'ont qu'un seul créateur, et les notes de fond ne sont pas toujours renseignées sur Fragrantica. Nous pouvons négliger **Perfumer2** sans perte d'information significative, car cette variable n'apporte pas de pouvoir prédictif exploitable dans notre contexte (trop de modalités, trop de données manquantes).

En revanche, les variables essentielles pour notre modélisation — **Rating_Value** (quasi complète), **Gender**, **Country**, et les accords olfactifs (**mainaccord1** à **mainaccord5**) — présentent des taux de complétion élevés, ce qui est rassurant pour la suite de l'analyse.

1.2.2 Création de la variable cible

La variable **Satisfaction** est binaire : *Oui* si **Rating_Value** médiane, *Non* sinon.

Pourquoi la médiane comme seuil ? Nous avons choisi la médiane plutôt que la moyenne ou un seuil arbitraire (par exemple 5/10) pour plusieurs raisons :

- La **médiane** est robuste aux valeurs extrêmes⁵, contrairement à la moyenne qui serait tirée vers le haut par les notes élevées (la distribution est asymétrique à gauche).
- Un seuil fixe comme 5/10 ne tient pas compte de la distribution réelle des notes : si la grande majorité des parfums sont notés au-dessus de 5, ce seuil produirait des classes très déséquilibrées (trop de « Oui »), ce qui dégraderait les performances des classifieurs.
- La médiane garantit par construction une répartition **quasi équilibrée** des deux classes, ce qui est souhaitable pour la classification supervisée.

5. Robuste aux valeurs extrêmes : la médiane n'est pas influencée par quelques notes très hautes ou très basses, contrairement à la moyenne.




FIGURE 1.2 : Distribution de la variable Satisfaction

La médiane (3.97) produit effectivement une répartition quasi équilibrée (50.7 % Oui), confirmant la pertinence de ce choix de seuil.

1.3 Analyse univariée

1.3.1 Rating_Value et Rating_Count




FIGURE 1.3 : Distribution des variables numériques




FIGURE 1.4 : Distribution des variables numériques

La distribution de **Rating_Value** est unimodale⁶ et légèrement asymétrique à gauche, indiquant que les utilisateurs ont tendance à attribuer des notes plutôt élevées. La distribution de **Rating_Count** est fortement asymétrique à droite : la grande majorité des parfums reçoivent peu d'évaluations, tandis que quelques parfums populaires en cumulent des milliers. La transformation logarithmique ($\log(1 + x)$) permet de mieux visualiser cette distribution très étalée.

6. Unimodale : la distribution ne présente qu'un seul pic (un seul mode).

1.3.2 Year




FIGURE 1.5 : Nombre de parfums par année de sortie

Croissance exponentielle des sorties à partir des années 2000. Les parfums anciens (avant 1980) sont sous-représentés.

1.3.3 Gender et Country




FIGURE 1.6 : Distribution par genre et pays d'origine ($\geq 5\%$)




FIGURE 1.7 : Distribution par genre et pays d'origine ($\geq 5\%$)

Les parfums unisex et pour femmes dominent le marché. La **France** est le premier pays d'origine des marques de parfum — ce qui n'est pas surprenant puisque la France est le berceau historique de la parfumerie moderne, notamment grâce à la ville de **Grasse**⁷, capitale mondiale du parfum depuis le XVII^e siècle. Elle est suivie des États-Unis et de l'Italie.

Les pays représentant moins de 5 % de l'effectif total seront regroupés dans une catégorie « Autre » lors de la préparation des données. Ce regroupement est nécessaire pour éviter de créer des variables indicatrices⁸ trop

7. Grasse (Alpes-Maritimes) : capitale mondiale de la parfumerie depuis le XVII^e siècle, centre historique de production de matières premières et de création de parfums.

8. Variable indicatrice (ou *dummy variable*) : variable binaire (0/1) créée pour représenter chaque modalité d'une variable catégorielle dans un modèle.

creuses (beaucoup de zéros), ce qui dégraderait la qualité des modèles.

1.3.4 Accords et notes olfactives




FIGURE 1.8 : Accords olfactifs ($\geq 5\%$ des parfums)

Les accords⁹ **boisés** (*woody*), **agrumes** (*citrus*) et **aromatiques** (*aromatic*) dominent largement. Ces 84 accords distincts seront regroupés par **famille olfactive** lors de la préparation (cf. Partie 2), afin de réduire la dimensionnalité tout en conservant l'information olfactive essentielle.

9. Accord olfactif : combinaison de notes créant une impression distincte (ex. : « boisé », « agrumes »). Voir l'introduction pour la distinction avec les notes et les familles.




FIGURE 1.9 : Notes olfactives les plus fréquentes par phase ($\geq 5\%$) — Tête : premières notes perçues ; Cœur : corps du parfum ; Fond : notes persistantes

On retrouve un profil olfactif cohérent à travers les trois phases :

- **Tête** : dominée par les agrumes (bergamote, citron) — des notes fraîches et volatiles qui constituent la première impression du parfum.
- **Cœur** : dominé par les notes florales (jasmin, rose) — le corps du parfum, qui se développe après les premières minutes.
- **Fond** : dominé par les notes boisées et musquées (musc, santal, cèdre) — les notes les plus persistantes, qui ancrent le parfum.

Cette structure classique (agrumes $\rightarrow$ floraux $\rightarrow$ boisés) se retrouve dans une grande partie de la parfumerie et justifie notre choix de regrouper les notes individuelles par familles olfactives lors de la préparation des données.

1.4 Analyse multivariée

1.4.1 Satisfaction vs. variables numériques





FIGURE 1.10 : Variables numériques selon la Satisfaction

Les parfums satisfaisants ont plus d'évaluations (biais de popularité) et sont légèrement plus anciens (effet de survivance).

1.4.2 Satisfaction vs. variables catégorielles





FIGURE 1.12 : Taux de satisfaction par genre

Le genre cible du parfum est **peu discriminant** : les taux de satisfaction sont proches entre les catégories (hommes, femmes, unisex). Cela signifie que le genre seul ne suffit pas à prédire la satisfaction.

FIGURE 1.13 : Taux de satisfaction par pays d'origine ($n \geq 100$)

En revanche, le **pays d'origine** montre des différences plus marquées. Certains pays associés à des marques de niche¹⁰ affichent des taux de satisfaction plus élevés, ce qui justifie l'inclusion du pays comme variable prédictive dans nos modèles.

1.4.3 Corrélations




FIGURE 1.14 : Matrice de corrélation entre les variables numériques

10. Marque de niche : maison de parfumerie artisanale ou spécialisée, par opposition aux grandes marques de distribution (« mass-market »).

La matrice de corrélation¹¹ montre des **corrélations faibles** entre les trois variables numériques (**Year**, **Rating_Count**, **Rating_Value**). Cela signifie :

- Il n'y a pas de **multicolinéarité**¹² problématique : chaque variable apporte une information distincte au modèle.
- L'année de sortie n'est pas linéairement liée au nombre d'évaluations ni à la note — ces variables capturent des aspects différents des parfums.

11. Matrice de corrélation : tableau symétrique montrant le coefficient de corrélation de Pearson entre chaque paire de variables numériques. Un coefficient proche de 0 indique l'absence de relation linéaire ; proche de 1 ou -1, une forte relation.

12. Multicolinéarité : situation où deux variables explicatives sont fortement corrélées entre elles, ce qui peut rendre instables les coefficients d'un modèle de régression.

2 Partie 2 : Préparation des Données

2.1 Feature Engineering par familles olfactives

L'objectif de cette étape est de transformer les données brutes (accords et notes individuelles) en variables exploitables par un modèle de classification. Plutôt que d'extraire les notes individuelles les plus fréquentes (approche arbitraire qui perdrait les relations entre notes proches), nous regroupons accords et notes par **famille olfactive** selon une **roue des parfums**¹.

Cette approche est soutenue par Kumar et al. (2015) qui montrent que les descripteurs olfactifs se regroupent naturellement en communautés perceptuelles (« fruit », « floral », « wood », « sweet », « green » sont des *hubs* dominants dans toutes les bases de données étudiées). Nous retenons **10 familles**, décrites ci-dessous :

TABLE 2.1 : Les 10 familles olfactives utilisées pour le regroupement

Famille	Description	Phase dominante	Exemples d'accords/notes
Citrus	Notes vives, pétillantes et solaires. Fraîcheur immédiate.	Tête	bergamote, citron, yuzu, orange sanguine
Green	Herbes fraîchement coupées, thé, bambou. Évoquent la nature et la pureté.	Tête / Cœur	foin, figue verte, thé vert, bambou
Aquatic	Impressions de mer, pluie, air marin. Fraîcheur minérale.	Tête	calone, ambrox, musc marin, péttrichor
Floral	Des floraux légers (muguet, pivoine) aux floraux riches et sensuels (rose, tubéreuse, jasmin).	Cœur	rose, jasmin, ylang-ylang, iris
Fruity	Notes jeunes et vibrantes de fruits rouges, tropicaux ou à noyau.	Tête / Cœur	framboise, mangue, pêche, pomme verte
Spicy	Notes chaudes et intrigantes d'épices. Caractère sensuel.	Cœur / Fond	cannelle, cardamome, poivre rose, safran
Woody	Des bois légers (santal, cèdre) aux bois sombres (oud, patchouli, vétiver fumé).	Fond	santal, cèdre, oud, vétiver, mousse de chêne

1. Roue des parfums (*fragrance wheel*) : classification circulaire des familles olfactives, inventée par Michael Edwards en 1983. Elle organise les parfums en grandes familles (florale, boisée, orientale, fraîche...) et montre leurs proximités. Voir par exemple : fragrancesoftheworld.com

Famille	Description	Phase dominante	Exemples d'accords/notes
Gourmand	Notes sucrées et comestibles. Très populaires dans la parfumerie contemporaine.	Fond	vanille, caramel, tonka, café, chocolat
Leather / Smoky	Accords de caractère : cuir, tabac, encens, fumée. Profondeur et mystère.	Fond	cuir, daim, tabac, encens, oliban, myrrhe
Powdery / Amber	Doux, enveloppants, « seconde peau ». Bases chaudes et résineux ambrés.	Fond	musc blanc, iris poudré, ambre, labdanum, benjoin

2.1.1 Accords → familles

Chaque accord (`mainaccord1` à `mainaccord5`) est associé à sa famille olfactive via une table de correspondance. Par exemple, pour la famille **boisée** (*woody*), le mapping regroupe les accords suivants :

TABLE 2.2 : Extrait du mapping pour la famille boisée

Accord Fragrantica	→ Famille
woody	Woody
aromatic	Woody
oud	Woody
patchouli	Woody
mossy	Woody
earthy	Woody

Le même principe s'applique aux 9 autres familles. Les accords non reconnus (absents de notre table de correspondance) sont classés dans une catégorie « autre ».

TABLE 2.3 : Distribution des familles olfactives (accords)

Famille	Parfums	%
woody	15919	66.2
floral	13386	55.6
powdery_amber	12500	51.9
spicy	10541	43.8
gourmand	10264	42.7
citrus	9493	39.5
fruity	7433	30.9
aquatic	4495	18.7
green	3760	15.6
leather_smoky	2322	9.6
autre	592	2.5

Les familles **woody**, **gourmand** et **floral** couvrent la majorité des parfums, cohérent avec les tendances du marché.

2.1.2 Notes → familles

En plus des accords (qui décrivent l'impression générale), chaque parfum possède des **notes individuelles** réparties en trois phases : tête, cœur et fond. Chaque note est un ingrédient précis (ex. : « bergamot », « sandalwood », « vanilla »).

Pour chaque phase, nous classons chaque note dans l'une des 10 familles olfactives à l'aide d'une liste de mots-clés. Par exemple, si la note « sandalwood » apparaît dans les notes de fond, la variable `base_woody` prend la valeur 1. Cela produit **30 variables indicatrices** (10 familles × 3 phases), qui capturent le profil olfactif du parfum à chaque étape de son évolution.

Cette approche permet de transformer des données textuelles (listes de notes séparées par des virgules) en variables numériques exploitables par les modèles, tout en préservant la structure tête/cœur/fond qui est fondamentale en parfumerie.

2.2 Variables catégorielles

2.2.1 Gender

La variable **Gender** (genre cible du parfum) est catégorielle avec trois modalités : *women*, *men*, *unisex*. Pour l'intégrer dans nos modèles, nous la transformons en **trois variables indicatrices** (encodage *one-hot*²). Chaque parfum aura ainsi une valeur 1 dans la colonne correspondant à son genre cible et 0 dans les autres.

2.2.2 Country (regroupement < 5%)

Le pays d'origine de la marque est une variable potentiellement discriminante, comme observé dans l'analyse exploratoire. La **France** domine largement le dataset — ce qui reflète son statut historique de berceau de la parfumerie mondiale (Grasse, capitale du parfum depuis le XVII^e siècle). Les pays représentant moins de 5 % de l'effectif sont regroupés en « Autre » pour éviter des variables indicatrices trop creuses (majoritairement des zéros), ce qui pourrait introduire du bruit dans les modèles.

TABLE 2.4 : Pays après regroupement (seuil 5%)

Pays	Effectif	%
France	7261	30.2
USA	4473	18.6
Autre	3422	14.2
Italy	3310	13.8
UK	1724	7.2
Brazil	1338	5.6
Spain	1307	5.4
UAE	1228	5.1

2.3 Jeu de données final

Au total, le jeu de données comprend **54 variables explicatives** pour **24063 observations**. Le tableau ci-dessous résume les catégories de variables retenues :

2. Encodage *one-hot* : transformation d'une variable catégorielle à k modalités en k colonnes binaires (0/1), une par modalité.

TABLE 2.5 : Résumé des variables retenues pour la modélisation

Catégorie	Nombre	Exemples
Numérique	2	Year, Rating_Count
Genre (binaire)	3	gender_women, gender_men, gender_unisex
Pays (binaire)	8	country_France, country_Autre, ...
Famille accord (binaire)	11	fam_woody, fam_floral, ...
Famille note tête (binaire)	10	top_citrus, top_floral, ...
Famille note cœur (binaire)	10	mid_spicy, mid_gourmand, ...
Famille note fond (binaire)	10	base_woody, base_powdery_amber, ...

2.4 Imputation et split

Certaines variables numériques (notamment **Rating_Count**) contiennent des valeurs manquantes qu'il faut imputer³ avant la modélisation. Nous choisissons l'imputation par la **médiane** plutôt que par la moyenne pour les raisons suivantes :

- La **médiane est robuste aux valeurs extrêmes** : **Rating_Count** présente une distribution très asymétrique (quelques parfums ont des milliers d'avis). La moyenne serait tirée vers le haut par ces valeurs extrêmes, ce qui donnerait une imputation peu représentative de la majorité des parfums.
- D'autres méthodes plus sophistiquées (imputation par KNN, par régression, ou par algorithme MICE) seraient possibles mais ajouteraient de la complexité sans gain garanti, étant donné que le taux de valeurs manquantes est faible.

TABLE 2.6 : Répartition train / test

Ensemble	Observations	Prop. Oui
Train	16845	0.507
Test	7218	0.507

2.5 Choix des classifieurs

Notre jeu de données présente les caractéristiques suivantes après préparation : variables explicatives binaires et numériques, variable cible équilibrée, pas de valeurs manquantes. Dans ce contexte, et conformément aux consignes du projet (deux classifieurs supervisés), nous retenons deux approches **complémentaires** :

1. **Régression logistique avec régularisation Elastic Net** (Zou et Hastie 2005) :
 - **Pourquoi ce choix ?** Ce modèle est adapté à nos données car il gère naturellement les variables binaires et numériques. La régularisation Elastic Net combine les pénalités L1 (Lasso, qui met à zéro les coefficients des variables non pertinentes → sélection automatique de variables) et L2 (Ridge, qui stabilise les coefficients en cas de corrélations entre variables). C'est un modèle **interprétable** : chaque coefficient indique la direction et l'amplitude de l'effet d'une variable sur la satisfaction.
 - **Rôle** : servir de *baseline*⁴ interprétable.
2. **Forêt aléatoire** (Breiman 2001) :
 - **Pourquoi ce choix ?** Contrairement à la régression logistique, la forêt aléatoire peut capturer des **interactions non-linéaires** entre variables. Par exemple, un accord « boisé » combiné à une note de tête « agrume » pourrait avoir un effet sur la satisfaction que la régression logistique ne peut pas modéliser. De plus, Kumar et al. (2015) obtiennent des AUC > 0.7 avec un random forest sur des descripteurs olfactifs similaires aux nôtres.

3. Imputer : remplacer une valeur manquante par une valeur estimée.

4. Baseline : modèle de référence, simple et interprétable, auquel on compare les modèles plus complexes.

— **Rôle** : explorer les interactions et fournir un classement d'importance des variables.

Métrique principale : l'**AUC**⁵ (capacité discriminante indépendante du seuil de décision), complétée par l'accuracy, la sensibilité, la spécificité et le score F1.

5. AUC (*Area Under the ROC Curve*) : aire sous la courbe ROC. Mesure la capacité du modèle à discriminer les deux classes indépendamment du seuil de décision. Un AUC de 0.5 = hasard, 1 = discrimination parfaite.

3 Partie 3 : Régression Logistique

3.1 Principe

i Définition

La régression logistique modélise la probabilité d'appartenance à une classe :

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}}$$

Nous utilisons une régularisation **Elastic Net** (`glmnet`) combinant pénalités L1 et L2 (Zou et Hastie 2005). Ce modèle est interprétable (coefficients), robuste (régularisation) et sert de baseline (Hastie, Tibshirani, et Friedman 2009).

3.2 Entraînement

Variables numériques centrées-réduites. Hyperparamètres **alpha** (mélange L1/L2) et **lambda** (force) optimisés par validation croisée 5-fold (métrique : AUC).

3.3 Résultats




FIGURE 3.1 : AUC selon alpha et lambda

TABLE 3.1 : Métriques (Régression Logistique)

Métrique	Valeur
alpha	1.000000

TABLE 3.1 : Métriques (Régression Logistique)

Métrique	Valeur
lambda	0.002154
AUC (CV)	0.668300
AUC (test)	0.669500
Accuracy	0.622600
Sensibilité	0.640100
Spécificité	0.604600
F1	0.632500




FIGURE 3.2 : Courbe ROC – Régression Logistique

La performance est modeste mais réelle, ce qui est attendu pour la prédiction d'une variable subjective comme la satisfaction à partir de caractéristiques olfactives.

4 Partie 4 : Forêt Aléatoire

4.1 Principe

i Définition

La forêt aléatoire est un ensemble de B arbres de décision entraînés sur des échantillons bootstrap. À chaque nœud, seul un sous-ensemble de m variables est considéré. Prédiction par **vote majoritaire** (Breiman 2001).

Avantages : capture des interactions non-linéaires entre familles olfactives, robustesse, classement d'importance des variables. Pas de prétraitement nécessaire. Ce choix est validé par Kumar et al. (2015) qui obtiennent des AUC > 0.7 avec un random forest pour la prédiction de qualités perceptuelles olfactives à partir de descripteurs similaires aux nôtres.

4.2 Entraînement

Hyperparamètre **mtry** optimisé par validation croisée 5-fold (métrique : AUC). 500 arbres.

4.3 Résultats




FIGURE 4.1 : Performance selon mtry

Top 15 variables




FIGURE 4.2 : Importance des variables (Top 15)

TABLE 4.1 : Métriques (Forêt Aléatoire)

Métrique	Valeur
mtry	3.0000
AUC (CV)	0.6904
AUC (test)	0.6934
Accuracy	0.6424
Sensibilité	0.6810
Spécificité	0.6026
F1	0.6590

Courbe ROC – Forêt Aléatoire




FIGURE 4.3 : Courbe ROC – Forêt Aléatoire

Le classement d'importance confirme le rôle prédictif des familles olfactives et du nombre d'évaluations. La forêt aléatoire exploite les interactions non-linéaires pour améliorer la discrimination.

5 Partie 5 : Comparaison et Conclusion

5.1 Comparaison des classifieurs

TABLE 5.1 : Comparaison des performances

Modèle	AUC_CV	AUC_Test	Accuracy	F1
Rég. Logistique	0.6683	0.6695	0.6226	0.6325
Forêt Aléatoire	0.6904	0.6934	0.6424	0.6590




FIGURE 5.1 : Courbes ROC comparées et distribution des AUC (5-fold CV)




FIGURE 5.2 : Courbes ROC comparées et distribution des AUC (5-fold CV)

L'écart entre AUC CV et test indique la généralisation. Un modèle dont la courbe ROC enveloppe l'autre est uniformément meilleur.

5.1.1 Choix final

Modèle retenu : Forêt Aléatoire (AUC test = 0.6934 vs 0.6695).

La forêt aléatoire capture les interactions non-linéaires entre familles olfactives.

Critère	Rég. Logistique	Forêt Aléatoire
Interprétabilité	Coefficients lisibles	Importance uniquement
Non-linéarité	Non	Oui
Temps d'entraînement	Rapide	Plus lent
Surapprentissage	Régularisation	Bagging + mtry

5.2 Regard critique

5.2.1 Limites

- **Variable cible construite** : le seuil (médiane) est arbitraire. Un autre seuil produirait des classes déséquilibrées.
- **Perte d'information** : le regroupement par familles traite “rose” et “iris” (tous deux “floral”) de la même façon. Néanmoins, Kumar et al. (2015) montrent que les descripteurs olfactifs forment naturellement des communautés perceptuelles via un réseau de co-occurrence, ce qui soutient la validité de ce regroupement.
- **Accords tronqués** : seulement 5 accords sur 10+ disponibles dans les données brutes.
- **Marque absente** : forte influence probable, mais cardinalité trop élevée pour un encodage simple.

5.2.2 Ce qui conforte notre approche

- Les communautés détectées par Kumar et al. (2015) (Fig. 3) correspondent à nos familles : les *hubs* « fruit », « floral », « wood », « sweet », « green » dominant dans 6 bases de données indépendantes.
- Les auteurs obtiennent des $AUC > 0.7$ avec un random forest sur des descripteurs perceptuels, ce qui est cohérent avec nos résultats.
- Le réseau olfactif est **disassortatif** (les descripteurs larges se connectent aux spécifiques), ce qui justifie de regrouper les accords spécifiques en familles larges.

5.2.3 Pistes d'amélioration

- Pondération par rang d'accord (1er = plus dominant)
- Target encoding de la marque par segment (luxe, niche, mass-market)
- Autres classifieurs : SVM, XGBoost, KNN
- Text mining : TF-IDF sur les descriptions textuelles
- Approche par réseau de co-occurrence des notes, comme proposé par Kumar et al. (2015), pour capturer les relations entre descripteurs

5.3 Utilisation de l'IA

[À compléter]

5.4 Contributions individuelles

[À compléter]

Références

- Breiman, Leo. 2001. « Random Forests ». *Machine Learning* 45 (1) : 5-32.
- Hastie, Trevor, Robert Tibshirani, et Jerome Friedman. 2009. *The Elements of Statistical Learning*. Springer.
- Kumar, Ritesh, Rishemjit Kaur, Benjamin Auffarth, et Amol P. Bhondekar. 2015. « Understanding the Odour Spaces : A Step towards Solving Olfactory Stimulus-Percept Problem ». *PLoS ONE* 10 (10) : e0141263. <https://doi.org/10.1371/journal.pone.0141263>.
- Zou, Hui, et Trevor Hastie. 2005. « Regularization and Variable Selection via the Elastic Net ». *Journal of the Royal Statistical Society : Series B* 67 (2) : 301-20.