



---

# Prédiction de la Satisfaction Client pour les Parfums

---

*Compléments de Mathématiques 2 – Introduction au Machine Learning*

L3 MIASHS – Université Grenoble Alpes

HAMLIL Mohamed    PARDO TERAN German  
EL KORAICHI Mohamed Yassine    ANZID Keltoum

9 avril 2026

# Prédiction de la Satisfaction Client pour les Parfums

## Compléments de Mathématiques 2 – Introduction au Machine Learning

HAMLIL Mohamed      PARDO TERAN German  
EL KORAICHI Mohamed Yassine      ANZID Keltoum

9 avril 2026

### Table des matières

|                                                                |           |
|----------------------------------------------------------------|-----------|
| <b>Introduction</b>                                            | <b>2</b>  |
| Contexte : le monde de la parfumerie . . . . .                 | 2         |
| Problématique . . . . .                                        | 2         |
| Plan du rapport . . . . .                                      | 3         |
| <b>1 Partie 1 : Données et Analyse Exploratoire</b>            | <b>3</b>  |
| <b>2 Données</b>                                               | <b>3</b>  |
| 2.1 Présentation du jeu de données . . . . .                   | 3         |
| 2.2 Chargement des données . . . . .                           | 3         |
| 2.3 Valeurs manquantes . . . . .                               | 4         |
| <b>3 Analyse Exploratoire</b>                                  | <b>4</b>  |
| 3.1 Construction de la variable cible . . . . .                | 4         |
| 3.2 Distribution des variables numériques . . . . .            | 4         |
| 3.3 Distribution par année . . . . .                           | 5         |
| 3.4 Variables catégoriques . . . . .                           | 6         |
| 3.5 Accords et notes olfactives . . . . .                      | 6         |
| 3.6 Analyse bivariée : satisfaction et prédicteurs . . . . .   | 7         |
| 3.7 Matrice de corrélation . . . . .                           | 8         |
| <b>4 Partie 2 : Feature Engineering et Préparation</b>         | <b>8</b>  |
| <b>5 Feature Engineering</b>                                   | <b>8</b>  |
| 5.1 Mapping des accords vers les familles olfactives . . . . . | 8         |
| 5.2 Satisfaction par famille olfactive . . . . .               | 9         |
| 5.3 Encodage du genre . . . . .                                | 9         |
| 5.4 Partition entraînement / test . . . . .                    | 9         |
| <b>6 Partie 3 : Régression Logistique LASSO</b>                | <b>10</b> |
| <b>7 Régression Logistique Régularisée (Elastic Net)</b>       | <b>10</b> |
| 7.1 Principe du modèle . . . . .                               | 10        |
| 7.2 Entraînement . . . . .                                     | 10        |
| <b>8 Partie 4 : Arbre de Décision</b>                          | <b>13</b> |
| <b>9 Arbre de Décision</b>                                     | <b>13</b> |
| 9.1 Principe . . . . .                                         | 13        |

|                                                        |           |
|--------------------------------------------------------|-----------|
| 9.2 Entraînement et élagage . . . . .                  | 13        |
| <b>10 Partie 5 : Forêt Aléatoire</b>                   | <b>14</b> |
| <b>11 Forêt Aléatoire</b>                              | <b>14</b> |
| 11.1 Principe . . . . .                                | 14        |
| 11.2 Entraînement . . . . .                            | 14        |
| <b>12 Partie 6 : k Plus Proches Voisins (kNN)</b>      | <b>16</b> |
| <b>13 k Plus Proches Voisins (kNN)</b>                 | <b>16</b> |
| 13.1 Principe . . . . .                                | 16        |
| 13.2 Entraînement et tuning . . . . .                  | 16        |
| <b>14 Partie 7 : Comparaison, Pistes et Conclusion</b> | <b>17</b> |
| <b>15 Comparaison des quatre modèles</b>               | <b>17</b> |
| 15.1 Récapitulatif des performances . . . . .          | 17        |
| 15.2 Courbes ROC comparées . . . . .                   | 18        |
| 15.3 Analyse comparative . . . . .                     | 18        |
| <b>16 Pistes non explorées</b>                         | <b>18</b> |
| 16.1 Naive Bayes . . . . .                             | 19        |
| 16.2 Clustering K-means . . . . .                      | 20        |
| <b>17 Regard critique et limites</b>                   | <b>21</b> |
| <b>18 Synthèse et conclusion</b>                       | <b>21</b> |
| 18.1 Retour sur la problématique . . . . .             | 21        |
| 18.2 Bilan des méthodes . . . . .                      | 22        |
| 18.3 Ouverture et perspectives . . . . .               | 22        |
| <b>19 Utilisation de l'IA</b>                          | <b>22</b> |
| 19.1 Contributions individuelles . . . . .             | 22        |
| <b>Références</b>                                      | <b>23</b> |

## Introduction

Ce projet s'inscrit dans le cadre du cours de **Compléments de Mathématiques 2 — Introduction au Machine Learning** (L3 MIASHS, Université Grenoble Alpes).

### i Résumé

Ce projet vise à prédire la satisfaction des consommateurs vis-à-vis des parfums à partir de leurs caractéristiques olfactives. À partir du jeu de données *Fragrantica* (~24 000 parfums, 14 variables), nous construisons une variable cible binaire (satisfaction *Oui/Non*) en seuillant la note moyenne à la médiane (3.97). Après une analyse exploratoire approfondie et un *feature engineering* basé sur 10 familles olfactives, nous entraînons quatre classifieurs — la régression logistique régularisée (Elastic Net/LASSO), l'arbre de décision élagué, la forêt aléatoire et le k plus proches voisins (kNN) — évalués par AUC sur validation croisée 5-fold. La forêt aléatoire obtient les meilleures performances (AUC test 0.69), suivie de la régression logistique (0.67), de l'arbre de décision et du kNN (0.65). Nous explorons également le Naive Bayes et le clustering K-means comme pistes complémentaires. Les résultats restent modestes, illustrant la difficulté de prédire une variable subjective à partir de descripteurs olfactifs seuls.

## Contexte : le monde de la parfumerie

L'industrie de la parfumerie représente un marché mondial de plus de **50 milliards de dollars**. Avant d'entrer dans l'analyse statistique, il est essentiel de comprendre le **vocabulaire du domaine**, car la parfumerie possède sa propre terminologie :

- **Note olfactive** : un ingrédient individuel perçu dans un parfum (ex. : bergamote, jasmin, musc). Chaque parfum est composé de dizaines de notes.
- **Pyramide olfactive** : structure en trois niveaux décrivant l'évolution temporelle d'un parfum :
  - *Notes de tête* (Top) : premières perçues, volatiles, disparaissent en 15–30 min (agrumes, herbes fraîches).
  - *Notes de cœur* (Middle) : le « caractère » du parfum, perceptibles pendant 2–4 h (floraux, épices).
  - *Notes de fond* (Base) : les plus persistantes, durent 6–24 h (bois, musc, vanille).
- **Accord** : combinaison de plusieurs notes créant une impression olfactive cohérente (ex. : un accord « fruité » mêle bergamote, pêche et cassis). Un parfum possède typiquement 3 à 5 accords principaux.
- **Famille olfactive** : grande catégorie regroupant des accords similaires (ex. : florale, boisée, orientale). La classification en familles est standardisée par la Société Française des Parfumeurs.

La France occupe une place centrale dans cette industrie, avec **Grasse** (Alpes-Maritimes) comme capitale historique du parfum depuis le XVII<sup>e</sup> siècle, et des maisons comme Chanel, Dior, Guerlain et Hermès.

## Problématique

Avec l'essor des plateformes communautaires en ligne comme **Fragrantica** — le plus grand site mondial dédié à la parfumerie, rassemblant des millions d'avis d'utilisateurs —, il devient possible d'analyser les préférences olfactives à grande échelle. Notre objectif est de répondre à la question :

**Peut-on prédire la satisfaction des consommateurs vis-à-vis d'un parfum à partir de ses caractéristiques olfactives ?**

Plus précisément, nous souhaitons :

1. Exploiter les variables de familles olfactives comme prédicteurs.
2. Comparer quatre approches supervisées : régression logistique régularisée, arbre de décision, forêt aléatoire et k plus proches voisins.
3. Évaluer honnêtement la performance de généralisation par validation croisée.
4. Explorer des pistes complémentaires (Naive Bayes, clustering K-means) et justifier leur non-rétention.

Le jeu de données est librement téléchargeable sur Kaggle (Fragrantica Fragrance Dataset).

## Plan du rapport

1. **Données et analyse exploratoire** : présentation du dataset, valeurs manquantes, distributions univariées et bivariées.
2. **Feature engineering et préparation** : regroupement des accords en 10 familles olfactives, encodage, partition stratifiée train/test.
3. **Régression logistique LASSO et arbre de décision** : modèles linéaire régularisé et arbre élagué.
4. **Forêt aléatoire et k plus proches voisins** : modèles non-linéaires (ensemble et instance-based).
5. **Comparaison, pistes et conclusion** : courbes ROC comparées, Naive Bayes, clustering K-means, regard critique et perspectives.

## 1 Partie 1 : Données et Analyse Exploratoire

### 2 Données

#### 2.1 Présentation du jeu de données

Le jeu de données Fragrantica contient les informations suivantes pour chaque parfum :

TABLE 1 : Description des variables du dataset Fragrantica

| Variable     | Type      | Description                                       |
|--------------|-----------|---------------------------------------------------|
| Rating_Value | Numérique | Note moyenne attribuée par les utilisateurs (1–5) |

| Variable            | Type         | Description                               |
|---------------------|--------------|-------------------------------------------|
| Rating_Count        | Numérique    | Nombre d'évaluations reçues               |
| Year                | Numérique    | Année de sortie du parfum                 |
| Gender              | Catégorielle | Genre cible (men, women, unisex)          |
| Country             | Catégorielle | Pays d'origine de la marque               |
| Top / Middle / Base | Texte        | Notes olfactives par phase de la pyramide |
| mainaccord1-5       | Texte        | Les 5 accords principaux du parfum        |

## 2.2 Chargement des données

Dimensions : 24063 lignes, 18 colonnes

Les données brutes comprennent 24063 parfums et 18 variables. Nous excluons **Name**, **Brand**, **url**, **Perfumer1** et **Perfumer2** car ce sont des identifiants à cardinalité trop élevée pour être directement intégrés dans un modèle de classification.

## 2.3 Valeurs manquantes




FIGURE 1 : Pourcentage de valeurs manquantes par variable

**Perfumer2** est absent dans plus de 80 % des cas et sera exclu. **Year** manque dans environ 8 % des cas — ces valeurs seront imputées par la médiane. Les accords secondaires (**mainaccord3–5**) présentent 5–15 % de valeurs manquantes, ce qui est attendu car tous les parfums n'ont pas 5 accords. La variable **Rating\_Value** est quasi-complète, permettant la construction fiable de la variable cible.

## 3 Analyse Exploratoire

### 3.1 Construction de la variable cible

La variable **Rating\_Value** (continue, 1–5) est transformée en variable binaire **Satisfaction** en utilisant la **médiane** comme seuil. Ce choix pragmatique maximise l'équilibre des classes et évite les problèmes liés au déséquilibre. Un seuil fixe (ex. 4.0) produirait des classes déséquilibrées.




FIGURE 2 : Distribution de la variable Satisfaction


La médiane (3.97) produit une répartition quasi-équilibrée (**50.7 % Oui**), favorable pour l'apprentissage statistique. Notons que ce seuil mesure une satisfaction *relative* (par rapport aux autres parfums) et non absolue.

### 3.2 Distribution des variables numériques

Le jeu de données contient deux variables numériques clés qu'il ne faut pas confondre :

- **Rating\_Value** : la **note moyenne** attribuée au parfum par les utilisateurs (échelle 1–5). C'est une mesure de *qualité perçue*. Sa distribution est quasi-symétrique (pas besoin de transformation).
- **Rating\_Count** : le **nombre total d'évaluations** reçues par le parfum. C'est une mesure de *popularité*. Sa distribution est très asymétrique à droite (quelques parfums vedettes cumulent des milliers d'avis, la majorité en a peu), d'où l'application d'une **transformation logarithmique**  $\log(1 + x)$  pour réduire cette asymétrie.

**Rating\_Value** sert à construire la variable cible (Satisfaction) et est donc **exclue des prédicteurs**. **Rating\_Count** est conservé comme prédicteur car il mesure la popularité, pas la satisfaction elle-même.

FIGURE 3 : Distribution de Rating\_Value et  $\log(1 + \text{Rating\_Count})$ 

Les notes (**Rating\_Value**) sont concentrées autour de 3.5–4.0, avec une légère asymétrie gauche. La popularité brute est extrêmement asymétrique : la majorité des parfums ont moins de 50 évaluations, tandis que quelques parfums iconiques (*Sauvage* de Dior, *Bleu de Chanel*) en cumulent des milliers. Après transformation logarithmique, la distribution devient quasi-normale.

### 3.3 Distribution par année




FIGURE 4 : Nombre de parfums par année de sortie

On observe une croissance exponentielle des sorties à partir des années 2000, liée à la démocratisation de la parfumerie et à la multiplication des marques de niche. Les parfums anciens (avant 1990) sont sous-représentés, ce qui introduit un **effet de survivance** : seuls les parfums ayant survécu commercialement restent référencés sur Fragrantica, et ces parfums « survivants » sont généralement mieux notés.

### 3.4 Variables catégoriques




FIGURE 5 : Distribution par genre et par pays d'origine

Les parfums pour femmes et unisex dominant le dataset. La **France** arrive en tête (~30 %), ce qui s'explique par son héritage historique : Grasse (Alpes-Maritimes) est le berceau mondial de la parfumerie depuis le XVII<sup>e</sup> siècle. Les **États-Unis** (~19 %) reflètent le dynamisme des marques designer et celebrity, tandis que l'**Italie** (~14 %) s'appuie sur sa tradition de la mode de luxe (Versace, Dolce & Gabbana, Acqua di Parma). Les pays représentant moins de 5 % seront regroupés en « Other ».

### 3.5 Accords et notes olfactives




FIGURE 6 : Accords olfactifs les plus fréquents

Les accords **woody** (boisé), **citrus** (agrumes) et **aromatic** (aromatique) dominent, suivis de sweet et fruity. Cette répartition reflète les tendances actuelles du marché. Les 84 accords distincts seront regroupés en 10 familles olfactives au chapitre suivant.




FIGURE 7 : Notes olfactives les plus fréquentes par phase

La répartition des notes confirme la **pyramide olfactive** classique : les notes de **tête** sont dominées par les agrumes volatils (bergamote, citron, poivre rose), les notes de **cœur** par les floraux (jasmin, rose, iris), et les notes de **fond** par les ingrédients tenaces (musc, santal, cèdre, vanille).



### 3.6 Analyse bivariable : satisfaction et prédicteurs




FIGURE 8 : Variables numériques selon la satisfaction

Les parfums satisfaisants ont significativement plus d'évaluations (**biais de popularité**) : sur Fragrantica, les utilisateurs évaluent préférentiellement les parfums qu'ils apprécient, créant un cercle vertueux popularité → bonnes notes. Les parfums satisfaisants sont aussi légèrement plus anciens (**effet de survivance**) : les mauvais parfums anciens ont été retirés du marché et ne sont plus référencés.




FIGURE 9 : Taux de satisfaction par genre et par pays

Le genre est peu discriminant. Par pays, certaines origines (souvent des maisons de niche à production artisanale, comme les parfumeurs des Émirats spécialisés dans le oud) affichent des taux de satisfaction plus élevés, probablement car leurs parfums ciblent un public passionné et averti.

### 3.7 Matrice de corrélation




FIGURE 10 : Matrice de corrélation des variables numériques

Les corrélations entre les variables numériques sont très faibles (toutes inférieures à 0.15), indiquant l'absence de multicolinéarité problématique : chaque variable (année, popularité, note) apporte une information distincte au modèle.

## 4 Partie 2 : Feature Engineering et Préparation

### 5 Feature Engineering

#### 5.1 Mapping des accords vers les familles olfactives

Plutôt que d'utiliser les 84 accords individuels (trop nombreux et bruités), nous les regroupons en **10 familles olfactives** standardisées, inspirées de la classification de la Société Française des Parfumeurs (Ellena, 2007). Voici un extrait du dictionnaire de correspondance :

TABLE 2 : Mapping des accords vers les 10 familles olfactives

| Famille         | Accords regroupés (exemples)               |
|-----------------|--------------------------------------------|
| <b>Fruity</b>   | fruity, citrus, tropical                   |
| <b>Floral</b>   | floral, rose, white floral, yellow floral  |
| <b>Woody</b>    | woody, earthy, mossy                       |
| <b>Sweet</b>    | sweet, vanilla, caramel, powdery, gourmand |
| <b>Oriental</b> | oriental, amber, balsamic, warm, musky     |
| <b>Fresh</b>    | fresh, aquatic, ozonic, marine, clean      |
| <b>Spicy</b>    | spicy, warm spicy, cinnamon                |
| <b>Herbal</b>   | herbal, aromatic, green, lavender          |
| <b>Leather</b>  | leather, animalic                          |
| <b>Smoky</b>    | smoky, tobacco                             |

Par exemple, un parfum dont les accords sont « *citrus, floral, vanilla, woody, amber* » sera classé dans les familles **fruity** (via citrus), **floral**, **sweet** (via vanilla), **woody** et **oriental** (via amber) — soit 5 familles simultanément. Cette approche réduit la dimensionnalité tout en conservant le sens olfactif.

TABLE 3 : Distribution des familles olfactives (accords)

| Famille  | Parfums | %    |
|----------|---------|------|
| fruity   | 14252   | 59.2 |
| sweet    | 13331   | 55.4 |
| woody    | 12803   | 53.2 |
| floral   | 11760   | 48.9 |
| herbal   | 9469    | 39.4 |
| oriental | 8497    | 35.3 |
| spicy    | 6120    | 25.4 |
| fresh    | 4495    | 18.7 |
| leather  | 1703    | 7.1  |
| smoky    | 861     | 3.6  |

Les pourcentages totalisent plus de 100 % car un parfum peut appartenir à plusieurs familles (il possède jusqu'à 5 accords). Les familles **fruity**, **woody** et **sweet** dominent, reflétant la tendance actuelle du marché vers les parfums fruités-boisés et gourmands.

## 5.2 Satisfaction par famille olfactive




FIGURE 11 : Taux de satisfaction par famille olfactive

Les écarts de satisfaction entre familles sont modestes (~47 % à ~54 %), la ligne rouge pointillée indiquant la moyenne globale. Les familles *smoky*, *spicy* et *leather* affichent les taux les plus élevés — ces familles plus niches attirent un public passionné et averti. À l'inverse, *fresh*, *floral* et *fruity* sont légèrement en dessous : ces familles très répandues englobent un grand nombre de parfums de qualité variable, ce qui tire leur taux moyen vers le bas. Ces différences, bien que faibles, seront exploitées par les modèles.

## 5.3 Encodage du genre

### 5.4 Partition entraînement / test

Le split 70/30 est un compromis standard : 70 % des données suffisent pour entraîner les modèles avec CV interne, et 30 % assurent une évaluation fiable. **Toutes les transformations impliquant des statistiques apprises** (top-10 des notes, seuil de regroupement des pays, imputation médiane) sont réalisées **après le split**, ajustées **uniquement sur le jeu d'entraînement**, afin d'éviter toute fuite d'information du test vers le train.

TABLE 4 : Pays après regroupement (seuil 5 %, calculé sur train)

| Pays   | Effectif | %    |
|--------|----------|------|
| France | 5093     | 30.2 |
| USA    | 3165     | 18.8 |
| Other  | 2414     | 14.3 |
| Italy  | 2314     | 13.7 |
| UK     | 1190     | 7.1  |
| Brazil | 919      | 5.5  |
| Spain  | 907      | 5.4  |
| UAE    | 843      | 5.0  |

TABLE 5 : Répartition entraînement / test (stratifié)

| Ensemble     | Observations | Variables | Prop. Oui |
|--------------|--------------|-----------|-----------|
| Entraînement | 16845        | 53        | 0.507     |
| Test         | 7218         | 53        | 0.507     |

Le pipeline produit 53 variables explicatives. La stratification assure que la proportion de parfums satisfaisants est identique dans les deux ensembles, garantissant une évaluation non biaisée.

## 6 Partie 3 : Régression Logistique LASSO

## 7 Régression Logistique Régularisée (Elastic Net)

### 7.1 Principe du modèle

#### i LASSO et Elastic Net

Le modèle LASSO minimise :

$$\mathcal{L}(\beta) = -\frac{1}{n} \sum_{i=1}^n \log P(y_i | x_i, \beta) + \lambda \|\beta\|_1$$

où  $\lambda$  est le paramètre de régularisation. La pénalité  $\ell_1$  force certains coefficients à exactement zéro, réalisant ainsi une **sélection de variables** automatique. Nous utilisons l'**Elastic Net** (Zou & Hastie, 2005) qui combine les pénalités  $\ell_1$  (sélection) et  $\ell_2$  (rétrécissement), contrôlées par le paramètre  $\alpha \in [0, 1]$ .

### 7.2 Entraînement

La grille d'hyperparamètres explore l'ensemble du spectre Elastic Net :  $\alpha \in \{0, 0.25, 0.5, 0.75, 1\}$  (de Ridge pur à LASSO pur) et 10 valeurs de  $\lambda \in [10^{-4}, 10^{-1}]$  en échelle logarithmique. La validation croisée 5-fold est un compromis classique entre biais et variance de l'estimation (Kohavi, 1995) : avec ~17 000 observations, chaque fold contient ~3 400 observations, assurant une estimation stable de l'AUC.

### 7.2.1 Sélection des hyperparamètres




FIGURE 12 : AUC en validation croisée selon alpha et lambda

Le meilleur modèle correspond à  $\alpha = 1$  et  $\lambda = 0.002154$ . Le fait que  $\alpha = 1$  soit optimal signifie que le modèle retenu est un **LASSO pur** : la sélection de variables (mise à zéro de coefficients non-informatifs) est plus bénéfique que le simple rétrécissement Ridge pour nos données à nombreuses variables binaires peu prédictives.

### 7.2.2 Performance sur le jeu test

TABLE 6 : Métriques de la régression logistique

| Metric      | Valeur   |
|-------------|----------|
| alpha       | 1.000000 |
| lambda      | 0.002154 |
| AUC (CV)    | 0.667000 |
| AUC (test)  | 0.669300 |
| Accuracy    | 0.625000 |
| Sensibilité | 0.635400 |
| Spécificité | 0.614200 |
| F1          | 0.632300 |

La proximité entre AUC CV et AUC test confirme l'absence de surapprentissage : le modèle généralise correctement.

### 7.2.3 Matrice de confusion




FIGURE 13 : Matrice de confusion — Régression logistique

Le classifieur est légèrement biaisé vers la classe positive. La **sensibilité** est supérieure à la **spécificité**, indiquant que le modèle détecte mieux les parfums satisfaisants que les non-satisfaisants.

### 7.2.4 Interprétation des coefficients




FIGURE 14 : Coefficients non-nuls de la régression logistique (LASSO)

Le LASSO retient **41 variables sur 53**, mettant les autres à zéro. **Rating\_Count** conserve un coefficient positif, confirmant le **biais de popularité** : à caractéristiques olfactives égales, un parfum avec plus d'évaluations a une probabilité plus élevée d'être satisfaisant. Les variables de pays et d'année présentent également des coefficients élevés, reflétant l'hétérogénéité géographique du marché et l'effet temporel. Parmi les familles olfactives, notamment **fam\_fruity** et **fam\_fresh** reçoivent des coefficients négatifs, indiquant qu'à popularité égale ces compositions sont associées à une moindre satisfaction — un résultat cohérent avec leurs taux observés dans l'analyse exploratoire.

**Bilan** — LASSO retenu, AUC test = 0.669, 41/53 variables actives. Baseline linéaire interprétable.

## 8 Partie 4 : Arbre de Décision

### 9 Arbre de Décision

#### 9.1 Principe

##### i Indice de Gini et élagage

L'arbre de décision partitionne récursivement l'espace des features en régions homogènes vis-à-vis de la variable cible. À chaque nœud, l'algorithme sélectionne la variable et le seuil qui maximisent la **pureté** des sous-groupes, mesurée par l'indice de Gini :

$$\text{Gini}(t) = 1 - \sum_c p_c^2$$

où  $p_c$  est la proportion de la classe  $c$  dans le nœud  $t$ . L'arbre est ensuite **élagué** (pruning) par validation croisée pour éviter le surapprentissage : on sélectionne le paramètre de complexité  $c_p$  qui minimise l'erreur CV.

#### 9.2 Entraînement et élagage

Arbre élagué (19 nœuds)




FIGURE 15 : Arbre de décision élagué — règles de classification interprétables

L'arbre élagué révèle des **règles de décision interprétables** : la variable de split au nœud racine est `gender_women`, et les niveaux suivants montrent comment le modèle combine les prédicteurs pour séparer les classes. Chaque feuille indique la classe prédite et la proportion de chaque classe, offrant une transparence totale — un avantage majeur sur les modèles « boîte noire ». L'arbre seul obtient une AUC de 0.649, inférieure à la forêt aléatoire (chapitre suivant), illustrant la **variance** des arbres individuels et justifiant le passage au bagging.

TABLE 7 : Métriques de l'arbre de décision élagué

|             | Metric      | Value  |
|-------------|-------------|--------|
|             | AUC (test)  | 0.6488 |
| Accuracy    | Accuracy    | 0.6146 |
| Sensitivity | Sensibilité | 0.5939 |
| Specificity | Spécificité | 0.6358 |
| F1          | F1          | 0.6099 |

**Bilan** — Arbre élagué retenu, AUC test = 0.649. Variance élevée → passage à la forêt au chapitre suivant.

## 10 Partie 5 : Forêt Aléatoire

### 11 Forêt Aléatoire

#### 11.1 Principe

##### i Bagging et décorrélation des arbres

La forêt aléatoire (Breiman, 2001) est un ensemble de 500 arbres de décision entraînés sur des échantillons bootstrap. À chaque nœud, seul un sous-ensemble de `mtry` variables est considéré, ce qui **décorrèle** les arbres. Contrairement au LASSO, la forêt aléatoire capture les **interactions non-linéaires** entre variables (ex. : un parfum *fruité ET récent ET populaire* peut avoir une satisfaction très différente de la somme des effets individuels). Par rapport à l'arbre unique du chapitre précédent, la forêt réduit la **variance** par moyennage de 500 arbres décorrélés, tout en conservant la capacité à capturer des interactions complexes.

#### 11.2 Entraînement

La grille optimise conjointement deux hyperparamètres par validation croisée 5-fold :

- `mtry` ∈ {3, 5, 7, 10, 15, 20} : centré autour de  $\sqrt{p} \approx 7$  (recommandation de Breiman).
- `min.node.size` ∈ {1, 5, 10} : taille minimale des feuilles. La valeur 1 (défaut de **ranger**) maximise la flexibilité, tandis que des valeurs plus élevées (5, 10) régularisent en empêchant les feuilles trop spécifiques.

##### 11.2.1 Sélection de mtry




FIGURE 16 : AUC en validation croisée selon mtry

L'optimum est atteint pour `mtry` = 5 et `min.node.size` = 10. L'AUC décroît avec des valeurs élevées de `mtry` : considérer trop de variables à chaque nœud ajoute du bruit, car la majorité de nos 53 prédicteurs sont peu informatifs. La décorrélation maximale des arbres (faible `mtry`) est plus bénéfique.

##### 11.2.2 Performance sur le jeu test

TABLE 8 : Métriques de la forêt aléatoire

| Métrique                   | Valeur  |
|----------------------------|---------|
| <code>mtry</code>          | 5.0000  |
| <code>min.node.size</code> | 10.0000 |
| AUC (CV)                   | 0.6875  |
| AUC (test)                 | 0.6926  |
| Accuracy                   | 0.6333  |
| Sensibilité                | 0.6551  |



TABLE 8 : Métriques de la forêt aléatoire

| Metrique    | Valeur |
|-------------|--------|
| Spécificité | 0.6108 |
| F1          | 0.6445 |

La forêt aléatoire surpasse le LASSO sur l'AUC test. La proximité entre AUC CV et AUC test confirme la bonne généralisation du modèle — le bagging agit comme un régulateur naturel du surapprentissage.

### 11.2.3 Matrice de confusion




FIGURE 17 : Matrice de confusion — Forêt aléatoire

### 11.2.4 Importance des variables




FIGURE 18 : Importance des variables (Top 15)

**Rating\_Count** et **Year** dominent massivement l'importance, suivis des familles olfactives. Cette hiérarchie est cohérente avec les résultats du LASSO et de l'arbre de décision, qui attribuent également un rôle central à la

popularité et à l'ancienneté. Ce résultat soulève une question fondamentale : **le modèle prédit-il la satisfaction olfactive, ou capture-t-il un effet de popularité ?** Les deux sont mêlés dans les données communautaires, et nos modèles ne peuvent pas les distinguer.

**Bilan** — Forêt aléatoire = **meilleur modèle**, AUC test = 0.693, mtry = 5, 500 arbres. Bagging > arbre seul grâce aux interactions non-linéaires.

## 12 Partie 6 : k Plus Proches Voisins (kNN)

### 13 k Plus Proches Voisins (kNN)

#### 13.1 Principe

##### **i** Classifieur paresseux par voisinage

Le kNN (Cover & Hart, 1967) est un classificateur **non-paramétrique** et **paresseux** (*lazy learner*) : il ne construit pas de modèle explicite, mais classe chaque nouvelle observation selon le **vote majoritaire** de ses  $k$  voisins les plus proches dans l'espace des features. La distance euclidienne est utilisée après standardisation.

**Avantages théoriques** : aucune hypothèse sur la distribution des données, capture les frontières de décision non-linéaires complexes.

##### **!** Malédiction de la dimensionnalité (Séance 5)

Avec 53 features dont la majorité sont binaires (0/1), les distances euclidiennes deviennent peu discriminantes en haute dimension : toutes les paires d'observations tendent vers une distance similaire et la notion de « voisin proche » perd son sens. C'est la **malédiction de la dimensionnalité** étudiée en Séance 5. Nous vérifions empiriquement ce phénomène théorique au cours du tuning.

#### 13.2 Entraînement et tuning

Nous testons 8 valeurs de  $k \in \{3, 5, 7, 11, 15, 21, 31, 51\}$ , couvrant les voisinages locaux ( $k=3$ , risque de surapprentissage) aux voisinages globaux ( $k=51$ , lissage maximal). La standardisation (centrage + réduction) est appliquée pour que les distances ne soient pas dominées par `Rating_Count` (échelle ~0–10 000) par rapport aux variables binaires (0/1).

##### 13.2.1 Sélection de k




FIGURE 19 : AUC en validation croisée selon k — comparaison avec LR et RF

L'AUC augmente **monotoniquement** avec  $k$ , passant de 0.592 ( $k=3$ ) à 0.652 ( $k=51$ ). Cette tendance est révélatrice : le modèle bénéficie systématiquement du lissage, ce qui indique que le **signal local est noyé dans le bruit dimensionnel**. Même au meilleur  $k=51$ , le kNN reste en-dessous des deux lignes de référence (logistique et forêt aléatoire).

### 13.2.2 Performance sur le jeu test

TABLE 9 : Métriques finales du kNN

| Metric      | Valeur  |
|-------------|---------|
| Meilleur k  | 51.0000 |
| AUC (CV)    | 0.6520  |
| AUC (test)  | 0.6541  |
| Accuracy    | 0.6114  |
| Sensibilité | 0.5871  |
| Spécificité | 0.6364  |
| F1          | 0.6052  |

### 13.2.3 Matrice de confusion




FIGURE 20 : Matrice de confusion — kNN

### 13.2.4 Diagnostic : la malédiction de la dimensionnalité

Le fait que  $k=51$  soit optimal (le plus grand testé) est révélateur : avec 53 dimensions dont ~50 binaires, les distances euclidiennes se concentrent autour de leur moyenne et les observations deviennent quasiment **équidistantes**. Le kNN perd sa capacité discriminante car la notion de « voisinage local » n'a plus de sens en haute dimension. C'est un cas d'école de la **malédiction de la dimensionnalité** étudiée en **Séance 5** : le kNN a besoin d'un voisinage très large pour moyenner le bruit, ce qui revient à une classification quasi-globale — perdant l'avantage principal de la méthode.

**Bilan** — kNN retenu pour illustration pédagogique, AUC test = 0.654 ( $k = 51$ ). Démonstre empiriquement la malédiction de la dimensionnalité.

## 14 Partie 7 : Comparaison, Pistes et Conclusion

### 15 Comparaison des quatre modèles

#### 15.1 Récapitulatif des performances

TABLE 10 : Comparaison des quatre modèles supervisés

| Modele                  | AUC_Test | Accuracy | Sensibilite | Specificite | F1     |
|-------------------------|----------|----------|-------------|-------------|--------|
| Rég. Logistique (LASSO) | 0.6693   | 0.6250   | 0.6354      | 0.6142      | 0.6323 |
| Arbre de Décision       | 0.6488   | 0.6146   | 0.5939      | 0.6358      | 0.6099 |
| Forêt Aléatoire         | 0.6926   | 0.6333   | 0.6551      | 0.6108      | 0.6445 |
| kNN (k=51)              | 0.6541   | 0.6114   | 0.5871      | 0.6364      | 0.6052 |

La hiérarchie des performances est claire : **Forêt Aléatoire** > **Régression Logistique** > **kNN** > **Arbre de Décision**. L'écart entre la forêt aléatoire et le kNN (3.9 points d'AUC) est substantiel. Le gain de la forêt par rapport à l'arbre seul (4.4 points) illustre concrètement l'avantage du bagging.

## 15.2 Courbes ROC comparées

### Courbes ROC comparées




FIGURE 21 : Courbes ROC comparées — quatre modèles supervisés

Les quatre courbes ROC (Figure 21) s'écartent de la diagonale (hasard pur), confirmant une discrimination réelle. La forêt aléatoire domine sur toute la plage de seuils. La comparaison arbre/forêt est particulièrement instructive : la courbe de l'arbre seul (pointillée) est plus irrégulière et systématiquement en-dessous de la forêt, illustrant le gain du bagging. L'AUC la plus élevée (forêt aléatoire, 0.693) signifie que le modèle classe correctement une paire aléatoire (satisfaisant, non-satisfaisant) dans **69 % des cas** (Fawcett, 2006) — modérément supérieur au hasard (50 %), mais significatif sur 7218 observations test.

## 15.3 Analyse comparative

Pourquoi la forêt aléatoire domine-t-elle ? Trois raisons : (1) elle capture les **interactions non-linéaires** entre variables sans les modéliser explicitement ; (2) le **bagging** et la restriction de `mtry` décorrèlent les arbres, offrant une régularisation naturelle absente du kNN ; (3) elle sélectionne implicitement les variables pertinentes à chaque nœud, contrairement au kNN qui utilise les 53 dimensions indistinctement. Le gain arbre → forêt (4.4 points d'AUC) illustre concrètement l'avantage du moyennage de 500 arbres décorrélés sur un arbre unique instable.

Le kNN échoue en raison de la **malédiction de la dimensionnalité** : avec ~50 features binaires, les distances euclidiennes deviennent peu discriminantes et le kNN nécessite un  $k=51$  très large, perdant son avantage de classificateur local.

## 16 Pistes non explorées

Au-delà des quatre modèles supervisés retenus, nous avons exploré deux pistes complémentaires que nous avons choisi de ne pas intégrer comme modèles principaux. Cette section justifie ces choix.

### 16.1 Naive Bayes

Le classificateur Naive Bayes applique le théorème de Bayes avec l'hypothèse d'**indépendance conditionnelle** entre les features :

$$P(Y = c \mid X_1, \dots, X_p) \propto P(Y = c) \prod_{j=1}^p P(X_j \mid Y = c)$$

TABLE 11 : Métriques du Naive Bayes — modèle non retenu

| Métrique    | Valeur |
|-------------|--------|
| AUC (CV)    | 0.6481 |
| AUC (test)  | 0.6464 |
| Accuracy    | 0.5540 |
| Sensibilité | 0.2002 |
| Spécificité | 0.9184 |

Raisons de la non-rétention :

1. **AUC la plus faible** (0.646) : inférieure à tous les modèles retenus.
2. **Classificateur dégénéré** : la sensibilité extrêmement basse (0.2) indique que le modèle prédit presque tous les parfums comme « Non satisfaisants ». Cela le rend inutilisable en pratique — un classificateur qui répond toujours « Non » est trivial.
3. **Violation de l'hypothèse d'indépendance** : les familles olfactives sont corrélées entre elles, ce qui viole l'hypothèse fondamentale du Naive Bayes.

### Corrélations entre familles olfactives




FIGURE 22 : Corrélations entre familles olfactives — violation de l'hypothèse d'indépendance du Naive Bayes

Plusieurs paires de familles présentent des corrélations non négligeables : **herbal/sweet** ( $r \approx -0.44$ , la plus forte anti-corrélation — les compositions aromatiques excluent les accords gourmands), **floral/herbal** ( $r \approx -0.27$ ) et

**fruity/spicy** ( $r \approx -0.27$ ). Ces anti-corrélations traduisent la spécialisation des compositions : les familles ne sont pas indépendantes mais structurées par les conventions de la parfumerie. Ces dépendances violent l'hypothèse d'indépendance conditionnelle du Naive Bayes, dégradant l'estimation des probabilités jointes et expliquant la mauvaise performance du modèle.

16.2 Clustering K-means

En complément de l'approche supervisée, nous avons réalisé un clustering **non-supervisé** K-means sur les 10 familles olfactives, afin de découvrir d'éventuels profils-types de parfums.




FIGURE 23 : Méthode du coude — choix du nombre de clusters

La méthode du coude suggère **k=3** clusters : la réduction d'inertie chute fortement après k=3.




FIGURE 24 : Profils olfactifs des 3 clusters K-means

Trois profils-types émergent clairement :

TABLE 12 : Taux de satisfaction par profil olfactif

| Profil           | Effectif | Satisfaction (%) | Rating moyen |
|------------------|----------|------------------|--------------|
| Aromatique-Frais | 7937     | 51.2             | 3.96         |
| Boisé-Oriental   | 6006     | 62.0             | 4.03         |
| Floral-Gourmand  | 10120    | 43.7             | 3.92         |




FIGURE 25 : Taux de satisfaction par profil olfactif

- **Aromatique-Frais** (7937 parfums) : dominé par les familles herbal, fruity et woody. Ce profil correspond aux fougères masculines classiques (lavande, bergamote, cèdre). Satisfaction : 51.2 %.
- **Floral-Gourmand** (10120 parfums) : dominé par sweet, floral et fruity. Compositions féminines accessibles (rose, vanille, fruits rouges). Satisfaction : 43.7 % — le taux le plus bas.
- **Boisé-Oriental** (6006 parfums) : dominé par woody, oriental et sweet. Parfums de niche (oud, santal, ambre). Satisfaction : 62 % — le taux le plus élevé.

L'écart de satisfaction entre le profil Boisé-Oriental (62 %) et le Floral-Gourmand (43.7 %) est de **18.3 points**. Comment l'expliquer ? Les parfums boisés-orientaux (oud, santal, ambre) sont des parfums de **niche**, souvent plus chers et moins connus du grand public. Les personnes qui les achètent sont donc des **passionnés** qui savent ce qu'ils veulent — ils choisissent avec soin et notent généreusement les parfums qu'ils apprécient. À l'inverse, les parfums floraux-gourmands (rose, vanille, fruits rouges) sont les plus **grand public** : ils attirent un large éventail d'acheteurs, y compris des consommateurs occasionnels qui peuvent être déçus. Ce mélange d'avis enthousiastes et mitigés tire la moyenne vers le bas. C'est un **biais de sélection** classique : ce n'est pas que les parfums orientaux sont objectivement meilleurs, mais leur public est plus sélectif. Cet écart est statistiquement significatif (test du  $\chi^2$ ,  $p < 0.001$ ), mais la taille d'effet reste faible ( $V$  de Cramér  $\approx 0.15$ ), confirmant que le profil olfactif n'explique qu'une part modeste de la satisfaction. De plus, l'ajout du cluster comme variable dans la forêt aléatoire ne modifie pas l'AUC, ce qui signifie que les familles individuelles capturent déjà cette information.

## 17 Regard critique et limites

1. **Biais de sélection** : `Rating_Count` domine les prédicteurs dans les quatre modèles. Ce n'est pas le nombre d'avis qui *cause* la satisfaction, mais les parfums populaires attirent plus d'évaluateurs *et* ces évaluateurs notent préférentiellement les parfums qu'ils apprécient. Nos modèles capturent cette corrélation sans pouvoir établir de causalité.
2. **Multicolinéarité des familles** : les familles olfactives ne sont pas mutuellement exclusives (un parfum peut être à la fois « fruity » et « sweet »), ce qui peut biaiser l'estimation des coefficients LASSO. La forêt aléatoire et le kNN sont moins sensibles à ce problème.
3. **Validité externe** : les données *Fragrantica* représentent un public auto-sélectionné de passionnés en ligne, non représentatif de la population générale des consommateurs.
4. **Perte d'information** : la binarisation à la médiane perd le gradient de satisfaction (un parfum à 4.8 et un à 4.0 sont tous deux « Oui »).
5. **Malédiction de la dimensionnalité** : le kNN illustre concrètement comment les performances d'un classificateur basé sur les distances se dégradent en haute dimension ( $p = 53$ ), un phénomène théorique étudié en **Séance 5** que nous avons pu vérifier empiriquement.

## 18 Synthèse et conclusion

### 18.1 Retour sur la problématique

**Les caractéristiques olfactives permettent-elles de prédire la satisfaction ?** Partiellement. Les familles olfactives contribuent à la prédiction ( $AUC > 0.50$ ), mais l'AUC plafonne à  $\sim 0.69$ , dominée par les variables non-olfactives. Ce projet illustre les concepts clés du cours :

- La **validation croisée** (TP3) pour une estimation honnête de la performance.
- La **régularisation** (TP5) pour gérer un espace de 53 prédicteurs — le LASSO a éliminé les variables redondantes.
- La **comparaison de modèles** (TP6–7) : le gain de la forêt aléatoire est réel mais modéré.
- La **classification par voisinage** (TP5) : le kNN échoue en haute dimension, confirmant les mises en garde du cours.
- Le **regard critique** : nous avons testé et écarté le Naive Bayes (Séance 6), et exploré le clustering K-means (Séance 10) pour un éclairage complémentaire.
- Une performance modérée reflète la subjectivité de la variable cible, pas un échec méthodologique.

## 18.2 Bilan des méthodes

TABLE 13 : Bilan des méthodes explorées

| Méthode           | AUC test | Statut       | Justification                                                                                          |
|-------------------|----------|--------------|--------------------------------------------------------------------------------------------------------|
| Forêt Aléatoire   | 0.693    | Retenu       | Meilleure performance, interactions non-linéaires                                                      |
| Rég. Logistique   | 0.669    | Retenu       | Interprétable, sélection de variables                                                                  |
| Arbre de Décision | 0.649    | Retenu       | Interprétable, justifie le passage à la forêt                                                          |
| kNN (k=51)        | 0.654    | Retenu       | Illustration malédiction dimensionnalité                                                               |
| Naive Bayes       | 0.646    | Non retenu   | Hypothèse violée, classificateur dégénéré                                                              |
| K-means (k=3)     | —        | Exploratoire | 3 profils significatifs ( $\chi^2$ , $p < 0.001$ ), effet faible ( $V = 0.15$ ), pas de gain prédictif |

## 18.3 Ouverture et perspectives

Ce travail ouvre plusieurs pistes. L'**ingénierie de features** pourrait être enrichie par un encodage **TF-IDF** sur les notes individuelles (traitement analogue au NLP), pondérant chaque note par sa rareté plutôt que de regrouper en 10 familles binaires. L'ajout de la **concentration du parfum** (Eau de Toilette, Eau de Parfum, Extrait) comme variable prédictive serait particulièrement pertinent : la concentration influence directement la tenue, la projection et donc la satisfaction perçue, mais cette information est absente du dataset *Fragrantica*. Les **méthodes d'ensemble hybrides** (stacking) ou les réseaux de neurones pourraient exploiter des interactions complexes entre prédicteurs. Le clustering K-means suggère qu'un modèle entraîné **séparément par cluster** pourrait capturer des relations différentes selon le segment de marché. Enfin, une **régression ordinale** préserverait le gradient de satisfaction perdu par la binarisation.

## 19 Utilisation de l'IA

Nous avons utilisé Claude et GitHub Copilot pour :

1. **Debugging du code R** (~15 % du temps) : résolution d'erreurs de syntaxe et de compatibilité entre packages (ex. : l'IA avait suggéré `randomForest` au lieu de `ranger`, corrigé après des temps d'exécution 10× supérieurs).
2. **Mise en forme du rapport** (~10 %) : aide à la structuration LaTeX (gestion des marges via `geometry`, espacement avec `setstretch` et `parskip`, placement des figures avec `float` et `\floatplacement{figure}{H}`, table des matières automatique).

Toutes les sorties ont été systématiquement vérifiées. L'analyse des données, le choix des hyperparamètres, l'interprétation des résultats et le regard critique sont entièrement le fruit de notre travail.

### 19.1 Contributions individuelles



TABLE 14 : Contributions individuelles des membres de l'équipe

| Membre                      | Contributions                                                                                                                          |
|-----------------------------|----------------------------------------------------------------------------------------------------------------------------------------|
| ANZID Keltoum               | Analyse exploratoire, interprétation des résultats, rédaction des sections contextuelles, présentation orale                           |
| EL KORAICHI Mohamed Yassine | Feature engineering (familles olfactives, notes), kNN et pistes non explorées, réécriture du rapport, validation et relecture critique |
| HAMLIL Mohamed              | Code R et modélisation (régression logistique, arbre de décision, forêt aléatoire), feature engineering, pipeline anti data leakage    |
| PARDO TERAN German          | Recherche des données (Fragrantica), visualisations, aide à l'interprétation, présentation orale                                       |

## Références

1. Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32.
2. Zou, H. & Hastie, T. (2005). *Regularization and Variable Selection via the Elastic Net*. JRSS-B, 67(2), 301–320.
3. Fawcett, T. (2006). *An Introduction to ROC Analysis*. Pattern Recognition Letters, 27(8), 861–874.
4. Kohavi, R. (1995). *A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection*. IJCAI.
5. Ellena, J.-C. (2007). *Que sais-je ? Le parfum*. Presses Universitaires de France.
6. Fragrantica Fragrance Dataset. Kaggle. <https://www.kaggle.com/datasets/olgagmiufana1/fragrantica-com-fragrance-dataset>
7. Cover, T. & Hart, P. (1967). *Nearest Neighbor Pattern Classification*. IEEE Transactions on Information Theory, 13(1), 21–27.