

TP 2 : Analyse préliminaire du jeu de données Titanic

HAMLIL Mohamed

2025-01-15

Table des matières

1	Introduction	1
1.1	1. Jeu de données	2
1.1.1	1.1. Charger le jeu de données	2
1.1.2	1.2. Caractéristiques du jeu de données	2
1.1.3	1.3. Variables	2
1.1.4	1.4. Target	3
1.1.5	1.5. Transformation de variables (Feature Engineering)	3
1.1.6	1.6. Sélection des variables prédictives	4
1.2	2. Analyse univariée	5
1.2.1	2.1. Statistiques descriptives	5
1.2.2	2.2. Analyse graphique	6
1.3	3. Analyse multivariée	8
1.3.1	3.1. Corrélations entre variables quantitatives	8
1.3.2	3.2. Variables quantitatives vs Target	9
1.3.3	3.3. Variables qualitatives vs Target	10
1.4	4. Gestion des données manquantes	11
1.5	5. Sauvegarde	12

1 Introduction

En TP nous travaillerons principalement avec le jeu de données `titanic`. Notre but sera de prédire la survie des passagers au naufrage du Titanic.

i Objectif

Préparer les données (Data Cleaning) et explorer les relations entre les variables (Data Exploration) avant la modélisation.

1.1 1. Jeu de données**1.1.1 1.1. Charger le jeu de données**

Format du fichier : .csv (Comma Separated Values).

```
# Chargement des librairies
library(dplyr)
library(ggplot2)
library(reshape2)
library(gridExtra)

# Chargement des données
# On utilise stringsAsFactors = FALSE pour garder la main sur les types
data = read.csv("../titanic.csv", stringsAsFactors = FALSE)
```

1.1.2 1.2. Caractéristiques du jeu de données

```
dim(data)
```

```
[1] 876    8
```

Le jeu de données contient **876 individus** et **8 variables**.

1.1.3 1.3. Variables

```
colnames(data)
```

```
[1] "PassengerId" "Survived"    "Pclass"      "Sex"         "Age"
[6] "SibSp"        "Parch"       "Fare"
```

Description des variables :

- **Identifiants (peu utiles pour la prédiction) :** PassengerId, Name, Ticket.
- **Target :** Survived (0 = Décédé, 1 = Survivant).
- **Socio-démographique :** Sex, Age.
- **Voyage :** Pclass (Classe), Fare (Prix), Cabin, Embarked (Port).
- **Famille :** SibSp (Frères/Sœurs/Époux), Parch (Parents/Enfants).

Types de données attendus :

- *Quantitatives :* Age, SibSp, Parch, Fare.
- *Qualitatives :* Survived, Pclass, Sex, Embarked.

```
str(data)
```

```
'data.frame':  876 obs. of  8 variables:
 $ PassengerId: int  1 2 3 4 5 6 7 8 9 10 ...
 $ Survived   : int  0 1 1 1 0 0 0 0 1 1 ...
 $ Pclass     : int  3 1 3 1 3 3 1 3 3 2 ...
 $ Sex        : chr  "male" "female" "female" "female" ...
 $ Age        : num  22 38 26 35 35 NA 54 2 27 14 ...
 $ SibSp      : int  1 1 0 1 0 0 0 3 0 1 ...
 $ Parch      : int  0 0 0 0 0 0 0 1 2 0 ...
 $ Fare       : num  7.25 71.28 7.92 53.1 8.05 ...
```

1.1.4 1.4. Target

La variable cible est **Survived**. Elle est initialement codée comme un entier (`int`).

 Bonnes pratiques

Il est préférable de convertir la target en **facteur** avec des labels explicites pour faciliter la lecture des graphiques et des résultats de modèles.

```
target = factor(data$Survived, labels = c("Décédé", "Survivant"))
data$Survived = as.factor(data$Survived)
```

1.1.5 1.5. Transformation de variables (Feature Engineering)

Nous créons de nouvelles variables pour mieux capturer l'information contenue dans les données brutes.

1. **Taille de la famille (Fam)** : Somme des conjoints, frères, sœurs, parents et enfants.
2. **Indicateur de famille (withFam)** : Binaire, pour savoir si la personne est seule ou accompagnée.

```
data$Fam = data$Parch + data$SibSp
data$withFam = as.factor(ifelse(data$Fam > 0, 1, 0))
```

3. **Catégories d'âge (Age_cat)** : L'âge a souvent un effet non linéaire (les enfants sont sauvés en priorité).

```
# Gestion de la valeur max pour inclure tout le monde
max_age = max(data$Age, na.rm = TRUE)

data$Age_cat = cut(data$Age,
                   breaks = c(0, 13, 18, 60, max_age + 1),
                   labels = c("Enfant", "Adolescent", "Adulte", "Senior"),
                   right = FALSE)
```

Attention

La variable **Age** contient des valeurs manquantes (NA). Par conséquent, **Age_cat** contiendra aussi des NA pour ces individus.

1.1.6 1.6. Sélection des variables prédictives

Nous écartons les identifiants et nous assurons que les variables qualitatives sont bien typées.

```
# Typage correct
data$Pclass = as.factor(data$Pclass)
data$Sex     = as.factor(data$Sex)
if("Embarked" %in% colnames(data)) data$Embarked = as.factor(data$Embarked)

# Séparation
qualitative_vars = data %>% select(Age_cat, Pclass, Sex, withFam)
quantitative_vars = data %>% select(Age, SibSp, Parch, Fam, Fare)
```

1.2 2. Analyse univariée

1.2.1 2.1. Statistiques descriptives

1.2.1.1 Variables quantitatives

```
summary(quantitative_vars)
```

Age	SibSp	Parch	Fam
Min. : 0.42	Min. : 0.000	Min. : 0.0000	Min. : 0.0000
1st Qu.: 20.00	1st Qu.: 0.000	1st Qu.: 0.0000	1st Qu.: 0.0000
Median : 28.00	Median : 0.000	Median : 0.0000	Median : 0.0000
Mean : 29.65	Mean : 0.532	Mean : 0.3881	Mean : 0.9201
3rd Qu.: 38.00	3rd Qu.: 1.000	3rd Qu.: 0.0000	3rd Qu.: 1.0000
Max. : 80.00	Max. : 8.000	Max. : 6.0000	Max. : 10.0000
NA's : 169			

Fare
Min. : 4.013
1st Qu.: 7.925
Median : 14.500
Mean : 32.756
3rd Qu.: 31.275
Max. : 512.329

Observations :

- Age : Environ 20% de données manquantes.
- Fare : Très dispersée (Moyenne = 32, Max = 512). Distribution probablement très asymétrique.

1.2.1.2 Variables qualitatives

```
summary(qualitative_vars)
```

Age_cat	Pclass	Sex	withFam
Enfant : 69	1:211	: 2	0:522
Adolescent: 44	2:178	female:314	1:354
Adulte : 568	3:487	male : 560	
Senior : 26			
NA's : 169			

! Nettoyage des chaînes vides

Parfois, les données manquantes dans les fichiers CSV sont encodées par du vide "" au lieu de NA. Il faut les corriger.

```
# Exemple de correction si nécessaire (notamment pour Embarked)
# data$Embarked[data$Embarked == ""] <- NA
# data$Embarked <- droplevels(data$Embarked)
```

1.2.1.3 Target

```
table(target)
```

```
target
  Décédé Survivant
    535      341
```

```
prop.table(table(target))
```

```
target
  Décédé Survivant
0.6107306 0.3892694
```

Environ **38%** de survie. Les classes sont déséquilibrées, mais c'est gérable.


1.2.2 2.2. Analyse graphique

1.2.2.1 Variables quantitatives (Histogrammes)

```
# Transformation en format long pour ggplot
quant_long = melt(quantitative_vars)

ggplot(quant_long, aes(x = value)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  facet_wrap(~variable, scales = "free") +
  theme_minimal() +
  labs(x = "Valeur", y = "Fréquence")
```

Remarque : Les distributions ne sont pas gaussiennes (normales).



(a) Distribution des variables quantitatives

- **Problème pour Naive Bayes** : Ce modèle suppose souvent la normalité des variables continues.
- **Solutions** : Transformation logarithmique ($\log(x+1)$) ou discrétisation.

1.2.2.2 Variables qualitatives (Barplots)

```
qual_long = melt(qualitative_vars, id.vars = NULL)

ggplot(qual_long, aes(x = value)) +
  geom_bar(fill = "coral", color = "black") +
  facet_wrap(~variable, scales = "free") +
  theme_minimal() +
  labs(x = "Catégories", y = "Effectif")
```




FIGURE 2 : Distribution des variables qualitatives

1.3 3. Analyse multivariée

1.3.1 3.1. Corrélations entre variables quantitatives

```
cor_mat = cor(quantitative_vars, use = "complete.obs")
melted_cor_mat = melt(cor_mat)

ggplot(data = melted_cor_mat, aes(x = Var1, y = Var2, fill = value)) +
  geom_tile() +
  scale_fill_gradient2(low = "blue", mid = "white", high = "red", limit = c(-1,1)) +
  geom_text(aes(label = round(value, 2)), size = 3) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +
  labs(x = "", y = "", fill = "Corr")
```





FIGURE 3 : Matrice de corrélation

Multicolinéarité : Forte corrélation entre Fam, SibSp et Parch. C'est attendu car $Fam = SibSp + Parch$. Il faudra éviter de mettre toutes ces variables ensemble dans certains modèles (ex : régression logistique) pour éviter la redondance.

1.3.2 3.2. Variables quantitatives vs Target


On utilise des **boxplots** pour voir si la distribution d'une variable change selon la survie.

```
plot_data = cbind(quantitative_vars, Target = target)
plot_data_long = melt(plot_data, id.vars = "Target")

ggplot(plot_data_long, aes(x = Target, y = value, fill = Target)) +
  geom_boxplot() +
  facet_wrap(~variable, scales = "free") +
  scale_fill_manual(values = c("pink", "lightblue")) +
  theme_minimal() +
  labs(x = "")
```

Interprétation :

- **Fare** : Les survivants ont payé plus cher en moyenne.
- **Age** : Différence subtile, mais les enfants semblent avantagés (moins d'outliers bas chez les décédés).



(a) Impact des variables quantitatives sur la survie

1.3.3 3.3. Variables qualitatives vs Target

Nous comparons les **proportions** (fill) pour neutraliser l'effet d'effectif total.

```
# Fonction pour générer les plots
plot_list = list()
for(col in names(qualitative_vars)){
  p = ggplot(data = data.frame(var = qualitative_vars[[col]], Target = target) %>% na.omit())
    aes(x = var, fill = Target)) +
    geom_bar(position = "fill", color = "black") +
    scale_fill_manual(values = c("gray70", "lightgreen")) +
    theme_minimal() +
    geom_hline(yintercept = 0.38, linetype="dashed", color="red") + # Moyenne survie
    labs(title = col, x = "", y = "Proportion") +
    theme(legend.position = "bottom")
  plot_list[[col]] = p
}

grid.arrange(grobs = plot_list, ncol = 2)
```




FIGURE 5 : Proportion de survie par catégorie

Conclusions majeures :

1. **Sex :** Les femmes ont beaucoup plus survécu.
2. **Pclass :** La 1ère classe a un net avantage.
3. **Age_cat :** Les enfants ont été protégés.

1.4 4. Gestion des données manquantes

```
colSums(is.na(data))
```

PassengerId	Survived	Pclass	Sex	Age	SibSp
0	0	0	0	169	0
Parch	Fare	Fam	withFam	Age_cat	
0	0	0	0	169	

- **Qualitatives (ex : Cabin, Embarked) :** Créer une catégorie “Inconnu” ou imputer par le mode.
- **Quantitatives (ex : Age) :** Imputer par la médiane ou utiliser une régression basée sur le titre (Mr, Mrs, Master...).

1.5 5. Sauvegarde

Nous sauvegardons les données nettoyées pour le prochain TP.

```
write.csv(data, "titanic_pre_processed.csv", row.names = FALSE)
write.csv(target, "titanic_pre_processed_target.csv", row.names = FALSE)
write.csv(quantitative_vars, "titanic_pre_processed_quantitative_vars.csv", row.names = FALSE)
write.csv(qualitative_vars, "titanic_pre_processed_qualitative_vars.csv", row.names = FALSE)
```