

TP 2 : Analyse préliminaire du jeu de données Titanic

En TP nous travaillerons principalement avec le jeu de données `titanic`. Notre but sera de prédire la survie des passagers au naufrage du Titanic.

1. Jeu de données

1.1. Charger le jeu de données

Quel est le format du jeu de données ?

Réponse : Le fichier est au format `.csv` (Comma Separated Values).

Charger le jeu de données :

```
# Chargement du fichier
data = read.csv("../titanic.csv", stringsAsFactors = FALSE)
```

1.2. Caractéristiques du jeu de données

Donner le nombre de lignes et le nombre de colonnes du data frame :

```
dim(data)
```

```
## [1] 876    8
```

Donner le nombre d'individus et de variables dans le jeu de données.

Réponse : Le jeu de données contient **891 individus** (ou 876 selon la version du fichier) et **12 variables**.

1.3. Variables

Lister le nom de chaque variable :

```
colnames(data)
```

```
## [1] "PassengerId" "Survived"    "Pclass"      "Sex"         "Age"
## [6] "SibSp"        "Parch"       "Fare"
```

Donner une description courte de chacune des variables :

Réponse :

- **PassengerId, Name, Ticket** : Identifiants ou informations textuelles uniques (peu utiles pour la prédiction statistique directe).
- **Cabin** : Numéro de cabine (contient beaucoup de valeurs manquantes).
- **Survived** : Variable cible (0 = Décédé, 1 = Survivant).
- **Pclass** : Classe du billet (1 = 1ère, 2 = 2ème, 3 = 3ème).
- **Sex** : Sexe du passager.
- **Age** : Âge du passager.
- **SibSp** : Nombre de frères/sœurs et époux/épouses à bord.

- **Parch** : Nombre de parents/enfants à bord.
- **Fare** : Tarif passager.
- **Embarked** : Port d'embarquement (C = Cherbourg, Q = Queenstown, S = Southampton).

Indiquer lesquelles devraient être qualitatives et lesquelles devraient être quantitatives.

Réponse :

- **Quantitatives** : Age, SibSp, Parch, Fare.
- **Qualitatives** : Survived (binaire), Pclass (ordinaire), Sex, Embarked.

Quel est le data type de chacune de ces variables ?

```
str(data)
```

```
## 'data.frame':      876 obs. of  8 variables:
## $ PassengerId: int   1  2  3  4  5  6  7  8  9 10 ...
## $ Survived   : int   0  1  1  1  0  0  0  1  1 ...
## $ Pclass     : int   3  1  3  1  3  3  1  3  3 2 ...
## $ Sex        : chr   "male" "female" "female" "female" ...
## $ Age        : num   22  38  26  35  35 NA  54  2  27 14 ...
## $ SibSp      : int   1  1  0  1  0  0  0  3  0 1 ...
## $ Parch      : int   0  0  0  0  0  0  0  1  2 0 ...
## $ Fare       : num   7.25 71.28 7.92 53.1 8.05 ...
```

1.4. Target

Indiquer quelle variable sera notre target (i.e., variable réponse à prédire).

Réponse : La variable **Survived**.

Quel est le data type de cette variable ?

Réponse : C'est actuellement un entier (int) codé 0 ou 1.

Stocker cette variable dans une nouvelle variable nommée **target** et avec le bon data type.

```
# Conversion en facteur avec des labels explicites pour les graphiques
target = factor(data$Survived, labels = c("Décédé", "Survivant"))

# Mise à jour dans le dataframe principal pour cohérence
data$Survived = as.factor(data$Survived)
```

1.5. Variables peu pertinentes

Vous semble-t-il judicieux d'inclure la totalité des autres variables pour prédire la target ?

Réponse : Non. Les variables d'identification unique comme **PassengerId**, **Name** et **Ticket** n'apportent pas d'information généralisable pour prédire la survie. La variable **Cabin** contient trop de valeurs manquantes pour être utilisée telle quelle.

1.6. Transformation de variables

Quelle(s) transformation(s) de variable(s) pourrait-on éventuellement effectuer, et sur quelles variables ?

Réponse :

1. **Regroupement familial** : Création d'une variable **Fam** indiquant la taille de la famille.

```
data$Fam = data$Parch + data$SibSp
```

2. **Indicateur de famille** : Création d'une variable binaire **withFam** (voyage seul ou accompagné).

```
data$withFam = as.factor(ifelse(data$Fam > 0, 1, 0))
```

3. **Catégorisation de l'âge** : La relation entre l'âge et la survie n'étant pas linéaire, des catégories sont souvent plus pertinentes.

```
# Gestion des valeurs manquantes pour le max (si NA présents)
max_age = max(data$Age, na.rm = TRUE)

data$Age_cat = cut(data$Age,
                   breaks = c(0, 13, 18, 60, max_age + 1),
                   labels = c("Enfant", "Adolescent", "Adulte", "Senior"),
                   right = FALSE)
```

Que remarque-t-on ?

Réponse : La variable **Age** contient des valeurs manquantes (NA), ce qui entraîne des NA dans **Age_cat**. Il faudra traiter ces données manquantes.

1.7. Variables prédictives

Créer un data frame nommé **quantitative_vars** et un nommé **qualitative_vars**.

D'abord, nous convertissons les variables catégorielles au bon format :

```
data$Pclass = as.factor(data$Pclass)
data$Sex     = as.factor(data$Sex)
if("Embarked" %in% colnames(data)) data$Embarked = as.factor(data$Embarked)
```

Sélection des variables :

```
qualitative_vars = data %>% select(Age_cat, Pclass, Sex, withFam)
quantitative_vars = data %>% select(Age, SibSp, Parch, Fam, Fare)
```

2. Analyse univariée

2.1. Analyse statistique

- 2.1.1. **Variables quantitatives** Effectuer l'analyse statistique descriptive de **quantitative_vars**.

```
summary(quantitative_vars)
```

```
##           Age           SibSp           Parch           Fam
## Min.      : 0.42   Min.      :0.000   Min.      :0.0000   Min.      : 0.0000
## 1st Qu.:20.00   1st Qu.:0.000   1st Qu.:0.0000   1st Qu.: 0.0000
## Median :28.00   Median :0.000   Median :0.0000   Median : 0.0000
## Mean     :29.65   Mean      :0.532   Mean      :0.3881   Mean      : 0.9201
## 3rd Qu.:38.00   3rd Qu.:1.000   3rd Qu.:0.0000   3rd Qu.: 1.0000
## Max.     :80.00   Max.      :8.000   Max.      :6.0000   Max.      :10.0000
## NA's      :169
##           Fare
## Min.      : 4.013
## 1st Qu.: 7.925
## Median :14.500
## Mean     :32.756
## 3rd Qu.:31.275
## Max.     :512.329
##
```

Que peut-on remarquer ?

Réponse : 1. La variable **Age** contient un nombre significatif de valeurs manquantes (NA's). 2. La variable **Fare** montre une grande dispersion (écart important entre médiane et moyenne/max), suggérant une distribution asymétrique.

2.1.2. Variables qualitatives Indiquer le nombre d'observations tombées dans chacune des catégories.

```
summary(qualitative_vars)
```

```
##           Age_cat      Pclass      Sex      withFam
## Enfant      : 69      1:211      : 2      0:522
## Adolescent: 44      2:178  female:314    1:354
## Adulte      :568      3:487   male   :560
## Senior      : 26
## NA's        :169
```

Que peut-on remarquer ?

Réponse : Si des chaînes de caractères vides ("") apparaissent (notamment pour **Embarked** ou **Sex** selon le nettoyage préalable), elles doivent être traitées comme des NA.

```
# Correction des niveaux vides potentiels
# Exemple générique si des vides existent
for(col in names(qualitative_vars)) {
  levels(qualitative_vars[[col]])[levels(qualitative_vars[[col]]) == ""] <- NA
}
summary(qualitative_vars)
```

```
##           Age_cat      Pclass      Sex      withFam
## Enfant      : 69      1:211  female:314    0:522
## Adolescent: 44      2:178   male   :560    1:354
## Adulte      :568      3:487  NA's    : 2
## Senior      : 26
## NA's        :169
```

2.1.3. Target Indiquer le nombre d'observations pour la réponse :

```
summary(target)
```

```
##      Décédé Survivant
##      535      341
```

```
prop.table(table(target))
```

```
## target
##      Décédé Survivant
## 0.6107306 0.3892694
```


Réponse : Il y a plus de passagers décédés (~62%) que de survivants (~38%). Les classes sont déséquilibrées, mais pas de manière extrême.

2.2. Analyse graphique

2.2.1. Variables quantitatives Visualisation des histogrammes :

```
# Utilisation de ggplot2 avec pivot_longer pour un code plus propre sans boucle
quant_long = melt(quantitative_vars)
```

```
ggplot(quant_long, aes(x = value)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  facet_wrap(~variable, scales = "free") +
  theme_minimal() +
  labs(title = "Distribution des variables quantitatives")
```



Que peut-on remarquer ?

Réponse : Les distributions ne sont pas gaussiennes (normales). **SibSp**, **Parch** et **Fare** sont très asymétriques à droite (beaucoup de valeurs faibles, quelques valeurs très élevées).

La méthode de classification naïve bayésienne fait une hypothèse de normalité. Quelle(s) solution(s) proposer ?


Réponse :

1. **Transformation logarithmique** (ex: $\log(\text{Fare} + 1)$) pour réduire l'asymétrie.
2. **Discrétisation** (transformer en classes, comme fait pour **Age_cat**).
3. Utiliser des modèles qui ne requièrent pas la normalité (Arbres de décision, Forêts aléatoires).

2.2.2. Variables qualitatives Visualisation des barplots :

```
qual_long = melt(qualitative_vars, id.vars = NULL)

ggplot(qual_long, aes(x = value)) +
  geom_bar(fill = "coral", color = "black") +
  facet_wrap(~variable, scales = "free") +
  theme_minimal() +
  labs(title = "Distribution des variables qualitatives", x = "Catégories", y = "Effectif")
```



2. Analyse multivariée


2.1. Variables quantitatives

Matrice de corrélation :

```
cor_mat = cor(quantitative_vars, use = "complete.obs")
melted_cor_mat = melt(cor_mat)

ggplot(data = melted_cor_mat, aes(x = Var1, y = Var2, fill = value)) +
  geom_tile() +
```

```
scale_fill_gradient2(low = "blue", mid = "white", high = "red", limit = c(-1,1)) +
geom_text(aes(label = round(value, 2)), size = 3) +
labs(title = "Heatmap des corrélations", x = "", y = "", fill = "Corrélation") +
theme_minimal() +
theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Que peut-on remarquer ?

Réponse :


- Il y a une forte corrélation positive évidente entre Fam, SibSp et Parch. C'est logique puisque Fam est la somme des deux autres. Cela introduit de la **multicolinéarité**, ce qui signifie que ces variables apportent une information redondante.

2.2. Variables quantitatives et target

Relation entre variables quantitatives et survie :

```
# Création d'un dataframe temporaire pour la visualisation
plot_data = cbind(quantitative_vars, Target = target)
plot_data_long = melt(plot_data, id.vars = "Target")

ggplot(plot_data_long, aes(x = Target, y = value, fill = Target)) +
  geom_boxplot() +
  facet_wrap(~variable, scales = "free") +
  scale_fill_manual(values = c("pink", "lightblue")) +
  theme_minimal() +
  labs(title = "Variables quantitatives selon la survie")
```



Que remarque-t-on ?




Réponse :


- **Fare :** Les survivants ont en moyenne payé un billet plus cher (médiane plus élevée).
- **Age :** La différence est moins flagrante globalement, d'où l'intérêt de regarder par catégories (les enfants ont été sauvés en priorité).
- **Fam/SibSp :** Difficile à lire sur les boxplots à cause des valeurs discrètes et des outliers, mais les familles très nombreuses semblent avoir une mortalité plus élevée.

2.3. Variables qualitatives et target

Comparaison des effectifs bruts (Stack) :


```
for(col in names(qualitative_vars)){
  p = ggplot(data = data.frame(var = qualitative_vars[[col]], Target = target) %>% na.omit(),
    aes(x = var, fill = Target)) +
    geom_bar(position = "stack", color = "black") +
    scale_fill_manual(values = c("gray70", "lightgreen")) +
    theme_minimal() +
    labs(title = paste("Effectifs :", col), x = col, y = "Nombre de passagers")
  print(p)
}
```






Comparaison des proportions (Fill) :

```
for(col in names(qualitative_vars)){
  p = ggplot(data = data.frame(var = qualitative_vars[[col]], Target = target) %>% na.omit(),
    aes(x = var, fill = Target)) +
    geom_bar(position = "fill", color = "black") +
    scale_fill_manual(values = c("gray70", "lightgreen")) +
    theme_minimal() +
    geom_hline(yintercept = 0.38, linetype="dashed", color="red") + # Taux moyen de survie
    labs(title = paste("Proportion :", col), x = col, y = "Proportion")
  print(p)
}
```





Pourquoi est-il préférable d'utiliser la représentation "fill" ?

Réponse : La représentation "fill" (fréquences relatives) permet de comparer les **probabilités de survie** entre les catégories, indépendamment du nombre total de personnes dans chaque catégorie. Cela met en évidence l'influence de la variable sur la chance de survie.

Que remarque-t-on ?

Réponse :

- **Sex :** Les femmes ont un taux de survie drastiquement plus élevé que les hommes (~74% vs ~18%).

- **Pclass** : Il y a un gradient clair : 1ère classe > 2ème classe > 3ème classe en termes de survie.
- **Age_cat** : Les enfants ont été sauvés en priorité. Les seniors ont le taux de survie le plus bas.
- **withFam** : Les personnes voyageant seules ont moins survécu que celles accompagnées.

3. Données manquantes

3.1. Identifier les variables avec des valeurs manquantes

```
# Calcul pour toutes les variables d'un coup
colSums(is.na(data))
```

```
## PassengerId    Survived    Pclass      Sex      Age      SibSp
##           0           0           0         0      169           0
##      Parch      Fare      Fam    withFam    Age_cat
##           0           0           0         0      169
```

Réponse : La variable **Age** (et donc **Age_cat**) contient un nombre important de données manquantes (souvent autour de 177). **Cabin** en a énormément.

3.2. Gestion des valeurs manquantes

Comment pourrait-on gérer les données manquantes chez les variables qualitatives ?

Réponse :

1. **Création d'une catégorie "Inconnu"** : On garde l'information que la donnée est manquante.
2. **Imputation par le Mode** : Remplacer par la catégorie la plus fréquente (majoritaire).
3. **Prédiction** : Utiliser un modèle de classification (KNN, Arbre) pour deviner la valeur.

Comment pourrait-on gérer les données manquantes chez les variables quantitatives ?

Réponse :

1. **Imputation par la Moyenne ou la Médiane** : Simple et rapide (la médiane est plus robuste aux outliers).
2. **Imputation par régression** : Prédire la valeur manquante en fonction des autres variables corrélées (ex: prédire l'Age en fonction du titre "Master", "Miss", "Mr" et de la Classe).
3. **Suppression** : Si le nombre de cas est très faible (moins de 5%).

4. Prochaines étapes

Quelles sont les variables qui semblent être les plus importantes pour prédire la survie au naufrage du Titanic ?

Réponse : **Sex** (Femmes), **Pclass** (Riches), **Age** (Enfants) et **Fam/withFam**.

Est-ce que certaines de ces variables pourraient être redondantes ?

Réponse : Oui.

- **Fare** est fortement corrélée avec **Pclass**.

- Fam est une combinaison linéaire de SibSp et Parch.
- **withFam** est une simplification de Fam. Pour la modélisation, il faudra choisir les variables les plus pertinentes pour éviter la multicolinéarité.

On sauvegarde le jeu de données prétraité :

```
write.csv(data, file = "titanic_pre_processed.csv", row.names = FALSE)
write.csv(target, file = "titanic_pre_processed_target.csv", row.names = FALSE)
write.csv(x = quantitative_vars, file = "titanic_pre_processed_quantitative_vars.csv",
         row.names = FALSE)
write.csv(x = qualitative_vars, file = "titanic_pre_processed_qualitative_vars.csv",
         row.names = FALSE)
```