

TP 4 : Transformation de variables, imputation et data leakage

Compléments de Mathématiques 2 - L3 MIA SHS

Lola Etiévant

2026-02-02

Table of contents

1	Introduction	1
2	Gestion des données manquantes	2
2.1	Imputation Statique	2
2.1.1	Variable Quantitative (Médiane)	2
2.1.2	Variable Qualitative (Mode)	2
2.2	Imputation prédictive par régression linéaire	3
2.2.1	Visualisation pédagogique	3
3	Transformations de variables	4
3.1	Encodage (Dummy vs Label)	4
3.2	Mise à l'échelle (Scaling)	5
4	Data Leakage	5
5	Résumé des étapes	5

1 Introduction

L'objectif de ce TP est d'approfondir les étapes de préparation des données (*preprocessing*). Nous allons mettre en œuvre des techniques d'imputation pour les données manquantes, explorer les transformations de variables et aborder le concept critique de **Data Leakage** pour garantir l'intégrité de nos futurs modèles.

```

library(caret)
library(ggplot2)
library(dplyr)

# Chargement des données (ajuster les chemins si nécessaire)
qualitative_vars <- read.csv("../TP2/titanic_pre_processed_qualitative_vars.csv", stringsAsFactors = FALSE)
quantitative_vars <- read.csv("../TP2/titanic_pre_processed_quantitative_vars.csv")
target <- read.csv("../TP2/titanic_pre_processed_target.csv")

# Correction des types
qualitative_vars$Pclass <- as.factor(qualitative_vars$Pclass)
qualitative_vars$withFam <- as.factor(qualitative_vars$withFam)
target <- as.factor(target$x)

# Création d'une copie pour les versions complétées
quantitative_vars_complete <- quantitative_vars

```

2 Gestion des données manquantes

2.1 Imputation Statique

L'imputation remplace les valeurs manquantes (NA) par des statistiques descriptives simples.

2.1.1 Variable Quantitative (Médiane)

On utilise la médiane plutôt que la moyenne car elle est moins sensible aux valeurs extrêmes.

```

Proc_median <- preProcess(quantitative_vars, method = "medianImpute")
quantitative_vars_complete <- predict(Proc_median, quantitative_vars)
names(quantitative_vars_complete)[1] <- "Age_imput_median"

```

2.1.2 Variable Qualitative (Mode)

Pour les catégories, on remplace par la modalité la plus fréquente.

```

cat_imputation <- function(v) {
  mode_val <- levels(v)[which.max(table(v))]
  v[is.na(v)] <- mode_val
  return(v)
}

```

```

}

qualitative_vars_complete <- qualitative_vars
qualitative_vars_complete$Sex <- cat_imputation(qualitative_vars$Sex)
qualitative_vars_complete$Age_cat <- cat_imputation(qualitative_vars$Age_cat)

```

2.2 Imputation prédictive par régression linéaire

L'imputation prédictive traite la variable manquante comme une cible à prédire à partir des autres informations disponibles.

i Concept

Peut-on imputer **Age** et **Sex** avec cette méthode ? **Réponse :** Oui pour l'**Age** (variable continue), mais pour **Sex** (binaire), une régression linéaire n'est pas adaptée ; on préférera une régression logistique.

```

# 1. Identification des indices
isMissing = which(is.na(quantitative_vars$Age))
isNotMissing = which(!is.na(quantitative_vars$Age))

# 2. Préparation des données pour le modèle (Variables Fam et Fare)
age_isNotMissing = quantitative_vars$Age[isNotMissing]
X_isNotMissing = quantitative_vars[isNotMissing, c("Fam", "Fare")]
X_isMissing = quantitative_vars[isMissing, c("Fam", "Fare")]

# 3. Entraînement et prédiction
fit = lm(age_isNotMissing ~ ., data = X_isNotMissing)

quantitative_vars_complete$Age_imput_reg = quantitative_vars$Age
quantitative_vars_complete$Age_imput_reg[isMissing] = predict(fit, X_isMissing)

```

2.2.1 Visualisation pédagogique

Le graphique suivant montre comment les valeurs imputées (en rouge) s'insèrent dans la distribution existante selon le modèle de régression.

```

plot_df <- data.frame(
  Fare = quantitative_vars$Fare,
  Age = quantitative_vars_complete$Age_imput_reg,

```

```

Type = ifelse(is.na(quantitative_vars$Age), "Imputée (LM)", "Réelle")
)

ggplot(plot_df, aes(x = Fare, y = Age, color = Type)) +
  geom_point(alpha = 0.5) +
  geom_smooth(data = filter(plot_df, Type == "Réelle"), method = "lm", se = FALSE, color = "black") +
  scale_color_manual(values = c("Imputée (LM)" = "red", "Réelle" = "steelblue")) +
  theme_minimal() +
  labs(title = "Imputation de l'Age par rapport au Fare")

```




Figure 1: Distribution de l'Age : Valeurs Réelles vs Imputées par Régression

3 Transformations de variables

3.1 Encodage (Dummy vs Label)

- **Dummy Coding** : Utile pour les variables nominales sans ordre (ex: Sex).
- **Label Encoding** : Réservé aux variables ordinales (ex: Pclass).

3.2 Mise à l'échelle (Scaling)

Il est crucial de ramener les variables à la même échelle pour les algorithmes calculant des distances (comme k-NN).

4 Data Leakage

! Définition

Le **Data Leakage** se produit lorsque des informations du jeu de test sont utilisées lors de l'entraînement. Pour l'éviter, on doit "apprendre" les transformations (moyenne, médiane, etc.) uniquement sur le **Train**.

```
set.seed(1234)
split <- createDataPartition(target, p = 0.8, list = FALSE)

train_X <- quantitative_vars[split, ]
test_X  <- quantitative_vars[-split, ]

# On calcule les paramètres sur Train
Proc <- preProcess(train_X, method = c("medianImpute", "center", "scale"))

# On applique au Train ET au Test
train_final <- predict(Proc, train_X)
test_final  <- predict(Proc, test_X)
```

5 Résumé des étapes

Avant d'appliquer un classifieur :

1. **Split** : Séparer en Train et Test.
2. **Imputation** : Gérer les NA (en utilisant les stats du Train).
3. **Transformation** : Encodage et Standardisation (en utilisant les paramètres du Train).