

TP1 – Graphiques Quantile-Quantile, Test de Normalité et Test du χ^2

HAMLIL Mohamed

2025-01-15

Table des matières

Introduction	2
1. Le QQ-Plot (graphique quantile-quantile)	2
1.1 Rappels théoriques	2
1.2 Application : tensions de pile	3
Étape 1 : Saisie des données	3
Étape 2 : Calcul de la moyenne pondérée	3
Étape 3 : Calcul de l'écart-type pondéré	3
Étape 4 : Fréquences cumulées et quantiles théoriques	4
Étape 5 : Tracé du QQ-plot	4
2. Test du χ^2 pour la normalité	5
2.1 Fusion des effectifs faibles	5
2.2 Calcul des probabilités théoriques	5
2.3 Calcul de la statistique du χ^2	5
2.4 Degrés de liberté et conclusion	6
3. Test du χ^2 d'indépendance	6
3.1 Importation des données du Titanic	6
3.2 Test d'indépendance : Survie vs Classe	8
3.3 Autres tests d'indépendance	9
Survie vs Sexe	9
Classe vs Port d'embarquement	9
Survie vs Port d'embarquement	10
4. Normalité et fonctions de R	10
4.1 Acquisition de la variable <code>age</code>	10

4.2 Normalité de age	11
Densité estimée	11
QQ-plot	12
Test de Shapiro-Wilk	13
4.3 Normalité de age par classe	14
Résumé	14

Introduction

Dans ce TP, nous allons utiliser les outils de la **normalité** et de **l'indépendance** dans deux cadres :

- Sur **données ordonnées** (regroupées par modalités) : nous reconstruirons tous les outils à la main.
- Sur **données brutes** : nous utiliserons largement les fonctions de R.

Objectifs pédagogiques :

- Comprendre et tracer un QQ-plot
- Réaliser un test du χ^2 d'adéquation (normalité)
- Réaliser un test du χ^2 d'indépendance
- Utiliser les fonctions R pour tester la normalité (Shapiro-Wilk, `qqnorm`)

1. Le QQ-Plot (graphique quantile-quantile)

1.1 Rappels théoriques

Le **QQ-plot** (Quantile-Quantile plot) est un outil graphique qui permet de visualiser rapidement si une série de données suit une distribution théorique donnée (gaussienne, Poisson, etc.).

Principe :

Soit $x_1, \dots, x_n$ une série statistique et F_0 la fonction de répartition de la loi de probabilité de référence. On trace :

- En **ordonnées** : les fractiles correspondant à la distribution **observée** (q_i)
- En **abscisses** : les fractiles correspondant à la distribution **théorique** (q_i^*)

Interprétation : Plus les points sont alignés sur la **diagonale**, plus l'adéquation de la loi théorique avec la loi observée est forte.

Pour des données regroupées par modalités $m_1, \dots, m_J$ avec des fréquences cumulées $F_1, \dots, F_J$, les quantiles théoriques d'une loi normale sont : $q_J^* = F_0^{-1}(F_J)$, accessibles via `qnorm(F_J, m, )`.

1.2 Application : tensions de pile

Contexte : Xantane a relevé 500 fois les tensions (x_i) de sa pile. Les données sont regroupées dans le tableau suivant :

x_i	92	93	94	95	96	97	98	99	100	101	102	103	104	105	106	107	108	109
n_i	1	4	9	28	23	37	51	63	65	60	48	38	32	23	12	3	1	2

Étape 1 : Saisie des données

```
qi = 92:109
ni = c(1, 4, 9, 28, 23, 37, 51, 63, 65, 60, 48, 38, 32, 23, 12, 3, 1, 2)
```

Étape 2 : Calcul de la moyenne pondérée

La moyenne pondérée se calcule comme : $m = \frac{\sum q_i \cdot n_i}{\sum n_i}$

```
m = sum(qi * ni) / sum(ni)
cat("Moyenne pondérée m =", m)
```

Moyenne pondérée m = 100.068

Étape 3 : Calcul de l'écart-type pondéré

$$\sigma = \sqrt{\frac{\sum n_i (q_i - m)^2}{\sum n_i - 1}}$$

```
sigma = sqrt(sum(ni * (qi - m)^2) / (sum(ni) - 1))
cat("Écart-type pondéré sigma =", round(sigma, 2))
```


Écart-type pondéré sigma = 3.08

Étape 4 : Fréquences cumulées et quantiles théoriques

```
Fi = cumsum(ni) / sum(ni)
qiетоile = qnorm(Fi, m, sigma)
```

Étape 5 : Tracé du QQ-plot

```
plot(qi, qiетоile,
     main = "QQ-Plot : Tensions de pile",
     xlab = "Quantiles observés (qi)",
     ylab = "Quantiles théoriques (qi*)",
     pch = 19, col = "blue")
lines(c(90, 110), c(90, 110), col = "red", lwd = 2)
legend("topleft", legend = "Diagonale y = x", col = "red", lwd = 2)
```



Conclusion : Les points sont bien alignés sur la diagonale. On observe une bonne adéquation avec une loi Normale $\mathcal{N}(m, \sigma)$.

2. Test du χ^2 pour la normalité

Puisque nous ne disposons pas des données brutes, nous ne pouvons pas faire un test de Shapiro-Wilk. Nous allons donc utiliser le **test du χ^2** pour vérifier l'adéquation à la loi normale.

2.1 Fusion des effectifs faibles

Pour que le test du χ^2 soit valide, il faut que les effectifs théoriques soient supérieurs à 5. On fusionne donc les 2 premiers et les 3 derniers effectifs :

```
ni2 = c(ni[1] + ni[2], ni[3:15], ni[16] + ni[17] + ni[18])
cat("Effectifs regroupés :", ni2)
```

Effectifs regroupés : 5 9 28 23 37 51 63 65 60 48 38 32 23 12 6

2.2 Calcul des probabilités théoriques

On calcule les probabilités théoriques p_i en faisant la **correction de continuité** (bornes à ± 0.5) :

```
k = c(91, 93:106) + 0.5
K = c(93:106.5, 109) + 0.5
pi_theo = pnorm(K, 100, 3.1) - pnorm(k, 100, 3.1)
ti = 500 * pi_theo
```

2.3 Calcul de la statistique du χ^2

```
dchi = sum((ni2 - ti)^2 / ti)
cat("Statistique du chi-deux :", round(dchi, 4))
```

Statistique du chi-deux : 12.0494

On peut aussi utiliser la fonction `chisq.test` :

```
chisq.test(ni2, p = pi_theo, rescale.p = TRUE)
```

Chi-squared test for given probabilities

```
data: ni2
X-squared = 11.991, df = 14, p-value = 0.607
```

2.4 Degrés de liberté et conclusion

Attention ! Les degrés de liberté valent $15 - 1 - 2 = 12$ (car nous avons estimé 2 paramètres : m et σ). Or `chisq.test()` n'utilise pas les bons d.d.l. et donne une p-value erronée.

Calculons la p-value correcte :

```
cat("Quantile théorique  $\chi^2(0.95, 12)$  =", qchisq(0.95, 12))
cat("\nStatistique observée =", round(dchi, 4))
cat("\np-value correcte =", 1 - pchisq(dchi, 12))
```

```
Quantile théorique  $\chi^2(0.95, 12)$  = 21.02607
Statistique observée = 12.0494
p-value correcte = 0.4417218
```

Conclusion : La p-value est supérieure à 0.05 $\rightarrow$ on **ne rejette pas** l'hypothèse de normalité au seuil 5%.

3. Test du χ^2 d'indépendance

3.1 Importation des données du Titanic

Le fichier `titanic.csv` contient le registre des passagers du Titanic. L'objectif est d'étudier la relation entre **survie** et **classe** à l'aide du test d'indépendance de Chi-deux.

```
titanic = read.csv("titanic.csv")
head(titanic)
```

A data.frame : 6 × 12

	Pas- sen- ge- rId <int>	Sur- vi- ved <int>	Pclass <int>	Name <chr>	Sex <chr>	Age <dbl>	SibSp <int>	Parch <int>	Ti- cket <chr>	Fare <dbl>	Ca- bin <chr>	Em- bar- ked <chr>
1	1	0	3	Braund Mr. Owen Har-	male	22	1	0	A/5 21171	7.2500		S
2	2	1	1	Cu- mings. Mrs. John Brad- ley (Flo- rence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C
3	3	1	3	Heik- ki- nen. Miss. Laina	female	26	0	0	STON/ 3101282	51.0125		S
4	4	1	1	Fu- trelle. Mrs. Jacques Heath (Lily May Peel)	female	35	1	0	113803	53.1000	C123	S
5	5	0	3	Al- len. Mr. William Henry	male	35	0	0	373450	8.0500		S
6	6	0	3	Mo- ran. Mr. James	male	NA	0	0	330877	8.4583		Q

Stockons les variables d'intérêt :

```
survived = titanic$Survived
class = titanic$Pclass
head(survived)
head(class)
```

```
1. 0
2. 1
3. 1
4. 1
5. 0
6. 0
```

```
1. 3
2. 1
3. 3
4. 1
5. 3
6. 3
```

3.2 Test d'indépendance : Survie vs Classe

Construisons le **tableau de contingence** :

```
contingence1 = table(survived, class)
contingence1
```

	class		
survived	1	2	3
0	80	97	372
1	136	87	119

Effectuons le test du χ^2 d'indépendance :

```
chisq.test(contingence1)
```

Pearson's Chi-squared test

```
data:  contingence1
X-squared = 102.89, df = 2, p-value < 2.2e-16
```


Interprétation : La p-value est inférieure à 0.05 (pratiquement égale à 0) → on **rejette** significativement l'hypothèse d'indépendance. La classe et la survie sont **dépendantes**. *Malheureusement, on le savait...*

3.3 Autres tests d'indépendance

Survie vs Sexe

```
contingence_sex = table(survived, titanic$Sex)
contingence_sex
chisq.test(contingence_sex)
```

```
survived female male
      0      81  468
      1     233  109
```

Pearson's Chi-squared test with Yates' continuity correction

```
data:  contingence_sex
X-squared = 260.72, df = 1, p-value < 2.2e-16
```

Classe vs Port d'embarquement

```
contingence2 = table(class, titanic$Embarked)
contingence2
```

```
class      C  Q  S
  1  2  85  2 127
  2  0  17  3 164
  3  0  66  72 353
```

On remarque une colonne vide (port inconnu). Supprimons-la :

```
contingence2 = contingency2[, -1]
contingence2
chisq.test(contingence2)
```

```
class   C   Q   S
  1  85   2 127
  2  17   3 164
  3  66  72 353
```

Pearson's Chi-squared test

```
data:  contingency2
X-squared = 123.75, df = 4, p-value < 2.2e-16
```

Survie vs Port d'embarquement

```
contingence3 = table(survived, titanic$Embarked)
contingence3 = contingency3[, -1]
chisq.test(contingence3)
```

Pearson's Chi-squared test

```
data:  contingency3
X-squared = 26.489, df = 2, p-value = 1.77e-06
```

4. Normalité et fonctions de R

4.1 Acquisition de la variable age

```
age = titanic$Age
head(age)
```

1. 22
2. 38
3. 26
4. 35
5. 35
6. <NA>

Certains âges sont manquants (NA). Gardons seulement les âges connus :


```
age = age[!is.na(age)]  
class2 = class[!is.na(titanic$Age)]  
cat("Nombre d'âges valides :", length(age))
```

Nombre d'âges valides : 714

4.2 Normalité de age


Densité estimée

```
plot(density(age),  
     main = "Densité de la variable Age",  
     xlab = "Âge", ylab = "Densité",  
     col = "blue", lwd = 2)
```



QQ-plot

```
qqnorm(age, main = "QQ-plot de Age")  
qqline(age, col = "red")
```



Test de Shapiro-Wilk

```
shapiro.test(age)
```

Shapiro-Wilk normality test

data: age

W = 0.98146, p-value = 7.337e-08

Conclusion : La densité n'a pas l'allure d'une gaussienne, le QQ-plot dévie, et le test de Shapiro-Wilk rejette la normalité ($p\text{-value} < 0.05$). La variable **age n'est pas normale**.

4.3 Normalité de age par classe

La fonction `tapply` permet d'appliquer une fonction à une variable divisée par sous-groupes :

```
tapply(age, class2, shapiro.test)
```

```
$`1`
```

```
Shapiro-Wilk normality test
```

```
data:  X[[i]]
```

```
W = 0.99169, p-value = 0.3643
```

```
$`2`
```

```
Shapiro-Wilk normality test
```

```
data:  X[[i]]
```

```
W = 0.97695, p-value = 0.005648
```

```
$`3`
```

```
Shapiro-Wilk normality test
```

```
data:  X[[i]]
```

```
W = 0.97344, p-value = 4.186e-06
```

Conclusion : Seul en **première classe**, l'âge peut être considéré comme normal. Reste à savoir si cette information est vraiment intéressante...

Résumé

Outil	Utilisation	Fonction R
QQ-plot	Visualiser l'adéquation à une loi	<code>qqnorm()</code> , <code>plot()</code>

Outil	Utilisation	Fonction R
Test χ^2 d'adéquation	Tester si les données suivent une loi	<code>chisq.test()</code>
Test χ^2 d'indépendance	Tester l'indépendance de 2 variables	<code>chisq.test(table())</code>
Test de Shapiro-Wilk	Tester la normalité (données brutes)	<code>shapiro.test()</code>
<code>tapply</code>	Appliquer une fonction par sous-groupe	<code>tapply(var, groupe, fun)</code>