

TP3 – ANOVA à un facteur

HAMLIL Mohamed

2025-01-15

Table des matières

Introduction	2
1. Acquisition des données	2
2. Effet de l'abolition sur le taux de meurtres	3
2.1 Statistiques descriptives	3
Boîtes à moustaches	3
Comparaison des moyennes	5
2.2 ANOVA	6
2.3 Retrouver les résultats du tableau d'ANOVA	6
SCM (Somme des Carrés du Modèle)	6
SCE (Somme des Carrés des Erreurs)	7
Statistique de Fisher	7
p-value	7
3. Et en 2016 ?	7
4. Beignets et matière grasse	9
4.1 Contexte	9
4.2 Acquisition des données	10
4.3 Test de normalité par groupe	10
4.4 Tableau d'ANOVA	11
4.5 Contrastes	12
Fonction de test de contraste	13
4.6 Construction du tableau d'ANOVA à la main	14
Résumé	15

Introduction

Le but de cette séance est de s'éclairer sur le **lien potentiel entre l'abolition de la peine de mort et le taux de criminalité** aux États-Unis.

Les données proviennent du site du FBI. Elles donnent le nombre de meurtres dans les différents états des États-Unis en 2009 ainsi que la population. Pour s'affranchir des différences de tailles de populations, on utilise le **taux de criminalité pour 1000 habitants**.

Nous étudierons ensuite un second jeu de données sur l'**absorption de matière grasse par des beignets**, un cas classique d'**ANOVA à un facteur**.

1. Acquisition des données

```
data = read.csv2("murderusa.csv")
head(data)
```

A data.frame : 6×5

	State <chr>	Popula- tion..en.mil- liers. <int>	Total.mur- ders..2009. <int>	tauxmeurtres <dbl>	PDMabolie09 <chr>
1	Vermont	622	7	0.113	oui
2	Iowa	3008	34	0.113	oui
3	Minnesota	5266	72	0.137	oui
4	North Dakota	647	9	0.139	oui
5	Hawaii	1295	21	0.162	oui
6	Maine	1318	26	0.197	oui

Affectons les variables :

```
txcrime09 = data$tauxmeurtres
PDMabolie09 = data$PDMabolie09
```

Créons deux sous-groupes : états ayant **aboli** la peine de mort et ceux ne l'ayant **pas aboli** :

```

abolie09 = txcrime09[PDMabolie09 == "oui"]
nonabolie09 = txcrime09[PDMabolie09 == "non"]

# Conversion en numérique si nécessaire
abolie09 = as.numeric(abolie09)
nonabolie09 = as.numeric(nonabolie09)

cat("Nombre d'états ayant aboli :", length(abolie09))
cat("\nNombre d'états n'ayant pas aboli :", length(nonabolie09))

```

Nombre d'états ayant aboli : 13
 Nombre d'états n'ayant pas aboli : 37

2. Effet de l'abolition sur le taux de meurtres


2.1 Statistiques descriptives

Boîtes à moustaches

```


boxplot(abolie09, nonabolie09,
        main = "Taux de criminalité selon l'abolition de la peine de mort",
        col = c("orange", "red"),
        names = c("Abolie", "Non Abolie"),
        ylab = "Taux de meurtres pour 1000 hab.")

```



On peut aussi utiliser directement la formule :

```
boxplot(txcrime09 ~ PDMabolie09,  
        main = "Taux de criminalité",  
        col = c("orange", "red"),  
        ylab = "Taux de meurtres pour 1000 hab.")
```



Observations :

- Tous les indicateurs (médiane, quartiles) sont **plus bas** dans les états ayant aboli la peine de mort.
- Le taux de criminalité est **globalement plus bas** dans les états ayant aboli.
- **Attention** : Aucun lien de cause à effet ne peut être dégagé ! (Est-ce l'abolition qui fait baisser le taux ? Est-ce un taux bas qui permet d'abolir ? Ou n'y a-t-il aucun lien ?)

Comparaison des moyennes

```
cat("Moyenne (abolie) :", mean(abolie09))
cat("\nMoyenne (non abolie) :", mean(nonabolie09))
```

Moyenne (abolie) : 0.2963846
Moyenne (non abolie) : 0.494973

2.2 ANOVA

On teste si la différence entre les groupes est **statistiquement significative** :

```
summary(aov(txcrime09 ~ PDMabolie09))
```

```
              Df Sum Sq Mean Sq F value Pr(>F)
PDMabolie09    1  0.379   0.3794    3.172 0.0812 .
Residuals     48  5.740   0.1196
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

On obtient le même résultat avec `anova` :

```
anova(lm(txcrime09 ~ PDMabolie09))
```

A anova : 2×5

	Df <int>	Sum Sq <dbl>	Mean Sq <dbl>	F value <dbl>	Pr(>F) <dbl>
PDMabolie09	1	0.3793872	0.3793872	3.172317	0.08122444
Residuals	48	5.7404680	0.1195931	NA	NA

Interprétation : La p-value est **trop grande** pour rejeter l'égalité des moyennes. On **ne peut pas affirmer** qu'il y a un lien significatif entre l'abolition de la peine de mort et le taux de criminalité.

2.3 Retrouver les résultats du tableau d'ANOVA

SCM (Somme des Carrés du Modèle)

$$SCM = \sum_{i=1}^2 n_i (\bar{X}_i - \bar{X})^2$$

```
SCM = length(abolie09) * (mean(abolie09) - mean(txcrime09))^2 +
      length(nonabolie09) * (mean(nonabolie09) - mean(txcrime09))^2
cat("SCM =", round(SCM, 6))
```

SCM = 0.379387

SCE (Somme des Carrés des Erreurs)

$$SCE = \sum_{i=1}^2 \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2$$

```
SCE = sum((abolie09 - mean(abolie09))^2) +  
      sum((nonabolie09 - mean(nonabolie09))^2)  
cat("SCE =", round(SCE, 6))
```

SCE = 5.740468

Statistique de Fisher

$$F_{obs} = \frac{SCM/(2-1)}{SCE/(50-2)} = \frac{SCM}{SCE/48}$$

```
Fobs = SCM / (SCE / 48)  
cat("F observé =", round(Fobs, 4))
```

F observé = 3.1723

p-value

La variable du test suit une loi de Fisher $\mathcal{F}_{1,48}$:

```
pval = 1 - pf(Fobs, 1, 48)  
cat("p-value =", round(pval, 4))
```

p-value = 0.0812

3. Et en 2016 ?


Des résultats similaires ont été montrés en 2016 en L2. On peut charger le fichier `crime16.csv` pour une analyse comparable :

```
crime16 = read.csv2("crime16.csv")
head(crime16)
```

A data.frame : 6×2

	crime_nonabo <dbl>	crime_abo <dbl>
1	532.3	123.8
2	470.1	158.3
3	550.9	227.1
4	445.3	238.9
5	372.2	242.6
6	501.8	245.0

```
boxplot(crime16$crime_nonabo, crime16$crime_abo,
        names = c("Non abolie", "Abolie"),
        main = "Taux de criminalité en 2016",
        col = c("red", "orange"),
        ylab = "Taux de criminalité")
```

4. Beignets et matière grasse

4.1 Contexte

On étudie la variable « quantité de matière grasse absorbée par des beignets durant leur cuisson ». Pour chacune des **4 matières grasses**, on a constitué 6 fournées de 24 beignets chacune. Les valeurs ont été simplifiées en soustrayant 100g.

C'est une **classification à une seule voie** : chaque matière grasse représente un **niveau du facteur**.

4.2 Acquisition des données

```
rm(list = ls())
donnees <- read.table("beignets.txt", header = TRUE)
head(donnees)
```

A data.frame : 6×2

	Gras <int>	Gr <int>
1	64	1
2	72	1
3	68	1
4	77	1
5	56	1
6	95	1

```
X = donnees[, "Gras"]
Groupe = factor(donnees[, "Gr"])
cat("Niveaux du facteur :", levels(Groupe))
cat("\nNombre d'observations :", length(X))
```

Niveaux du facteur : 1 2 3 4

Nombre d'observations : 24

Note : Bien que codée de 1 à 4, la variable **Groupe** n'est pas numérique, c'est un **facteur**. C'est pour cela qu'on utilise `factor()`.

4.3 Test de normalité par groupe

Avant de faire une ANOVA, on vérifie l'hypothèse de normalité dans chaque groupe :

```
tapply(X, Groupe, shapiro.test)
```

```
$`1`
```

```
Shapiro-Wilk normality test
```

```
data: X[[i]]
```

```
W = 0.95004, p-value = 0.7406
```

```
$`2`
```

```
Shapiro-Wilk normality test
```

```
data: X[[i]]
```

```
W = 0.93162, p-value = 0.5926
```

```
$`3`
```

```
Shapiro-Wilk normality test
```

```
data: X[[i]]
```

```
W = 0.9334, p-value = 0.6066
```

```
$`4`
```

```
Shapiro-Wilk normality test
```

```
data: X[[i]]
```

```
W = 0.88836, p-value = 0.3097
```

Conclusion : On ne rejette la normalité dans **aucun** groupe → on peut utiliser l'ANOVA.

4.4 Tableau d'ANOVA

```
summary(aov(X ~ Groupe))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Groupe	3	1636	545.5	5.406	0.00688 **
Residuals	20	2018	100.9		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
anova(lm(X ~ Groupe))
```

A anova : 2×5

	Df <int>	Sum Sq <dbl>	Mean Sq <dbl>	F value <dbl>	Pr(>F) <dbl>
Groupe	3	1636.5	545.5	5.406343	0.006875948
Residuals	20	2018.0	100.9	NA	NA

Conclusion : On rejette l'égalité des moyennes $\rightarrow$ il y a un **effet significatif** du type de graisse sur l'absorption.

4.5 Contrastes

On souhaite tester l'hypothèse que les matières grasses **d'origine animale** (groupes 1 et 2) sont absorbées de la même façon que celles **d'origine végétale** (groupes 3 et 4) :

$$\frac{\mu_1 + \mu_2}{2} = \frac{\mu_3 + \mu_4}{2} \iff \mu_1 + \mu_2 - \mu_3 - \mu_4 = 0$$

Les coefficients du contraste sont $\lambda = (1, 1, -1, -1)$.

```
lambda.i = c(1, 1, -1, -1)
xbar.i = tapply(X, Groupe, mean)
cat("Moyennes par groupe :\n")
print(xbar.i)
```

Moyennes par groupe :

```
1 2 3 4
72 85 76 62
```

```
n = length(X)
n.i = tapply(rep(1, n), Groupe, sum)
a = length(levels(Groupe))

# Somme des carrés des erreurs
Q.i = tapply(X, Groupe, var) * (n.i - 1)
SCE = sum(Q.i)
dl = n - a
```

```

CME = SCE / dl

# Contraste et test de Student
phi = sum(xbar.i * lambda.i)
s.phi = sqrt(CME * sum(lambda.i^2 / n.i))
tvalue = (phi - 0) / s.phi
pvaleur = pt(tvalue, dl)
pvaleur = 2 * min(pvaleur, 1 - pvaleur)

cat("Contraste estimé ^ =", round(phi, 2))
cat("\nÉcart-type s(^) =", round(s.phi, 2))
cat("\nStatistique t =", round(tvalue, 4))
cat("\np-value =", round(pvaleur, 4))
cat("\nDegrés de liberté =", dl)

```

```

Contraste estimé ^ = 19
Écart-type s(^) = 8.2
Statistique t = 2.3166
p-value = 0.0313
Degrés de liberté = 20

```

Conclusion : La nature de la matière grasse (animale vs végétale) a une **influence significative** sur l'absorption.

Fonction de test de contraste

On peut encapsuler ce test dans une fonction réutilisable :

```

contrast.test = function(X, Groupe, lambda.i, phi0 = 0) {
  xbar.i = tapply(X, Groupe, mean)
  n = length(X)
  a = length(levels(Groupe))
  n.i = tapply(rep(1, n), Groupe, sum)
  Q.i = tapply(X, Groupe, var) * (n.i - 1)
  SCE = sum(Q.i)
  dl = n - a
  CME = SCE / dl
  phi = sum(xbar.i * lambda.i)
  s.phi = sqrt(CME * sum(lambda.i^2 / n.i))
  tvalue = (phi - phi0) / s.phi

```

```

pvaleur = pt(tvalue, dl)
pvaleur = 2 * min(pvaleur, 1 - pvaleur)
return(list(c(phi.hat = phi, s.phi = s.phi),
              c(t = tvalue, p.value = pvaleur), dl = dl))
}

contrast.test(X, Groupe, c(1, 1, -1, -1), phi0 = 0)

```

```

[[1]] phi.hat
      19s.phi
      8.20162585507695
[[2]] t
      2.31661384410003p.value
      0.0312510602796205
$dl 20

```

4.6 Construction du tableau d'ANOVA à la main

Pour bien comprendre l'ANOVA, construisons le tableau pas à pas :

```

a <- length(levels(Groupe))
n <- length(X)

# Tailles de chaque groupe
n.i <- tapply(rep(1, n), Groupe, sum)

# Moyennes de chaque groupe
xbar.i <- tapply(X, Groupe, mean)

# Variation dans chaque groupe
Q.i <- tapply(X, Groupe, var) * (n.i - 1)

# Sommes des carrés
SCT <- (n - 1) * var(X)
SCE <- sum(Q.i)
SCM <- SCT - SCE

# Degrés de liberté
dlE <- n - a
dlM <- a - 1

```

```
# Carrés moyens
CMM <- SCM / dlM
CME <- SCE / dlE

# Statistique de Fisher et p-value
F.obs <- CMM / CME
seuil.crit <- 1 - pf(F.obs, dlM, dlE)

# Construction du tableau
Anova.tableau <- matrix(
  c(SCM, SCE, SCT, dlM, dlE, NA, CMM, CME, NA, F.obs, NA, NA, seuil.crit, NA, NA),
  nrow = 3,
  dimnames = list(c("Inter groupe", "Intra groupe", "Totale"),
                  c("SC", "dl", "CM", "F.obs", "Pr(F)"))
)
Anova.tableau
```

A matrix : 3×5 of type dbl

	SC	dl	CM	F.obs	Pr(F)
Inter groupe	1636.5	3	545.5	5.406343	0.006875948
Intra groupe	2018.0	20	100.9	NA	NA
Totale	3654.5	NA	NA	NA	NA

Résumé

Concept	Description	Fonction R
Boxplot comparatif	Comparer deux distributions	<code>boxplot(x ~ facteur)</code>
ANOVA à 1 facteur	Tester l'égalité des moyennes	<code>anova(lm()), aov()</code>
SCM, SCE, SCT	Décomposition de la variance	Calcul manuel
Contrastes	Tester une combinaison linéaire des moyennes	Fonction personnalisée
<code>tapply</code>	Appliquer une fonction par sous-groupe	<code>tapply(var, facteur, fun)</code>

Points clés :

- L'ANOVA teste si la différence entre les moyennes des groupes est significative.
- Avant de faire une ANOVA, il faut vérifier la **normalité** dans chaque groupe.
- L'ANOVA ne permet pas de conclure à un lien de **cause à effet**.
- Les contrastes permettent de tester des hypothèses plus fines sur les moyennes.