

TP4 – ANOVA à deux facteurs et Tests Non Paramétriques

HAMLIL Mohamed

2025-01-15

Table des matières

Introduction	2
1. Simulations et ANOVA à 1 facteur	2
1.1 Principe	2
1.2 Modèle sans erreur	2
1.3 Introduction de l'erreur	3
1.4 Fonction pour automatiser	4
1.5 Exploration de l'effet de sigma	4
2. ANOVA à deux facteurs	4
2.1 Données de dureté de mèche	4
Contexte	4
Graphe d'interaction	5
2.2 Table d'ANOVA sans interaction	6
Avec interaction	7
2.3 Attention : ANOVA à un facteur seul	7
2.4 ANOVA avec interaction (données engrais)	8
ANOVA avec interaction	8
Sans interaction	9
Graphe d'interaction	9
3. Tests non paramétriques	10
3.1 Test de Wilcoxon contre Test du χ^2 – Round 1	10
Simulation des données	10
Test du χ^2	11
Test de Wilcoxon	12
Conclusion du test de Wilcoxon	12

3.2 Round 2	13
3.3 ANOVA contre tests non paramétriques (Ozone)	14
Contexte	14
ANOVA : le vent influence-t-il l’ozone ?	14
Test de normalité par groupe	15
Test de Kruskal-Wallis (alternative non paramétrique)	16
Test de corrélation de rang de Spearman	16
Résumé	17

Introduction

Ce TP couvre trois thèmes importants :

1. **Simulations et ANOVA à 1 facteur** : comprendre le comportement du test de Fisher par la simulation
2. **ANOVA à deux facteurs** : prendre en compte l’effet simultané de deux facteurs
3. **Tests non paramétriques** : alternatives quand l’hypothèse de normalité n’est pas vérifiée

1. Simulations et ANOVA à 1 facteur

1.1 Principe

Le test d’ANOVA (Fisher) teste l’égalité des moyennes entre groupes. La statistique est :

$$F_{obs} = \frac{CMM}{CME}$$

C’est un rapport entre la variance **due au modèle** et la variance **due aux erreurs**. Plus la variance de l’erreur est faible, plus on a de chances de rejeter l’égalité.

1.2 Modèle sans erreur

On suppose 3 niveaux avec 20 observations chacun et des moyennes 15, 20, 25 :

```
x = c(rep(15, 20), rep(20, 20), rep(25, 20))
a = c(rep("a", 20), rep("b", 20), rep("c", 20))
```

Si on lance une ANOVA sur ce modèle **sans erreur** :

```
anova(lm(x ~ a))
```

A anova : 2×5

	Df <int>	Sum Sq <dbl>	Mean Sq <dbl>	F value <dbl>	Pr(>F) <dbl>
a	2	1.000000e+03	5.000000e+02	1.966637e+31	0
Residuals	57	1.449174e-27	2.542411e-29	NA	NA

R donne un avertissement : *les tests F d'ANOVA sur un ajustement pratiquement parfait ne sont pas fiables*. C'est logique : sans erreur, le test n'a pas de sens !

1.3 Introduction de l'erreur

On crée un vecteur d'erreurs normales centrées réduites :

```
set.seed(42)
err = rnorm(60)
```

On ajoute l'erreur multipliée par un écart-type (commençons par 0.5) :

```
xe = x + 0.5 * err
anova(lm(xe ~ a))
```

A anova : 2×5

	Df <int>	Sum Sq <dbl>	Mean Sq <dbl>	F value <dbl>	Pr(>F) <dbl>
a	2	981.25762	490.628809	1471.204	8.849578e-50
Residuals	57	19.00882	0.333488	NA	NA

Avec un écart-type de 0.5, la p-value est très petite → rejet facile.

1.4 Fonction pour automatiser

```
anovalue = function(x, a, sigma) {  
  err = rnorm(length(x))  
  xe = x + sigma * err  
  return(anova(lm(xe ~ a))$Pr)  
}
```

1.5 Exploration de l'effet de sigma

Faisons varier la valeur de `sigma` pour voir quand la p-value passe au-dessus de 5% :

```
cat("sigma = 1 :", anovalue(x, a, 1), "\n")  
cat("sigma = 5 :", anovalue(x, a, 5), "\n")  
cat("sigma = 10 :", anovalue(x, a, 10), "\n")  
cat("sigma = 15 :", anovalue(x, a, 15), "\n")  
cat("sigma = 20 :", anovalue(x, a, 20), "\n")
```

```
sigma = 1 : 6.457851e-38 NA  
sigma = 5 : 1.401194e-09 NA  
sigma = 10 : 0.00149247 NA  
sigma = 15 : 0.04803149 NA  
sigma = 20 : 0.2232089 NA
```

Attention ! Puisque l'erreur est aléatoire, la p-value change à chaque appel. Près du seuil de 5%, relancez plusieurs fois pour observer les fluctuations.

Morale : Voilà, vous savez pondre des études bidons maintenant ! C'est une leçon sur l'importance de ne pas p-hacker ses résultats.

2. ANOVA à deux facteurs

2.1 Données de dureté de mèche

Contexte

On compare la vitesse de pénétration de **4 marques de mèches** en acier sur **5 types de dureté** d'acier. Les temps sont mesurés en secondes.

C'est une **classification à deux entrées** (mesures répétées).

```
options(OutDec = ",")
durtVit <- read.table("dureteMeche.txt", header = TRUE)
head(durtVit)
```

A data.frame : 6×3


	Y <int>	D <int>	M <int>
1	12	1	1
2	2	2	1
3	8	3	1
4	1	4	1
5	7	5	1
6	20	1	2

```
Y = durtVit$Y
D = factor(durtVit$D) # Dureté (5 niveaux)
M = factor(durtVit$M) # Mèche (4 niveaux)
```

Note : Les variables D et M sont codées avec des entiers mais ce sont bien des **variables qualitatives** (facteurs). On utilise `factor()` pour le préciser à R.

Graphes d'interaction

```
interaction.plot(M, D, Y, main = "Graphes d'interaction",
                xlab = "Mèche", ylab = "Moyenne de Y",
                col = 1:5, lwd = 2)
```



Interprétation : Les lignes ne se croisent pas vraiment → l'interaction des deux facteurs influence **peu** la variable Y.

2.2 Table d'ANOVA sans interaction

On teste l'effet de 2 facteurs **sans** leur interaction (modèle additif) :

```
summary(aov(Y ~ D + M))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
D	4	184	46,0	23,00	1,49e-05 ***
M	3	310	103,3	51,67	3,91e-07 ***
Residuals	12	24	2,0		

Signif. codes: 0 '***' 0,001 '**' 0,01 '*' 0,05 '.' 0,1 ' ' 1

Résultat : Chaque facteur influence **significativement** Y.

Avec interaction

```
summary(aov(Y ~ D * M))
```

	Df	Sum Sq	Mean Sq
D	4	184	46,0
M	3	310	103,3
D:M	12	24	2,0

```
anova(lm(Y ~ D * M))
```

A anova : 4×5

	Df <int>	Sum Sq <dbl>	Mean Sq <dbl>	F value <dbl>	Pr(>F) <dbl>
D	4	184	46,0000	NaN	NaN
M	3	310	103,3333	NaN	NaN
D:M	12	24	2,0000	NaN	NaN
Residuals	0	0	NaN	NA	NA

R renvoie un message d'erreur car il n'y a pas assez de données pour estimer l'interaction de manière fiable. Cela nous conforte dans l'idée que l'interaction n'influence pas Y.

2.3 Attention : ANOVA à un facteur seul

Il est fondamental de noter que pris séparément, un facteur ne suffit pas à expliquer Y :

```
cat("=== ANOVA Y ~ M ===\n")
summary(aov(Y ~ M))
cat("\n=== ANOVA Y ~ D ===\n")
summary(aov(Y ~ D))
```

```
=== ANOVA Y ~ M ===
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
M	3	310	103,3	7,949	0,00181 **
Residuals	16	208	13,0		

Signif. codes: 0 '***' 0,001 '**' 0,01 '*' 0,05 '.' 0,1 ' ' 1

```
=== ANOVA Y ~ D ===
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
D	4	184	46,00	2,066	0,136
Residuals	15	334	22,27		

Observation : Le facteur M semble expliquer Y seul, mais pas D. Pourtant, dans l'ANOVA à deux facteurs, les **deux** sont significatifs. C'est leur **action jointe** qui explique Y. Faire une ANOVA à un facteur sur ce jeu de données est une **mauvaise démarche**.

2.4 ANOVA avec interaction (données engrais)

Un second jeu de données avec un peu plus de données et une interaction plus marquée :

```
engrais = read.table("engraisRegion.txt", header = TRUE)
head(engrais)
Y = engrais$Y
R = factor(engrais$R)
E = factor(engrais$E)
```

A data.frame : 6×3

	Y <int>	R <int>	E <int>
1	15	1	1
2	14	1	1
3	17	1	1
4	21	2	1
5	20	2	1
6	21	2	1

ANOVA avec interaction

```
anova(lm(Y ~ R * E))
```

A anova : 4×5

	Df <int>	Sum Sq <dbl>	Mean Sq <dbl>	F value <dbl>	Pr(>F) <dbl>
R	3	327,1944444	109,0648148	112,1809524	2,954829e-14
E	2	0,8888889	0,4444444	0,4571429	6,384893e-01
R:E	6	99,5555556	16,5925926	17,0666667	1,359421e-07
Residuals	24	23,3333333	0,9722222	NA	NA

Résultat : Seul le facteur E n'explique pas significativement Y. Par contre, R et l'interaction R:E sont significatifs.

Sans interaction


```
anova(lm(Y ~ R + E))
```

A anova : 3×5

	Df <int>	Sum Sq <dbl>	Mean Sq <dbl>	F value <dbl>	Pr(>F) <dbl>
R	3	327,1944444	109,0648148	26,6252260	1,349547e-08
E	2	0,8888889	0,4444444	0,1084991	8,975301e-01
Residuals	30	122,8888889	4,0962963	NA	NA

Graphe d'interaction

```
interaction.plot(R, E, Y, main = "Graphe d'interaction (Engrais)",
                 col = 1:4, lwd = 2)
```



3. Tests non paramétriques

Les tests non paramétriques n'exigent **pas** l'hypothèse de normalité. Ils sont basés sur les **rangs** plutôt que sur les valeurs brutes.

3.1 Test de Wilcoxon contre Test du χ^2 – Round 1

Simulation des données

```
set.seed(42)
x = sample(1:100, 100, replace = TRUE)
quantile(x)
```

```
Q1 = quantile(x)[2]
Q3 = quantile(x)[4]
```

```
0% 225%
23,550%
4875%
81,25100%
100
```

On crée X (valeurs **extérieures** aux quartiles) et Y (valeurs **intérieures**) :

```
X = x[x < Q1 | x > Q3]
Y = x[x > Q1 & x < Q3]

# Ajout d'aléa pour les effectifs du test 2
X = c(X, sample(Q1:Q3, 5))
Y = c(Y, sample(1:Q1, 5), sample(Q3:100, 5))
X = sort(X)
Y = sort(Y)
```

Test du ²

On construit un tableau de contingence basé sur les quartiles :

```
table_chi = rbind(c(1, 1, 1), c(1, 1, 1))
table_chi[1, 1] = length(X[X < Q1])
table_chi[1, 2] = length(X[X > Q1 & X < Q3])
table_chi[1, 3] = length(X[X > Q3])
table_chi[2, 1] = length(Y[Y < Q1])
table_chi[2, 2] = length(Y[Y > Q1 & Y < Q3])
table_chi[2, 3] = length(Y[Y > Q3])
table_chi
```

A matrix : 2×3 of type dbl

```
25 | 4 | 25 |
5 | 50 | 4 |
```

```
chisq.test(table_chi)
```

Pearson's Chi-squared test

```
data: table_chi  
X-squared = 67,637, df = 2, p-value = 2,055e-15
```

Résultat : p-value proche de 0 $\rightarrow$ le χ^2 détecte la différence.

Test de Wilcoxon

On classe toutes les valeurs de X et Y ensemble et on calcule la somme des rangs de X :

```
matX = rbind(X, rep(1, length(X)))  
matY = rbind(Y, rep(0, length(Y)))  
matXY = cbind(matX, matY)  
mat = matXY[, order(matXY[, 1])]  
data_ranks = rbind(mat, 1:length(mat[, 1]))
```

```
rang = data_ranks[3, ]  
W = sum(rang[data_ranks[2, ] == 1])  
cat("Statistique W =", W)
```

Statistique W = 3201

Conclusion du test de Wilcoxon

L'hypothèse H_0 d'équidistribution est rejetée au seuil α si :

$$\left| W - \frac{n_X(n+1)}{2} \right| > q_{\alpha/2} \sqrt{\frac{n_X n_Y (n+1)}{12}}$$

```
U = W - length(X) * (length(X) + length(Y) + 1) / 2  
pval_wilcox = 1 - pnorm(abs(U), 0, sqrt(length(X) * length(Y) * (length(X) + length(Y) + 1) / 12))  
cat("p-value Wilcoxon =", pval_wilcox)
```

p-value Wilcoxon = 0,4754454

Résultat : Le test de Wilcoxon ne détecte pas la différence $\rightarrow$ Score : χ^2 1 - 0 Wilcoxon.

3.2 Round 2

On redécoupe la variable x différemment :

```
X2 = x[c(1:12, 25:36, 49:60, 73:84)]
Y2 = x[c(13:24, 37:48, 61:72, 85:96)]
```

Refaisons les deux tests :

```
# Test 2
table2 = rbind(c(1, 1, 1), c(1, 1, 1))
table2[1, 1] = length(X2[X2 < Q1])
table2[1, 2] = length(X2[X2 > Q1 & X2 < Q3])
table2[1, 3] = length(X2[X2 > Q3])
table2[2, 1] = length(Y2[Y2 < Q1])
table2[2, 2] = length(Y2[Y2 > Q1 & Y2 < Q3])
table2[2, 3] = length(Y2[Y2 > Q3])
chisq.test(table2)
```

Pearson's Chi-squared test

```
data: table2
X-squared = 4,6479, df = 2, p-value = 0,09788
```

```
# Test de Wilcoxon (round 2)
matX2 = rbind(X2, rep(1, length(X2)))
matY2 = rbind(Y2, rep(0, length(Y2)))
matXY2 = cbind(matX2, matY2)
mat2 = matXY2[, order(matXY2[1, ])]
data2 = rbind(mat2, 1:length(mat2[1, ]))
rang2 = data2[3, ]
W2 = sum(rang2[data2[2, ] == 1])
U2 = W2 - length(X2) * (length(X2) + length(Y2) + 1) / 2
pval2 = 1 - pnorm(abs(U2), 0, sqrt(length(X2) * length(Y2) * (length(X2) + length(Y2) + 1) / 2))
cat("p-value Wilcoxon round 2 =", pval2)
```

p-value Wilcoxon round 2 = 0,0283781

Résultat : Cette fois, c'est le Wilcoxon qui détecte → Score : **1 partout !**

Chaque test est sensible à un type différent de différence entre distributions.

3.3 ANOVA contre tests non paramétriques (Ozone)

Contexte

Étude sur la pollution de l'air : données de concentration d'ozone à Rennes durant l'été 2001. 112 observations, 13 variables.

```
ozone = read.table("ozone.txt", sep = " ", dec = ".", header = TRUE)
head(ozone)
```

A data.frame : 6 × 13

	maxO3	T9	T12	T15	Ne9	Ne12	Ne15	Vx9	Vx12	Vx15	maxO3	vent	pluie
	<int>	<dbl>	<dbl>	<dbl>	<int>	<int>	<int>	<dbl>	<dbl>	<dbl>	<int>	<chr>	<chr>
20010601	15,6	18,5	18,4	4	4	8	0,6946	-	-	-	84	Nord	Sec
20010602	17,0	18,4	17,7	5	5	7	-	-	-	-	87	Nord	Sec
20010603	15,3	17,6	19,5	2	5	4	2,9544	1,8794	0,5209	82	Est	Sec	
20010604	16,2	19,7	22,5	1	1	0	0,9848	0,3473	-	-	92	Nord	Sec
20010605	17,4	20,5	20,4	8	8	7	-	-	-	-	114	Ouest	Sec
20010606	17,7	19,8	18,3	6	6	7	-	-	-	-	94	Ouest	Pluie

```
vent = ozone$vent
maxO3 = ozone$maxO3
```

ANOVA : le vent influence-t-il l'ozone ?

```
anova(lm(maxO3 ~ vent))
```

A anova : 2 × 5

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
	<int>	<dbl>	<dbl>	<dbl>	<dbl>
vent	3	7586,057	2528,6855	3,388077	0,02073516
Residuals	108	80605,622	746,3484	NA	NA

	Sum Sq	Mean Sq	F value	Pr(>F)
Df <int>	<dbl>	<dbl>	<dbl>	<dbl>

On aurait tendance à penser que le vent influence significativement la concentration en ozone.

Test de normalité par groupe

Il est **indispensable** de vérifier la normalité pour valider l'ANOVA :

```
tapply(maxO3, vent, shapiro.test)
```

\$Est

Shapiro-Wilk normality test

data: X[[i]]

W = 0,91843, p-value = 0,344

\$Nord

Shapiro-Wilk normality test

data: X[[i]]

W = 0,87595, p-value = 0,001906

\$Ouest

Shapiro-Wilk normality test

data: X[[i]]

W = 0,7954, p-value = 6,881e-07

\$Sud

Shapiro-Wilk normality test

data: X[[i]]

W = 0,95172, p-value = 0,367

Problème : Certains échantillons ne sont **pas gaussiens** → on devrait éviter l'ANOVA !

Test de Kruskal-Wallis (alternative non paramétrique)

Le test de Kruskal-Wallis est un analogue de l'ANOVA, mais **sans hypothèse de normalité**. Il est basé sur les rangs.

```
kruskal.test(max03 ~ vent)
```

```
Kruskal-Wallis rank sum test
```

```
data: max03 by vent
```

```
Kruskal-Wallis chi-squared = 13,645, df = 3, p-value = 0,003431
```

Résultat : Même conclusion (le vent influence l'ozone), avec une p-value encore plus faible.

Test de corrélation de rang de Spearman

On se demande si la température et la composante E-O du vent à 9h sont indépendantes :

```
Vx9 = ozone$Vx9
```

```
T9 = ozone$T9
```

À la main

La statistique est le coefficient de corrélation des **rangs** :

```
Rstar = cor(rank(Vx9), rank(T9))  
cat("Corrélation de Spearman R* =", round(Rstar, 4))
```

Corrélation de Spearman R* = 0,2314

On compare $|R^*|$ au quantile $q_{0.975}$ de $\mathcal{N}(0, \sqrt{1/(n-1)})$:

```
seuil = qnorm(0.975, 0, sqrt(1 / (length(T9) - 1)))  
cat("Seuil critique =", round(seuil, 4))  
cat("\n|R*| =", round(abs(Rstar), 4))  
cat("\nRejet ?", abs(Rstar) > seuil)
```

```
Seuil critique = 0,186
|R*| = 0,2314
Rejet ? TRUE
```

Avec la fonction R

```
cor.test(Vx9, T9, method = "spearman")
```

Spearman's rank correlation rho

```
data: Vx9 and T9
S = 179954, p-value = 0,01409
alternative hypothesis: true rho is not equal to 0
sample estimates:
      rho
0,2314122
```

Conclusion : On rejette l'hypothèse de nullité de la corrélation → les variables sont **dépendantes**.

Résumé

Test	Hypothèse de normalité	Utilisation	Fonction R
ANOVA (Fisher)	Oui	Comparer les moyennes de k groupes	<code>anova(lm())</code>
Kruskal-Wallis	Non	Alternative à l'ANOVA	<code>kruskal.test()</code>
Wilcoxon	Non	Comparer 2 échantillons	Calcul manuel
χ^2 d'adéquation	Non	Comparer des distributions	<code>chisq.test()</code>
Spearman	Non	Tester l'indépendance (corrélation de rangs)	<code>cor.test(method="spearman")</code>

Points clés :

- Toujours vérifier la **normalité** avant d'utiliser l'ANOVA.
- Les tests non paramétriques sont des alternatives robustes.
- Différents tests détectent différents types de différences entre distributions.
- L'ANOVA à deux facteurs capture l'effet **conjoint** de deux facteurs, ce qu'une ANOVA à un facteur ne peut pas faire.