

Troisième année de Licence MIASHS

TP R– Statistique mathématique 3¹

Julien GREPAT²

Contents

I	Séance de TP 1	4
1	Graphiques quantile-quantile – Test de Normalité – Test du χ^2	4
1.1	QQ-plot	4
1.1.1	Quelques rappels sur le qq-plot	4
1.1.2	En pratique	4
1.1.3	Interprétation	4
1.1.4	Application	4
1.1.5	Corrigé	5
1.2	Test du χ^2 pour la normalité	6
1.3	Test du χ^2 d'indépendance	6
1.3.1	Importation	7
1.3.2	Test du χ^2 d'indépendance	7
1.4	Normalité et fonctions de R	8
1.4.1	Acquisition de <code>age</code>	8
1.4.2	Normalité de <code>age</code>	8
1.4.3	Normalité de <code>age</code> en fonction de la classe des passagers du Titanic	8
II	Séance de TP 2	9
2	Régressions linéaires (énoncé)	9
2.1	Statistiques descriptives	9
2.2	Résidus	9

¹Reproduction et diffusion interdite sans l'accord de l'auteur

²Contact : julien.grepata@univ-grenoble-alpes.fr

2.3	Somme des carrés	10
2.4	distribution de β_1	10
2.5	intervalle de confiance de β_1	11
3	Régressions linéaires (correction)	11
3.1	Statistiques descriptives	11
3.2	Résidus	12
3.3	Somme des carrés	13
3.4	distribution de β_1	13
3.5	intervalle de confiance de β_1	14
4	Tests de la régression linéaire (Commun)	14
4.1	Test de Fischer et ANOVA	14
5	Prévision (énoncé)	15
5.1	Prévision (corrigé)	15
6	Régression linéaire multiple (commun)	16
6.1	Import des données	16
6.2	Les coefficients de la régression linéaire	16
6.3	Tests statistiques	17
III	Séance de TP 3	18
7	Acquisition des données	18
8	Effet de l'abolition de la peine de mort sur le taux de meurtres (énoncé)	19
8.1	Statistiques descriptives	19
8.2	Anova	19
8.3	Retrouver les résultats du tableau	19
9	Effet de l'abolition de la peine de mort sur le taux de meurtres (corrigé)	20
9.1	Statistiques descriptives	20
9.2	Anova	21
9.3	Retrouver les résultats du tableau	21
10	Et en 2016 ?	23
11	Beignets et matière grasse	23
11.0.1	Acquisition des données	23
11.0.2	Normalité	24
11.0.3	Tableau d'ANOVA	24

11.0.4 Contrastes	24
11.1 Construction du tableau d'ANOVA	25
IV Séance de TP 4	27
12 Simulations et ANOVA à 1 facteur	27
13 Anova à deux facteurs	28
13.0.1 Table d'ANOVA sans interaction	29
13.0.2 Note : Pas d'ANOVA à un facteur sur un tel jeu de données !	30
13.0.3 Anova avec interaction	30
14 Tests non paramétriques	30
14.1 Test de Wilcoxon contre Test du χ^2 – round 1	30
14.1.1 Énoncé	30
14.1.2 Corrigé	31
14.2 Test de Wilcoxon contre Test du χ^2 – round 2	33
14.3 ANOVA contre tests non paramétriques	34

Part I

Séance de TP 1

1 Graphiques quantile-quantile – Test de Normalité – Test du χ^2

Nous proposons, dans ce TP, d'utiliser les outils de la normalité et de l'indépendance dans deux cadres :

- sur données ordonnées (nous devons reconstruire tous les outils à la main),
- sur données brutes (nous utiliserons largement les fonctions de R).

1.1 QQ-plot

1.1.1 Quelques rappels sur le qq-plot

Soit $x_1, \dots, x_n$ une série statistique. On peut chercher à savoir si la distribution des données est gaussienne ou Poisson etc... Notons F_0 la fonction de répartition de cette loi de probabilité d'intérêt. Le QQ-plot est un outil graphique permettant de visualiser rapidement l'adéquation de la distribution d'une série numérique à une distribution de référence. Dans ce graphe, on reporte sur l'axe des ordonnées les fractiles correspondant à la distribution observée et sur l'axe des abscisses ceux correspondant à la distribution théorique.

1.1.2 En pratique

Dans le cas d'une variable quantitative dont les valeurs sont regroupées par modalités. Soient $m_1, \dots, m_J$ les modalités de la série $x_1, \dots, x_n$ que l'on appellera quantiles observés ($q_i = m_i$). On a alors

Modalités ordonnées, quantiles observés	$q_1 = m_1$	$\dots$	$q_J = m_J$
Fréquences cumulées	F_1	$\dots$	F_J
Quantiles théoriques	$q_1^* = F_0^{-1}(F_1)$	$\dots$	$q_J^* = F_0^{-1}(F_J)$

Il reste à tracer le nuage de points $(q_i^*; q_i)_i$.

Note : Les quantiles théoriques d'une loi normale $q_J^* = F_0^{-1}(F_J)$ sont accessibles sur R via `qnorm( $F_J, m, \sigma$ )`.

1.1.3 Interprétation

Plus les points sont alignés sur la diagonale, plus l'adéquation de la loi théorique avec la loi observée est forte.

1.1.4 Application

Dans son château, l'abominable Xantane a deux passions, la torture et manger des chatons. Au lycée, il a appris qu'en empilant des disques de zinc, de cuivre et des cotons démaquillants imbibés d'eau salée, il pouvait créer une pile électrique. Chaque empilement lui fait gagner 1V de tension sur sa pile. Xantane ne sait pas comment transformer le courant continu en alternatif puisqu'il était trop occupé à endormir des chatons à l'éther pour les manger ensuite au lieu de suivre le cours en question. Il a donc acheté

une espèce de grande roue de hamster qui fait tourner un alternateur. Il a glissé son fidèle serviteur, le gluant Guar, à l'intérieur et le motive avec les décharges électriques générées par sa pile. Soucieux du bien-être de son personnel, Xantane a relevé 500 fois les tensions (x_i) de la pile nécessaires pour que Guar fasse tourner la roue assez vite pour que la tension de l'alternateur soit suffisante et stable pour que la télévision fonctionne correctement. Xantane souhaiterait savoir si ces tensions sont réparties selon une loi Gaussienne (Xantane aimait bien sa prof de maths de terminale mais elle aimait les chatons vivants).

x_i	92	93	94	95	96	97	98	99	100	101	102	103	104	105	106	107	108	109
n_i	1	4	9	28	23	37	51	63	65	60	48	38	32	23	12	3	1	2

- Estimer m et σ les moyenne et écart-type de la série x .
- On souhaite savoir si cette série est proche d'une loi Gaussienne de moyenne m et écart-type σ . Tracer le QQ-plot et conclure.

1.1.5 Corrigé

- Saisie des q_i :

```
qi=92:109
```

- Saisie des effectifs :

```
ni=c(1,4,9,28,23,37,51,63,65,60,48,38,32,23,12,3,1,2)
```

- Calcul de la moyenne pondérée :

```
m=sum(qi*ni)/sum(ni),
```

On obtient $m = 100$.

- Calcul de l'écart-type pondéré :

```
sigma=sqrt(sum(ni*(qi-m)^2)/(sum(ni)-1)),
```

l'écart-type vaut environ 3.1.

- **On observe l'adéquation avec une loi Normale $\mathcal{N}(m, \sigma)$.**
- Calcul des fréquences cumulée :

```
Fi=cumsum(ni)/sum(ni).
```

- Quantiles théoriques de la loi normale :

```
qiетоile=qnorm(Fi,m,sigma)
```

- On trace le qqplot

```
plot(qi,qiетоile)
```

- On ajoute la diagonale :

```
lines(c(90,110),c(90,110))
```

Note. Puisque nous ne disposons pas des données brutes, nous ne pouvons pas utiliser les fonctions de R pour le qq-plot.

1.2 Test du χ^2 pour la normalité

Puisque nous ne disposons pas des données brutes, nous n'avons pas la possibilité de faire un test de Shapiro–Wilk avec les fonctions prédéfinies de R. Faisons le test du χ^2 pour conclure sur l'adéquation à la loi théorique précédente.

On rappelle que nous disposons des valeurs x_i dans `qi` et des effectifs dans `ni`.

- (i) On fusionne les 2 premiers effectifs et les 3 derniers pour obtenir des effectifs plus grands que 5

```
ni2=c(ni[1]+ni[2],ni[3:15],ni[16]+ni[17]+ni[18])
```

- (ii) On calcule les probabilités théoriques `pi` et les effectifs théoriques `ti` en faisant la correction de continuité et en fusionnant les modalités (afficher `k` et `K` pour s'en persuader)

```
k=c(91,93:106)+0.5
K=c(93:106.5,109)+0.5
pi=(pnorm(K,100,3.1)-pnorm(k,100,3.1))
ti=500*pi
```

- (iii) On calcule la statistique du χ^2

```
dchi=sum((ni2-ti)^2/ti)
```

On peut également utiliser le test du χ^2

```
chisq.test(ni2,p=pi)
```

en notant qu'il faut spécifier le fait qu'on cherche une adéquation à une loi de probabilité.

- (iv) On note que les degrés de libertés valent $15-1-2=12$ (car nous avons déterminé deux paramètres m et σ). Or le test `chisq.test()` n'utilise pas les bons d.d.l et donne donc une p-value erronée. On pourra donc chercher le quantile théorique 0.95 `qchisq(0.95,12)` et conclure au non rejet de l'hypothèse d'adéquation au seuil 5%. Ou calculer la p-value `1-pchisq(dchi,12)` qui amène à la même conclusion.

Note. On rappelle que si $K \sim \chi^2(12)$ alors la p-valeur associée au test du Chi-deux d'adéquation à une loi est $P(K \geq \text{dchi})$.

1.3 Test du χ^2 d'indépendance

Le fichier “titanic.csv” contient le registre des passagers du Titanic avec leur survie ou non au naufrage et, entre autre, la classe.

L'objectif est d'étudier la relation entre ces deux variables qualitatives. Nous allons pour cela effectuer des tests d'indépendance de Chi-deux.

1.3.1 Importation

Télécharger ce fichier. Notons qu'il est dans un format anglo-saxon et qu'il suffira d'utiliser la fonction `read.csv()` sans paramètre supplémentaire pour l'importer. Effectuons l'importation de ce fichier dans la variable `titanic`. (Ne pas oublier de changer le répertoire de courant... dans `Fichier` et de sélectionner le dossier dans lequel le fichier `.csv` a été enregistré.)

```
titanic=read.csv("titanic.csv")
```

La fonction `head()` permet d'obtenir un aperçu du `dataframe`

```
head(titanic)
```

On peut stocker les variables `survived` et `class`

```
survived=titanic$Survived  
head(survived)  
class=titanic$Pclass  
head(class)
```

Note. Toujours utiliser la fonction `head()` pour observer que l'acquisition est correctement faite

1.3.2 Test du χ^2 d'indépendance

Éditons le tableau de contingence des variables `survived` et `class`.

```
contingence1=table(survived,class)
```

que l'on peut afficher

```
contingence1
```

Concluons quant à la dépendance entre la classe et la survie grâce au test du χ^2 d'indépendance

```
chisq.test(contingence1)
```

Puisque la p-value est inférieure à 0,05 (elle est même presque égale à 0), on conclut qu'on rejette significativement l'hypothèse nulle et on considère les variables comme dépendantes. *Malheureusement, on le savait.*

On vous invite à vérifier la dépendance de

- `survived` et `sex`
- `class` est `embarked`
- `survived` et `embarked`

Note. Dans ce dernier cas, on observe un effectif inférieur à 5 pour ceux dont la porte d'embarquement n'est pas connue.

```
contingence2=table(class,embarked)  
contingence2
```

On peut se débarrasser de la première colonne avec l'indice négatif

```
contingence2=contingence2[,-1]
```

1.4 Normalité et fonctions de R

1.4.1 Acquisition de age

On peut acquérir, dans `titanic`, la variable `Age`

```
age=titanic$Age  
head(age)
```

Notons que, dès la sixième valeur, certains âges sont “non acquis”. Cela va poser problème pour ce qu’on veut faire. La fonction `is.na` identifie les valeurs NA avec la valeur logique `TRUE`. Gardons les âges connus.

```
age=age[!is.na(age)]
```

Associions les valeurs de la variable `class` associée.

```
class2=class[!is.na(titanic$Age)]
```

1.4.2 Normalité de age

Traçons la densité de la variable `age`

```
plot(density(age))
```

et le qq-plot

```
qqnorm(age)
```

Cette variable n’a pas l’air très normale. Sans surprise le test de Shapiro-Wilk,

```
shapiro.test(age)
```

rejette la normalité avec une p-value inférieure largement à 5%.

1.4.3 Normalité de age en fonction de la classe des passagers du Titanic

La fonction `tapply` permet d’effectuer une fonction (ici `shapiro.test()`) à une variable (ici `age`) divisée sur les sous-groupes donnés par les valeurs d’une autre variable (ici `class`). Nous allons donc tester la normalité de l’âge sur les 1ere, 2eme et 3eme classe.

```
tapply(age,class2,shapiro.test)
```

On observe que seul en première classe, l’âge peut être considéré comme normal.

Reste à savoir si cette information est vraiment intéressante...

Part II

Séance de TP 2

2 Régressions linéaires (énoncé)

Dans ce TP, on vous propose de travailler en partie par vous même. Vous verrez souvent une partie **énoncé** dont le **corrigé** est disponible à la suite et contient tous les codes. Vous pouvez vous en servir directement comme énoncé si vous préférez. Certaines partie **communes** sortent de ce système et doivent être traitée quelque-soit la façon de travailler choisie.

On va étudier la relation entre la tension artérielle et l'âge des individus. Les données ont été simulées à partir de *BOUYER et al. (1995) Epidemiologie. Principes et méthodes quantitatives, Les éditions INSERM.*

On va utiliser le fichier `tension.csv` qui contient le relevé de la tension des individus et de leur âge. Notre objectif est de déterminer si l'âge a une influence sur la tension artérielle et éventuellement de prédire la tension en fonction de l'âge.

2.1 Statistiques descriptives

- (i) Quelle est la variable explicative (indépendante) et la variable à expliquer (dépendante) ?
- (ii) Télécharger le fichier `tension.csv` et stocker les variable dans `x` et `y`.
- (iii) Tracer le nuage de points et commenter.
- (iv) Calculer le coefficient de corrélation linéaire avec la fonction `cor`. Sa valeur confirme la réponse à la question précédente.
- (v) Calculer les estimation `beta1` et `beta0` des coefficients de la droite de régression tels que $y = \hat{\beta}_1 x + \hat{\beta}_0$ par la méthode des moindres carrés.
- (vi) On peut vérifier que ces coefficients sont accessibles par la fonction

`lm(y~x)`

- (vii) Utiliser la fonction `abline` pour tracer la droite de régression.

2.2 Résidus

- (i) On peut calculer les valeurs ajustées et les erreurs :

`yajust=beta1*x+beta0`
`erreurs=y-yajust`

.

- (ii) La fonction `lm` permet d'effectuer directement ce que nous avons fait :

```
lm(y~x)
model=lm(y~x)
beta0=model$coefficients[1]
beta1=model$coefficients[2]
yajustes=model$fitted.values
erreurs=model$residuals
```

- (iii) Représenter les résidus (erreurs) en fonction des valeurs ajustées.
- (iv) Voit-on une structure particulière des résidus ?
- (v) Tracer la densité des résidus et la comparer à la densité de la gaussienne.
- (vi) Tracer le qq-plot des résidus. Tester leur normalité avec le test de Shapiro–Wilk.

2.3 Somme des carrés

- (i) Calculer les sommes des carrés nommées dans le cours

```
SCE, SCT, SCM
```

- (ii) Vérifier que $SCT = SCM + SCE$.
- (iii) Calculer le coefficient de détermination et vérifie qu'il est égal au carré du coefficient de corrélation.

2.4 distribution de β_1

- (i) On se propose de simuler cent séries X et Y du même modèle pour voir comment varie $\hat{\beta}_1$. On simulera 30000 valeur de X selon une loi uniforme discrète sur $[40; 56]$ que l'on découpe en 100 échantillons :

```
age=sample(40:56,replace=TRUE,30000)
simx=matrix(age,nrow=100)
```

et 30000 erreurs de loi normale centrée et de variance $SCE/(n - 2)$ que l'on découpe en 100 échantillons :

```
err=rnorm(30000,0,sqrt(SCE/(length(x)-2)))
simerr=matrix(err,nrow=100)
```

On simule `simy`

```
simy=beta1*simx+beta0+simerr
```

- (ii) Calculer les valeurs des estimations de β_1 sur chaque échantillon.
- (iii) Comparer la distribution des simulations de $(\beta_1 - \bar{\beta}_1)/\sigma_{\beta_1}$, avec la loi de Student à $n - 2$ d.d.l.

2.5 intervalle de confiance de β_1

On rappelle l'intervalle de confiance à 95% pour β_1 :

$$\hat{\beta}_1 + t_{n-2;0,025}\hat{\sigma}_{\beta_1} \leq \beta_1 \leq \hat{\beta}_1 - t_{n-2;0,025}\hat{\sigma}_{\beta_1}.$$

- (i) Calculer les bornes de cet intervalle.
- (ii) Chercher les valeurs de `simbeta` en dehors de cet intervalle.

On peut s'attendre à voir apparaître cinq valeurs. Sinon, on peut avancer un élément de doute : la machine a du mal à produire des tirages totalement indépendants. Il faut bien avoir conscience que l'aléa et l'indépendance sont des choses compliquées dans l'électronique.

3 Régressions linéaires (correction)

On va utiliser le fichier `tension.csv` qui contient le relevé de la tension des individus et de leur âge. Notre objectif est de déterminer si l'âge a une influence sur la tension artérielle et éventuellement de prédire la tension en fonction de l'âge.

3.1 Statistiques descriptives

- (i) Quelle est la variable explicative (indépendante) et la variable à expliquer (dépendante) ?

Réponse : Variable explicative : âge ; variable expliquée : tension

- (ii) Télécharger le fichier `tension.csv` et stocker les variable dans `x` et `y`.

```
data=read.csv("tension.csv",header =TRUE,sep=";",dec=",")
head(data)
x=data$age
y=data$tension
head(x)
head(y)
```

- (iii) Tracer le nuage de points et commenter.

```
plot(x,y) .
```

Réponse : Le nuage est relativement rectiligne, la régression linéaire a du sens, elle donnera une tendance moyennement précise de `y` en fonction de `x`.

- (iv) Calculer le coefficient de corrélation linéaire avec la fonction `cor` :

```
cor(x,y) .
```

Sa valeur confirme la réponse à la question précédente.

- (v) Calculer les estimation `beta1` et `beta0` des coefficients de la droite de régression tels que $y = \hat{\beta}_1 x + \hat{\beta}_0$ par la méthode des moindres carrés.

```
beta1=cov(x,y)/var(x)
beta0=mean(y)-beta1*mean(x) .
```

(vi) On peut vérifier que ces coefficients sont accessibles par la fonction

```
lm(y~x)
```

(vii) On utilise la fonction `abline` pour tracer la droite de régression :

```
abline(beta0,beta1,col="red")
```

3.2 Résidus

(i) On peut calculer les valeurs ajustées et les erreurs :

```
yajust=beta1*x+beta0  
erreurs=y-yajust
```

(ii) La fonction `lm` permet d'effectuer directement ce que nous avons fait :

```
lm(y~x)  
model=lm(y~x)  
beta0=model$coefficients[1]  
beta1=model$coefficients[2]  
yajustes=model$fitted.values  
erreurs=model$residuals
```

(iii) Représenter les résidus (erreurs) en fonction des valeurs ajustées.

```
plot(yajust,erreurs)
```

(iv) Voit-on une structure particulière des résidus ?

Réponse : Il ne semble pas y avoir de structure particulière des erreurs car dans une régression linéaire on a une hypothèse : les erreurs sont distribuées selon une loi normale $\mathcal{N}(0, \sigma)$ et sont indépendantes de la variable explicative.

(v) On peut observer la densité des résidus

```
plot(density(erreurs))
```

et la comparer à la densité de la gaussienne

```
discr=-15:15  
norm=dnorm(discr,0,sqrt(var(erreurs)))  
plot(discr,norm)
```

(vi) Pour le tracé du qq-plot :

```
qqnorm(erreurs)
```

Il y a peu de doutes sur la normalité des résidus. Effectuons le test de Shapiro–Wilk

```
shapiro.test(erreurs)
```

Avec une p-value supérieure à 5%, on ne rejette pas la normalité.

3.3 Somme des carrés

- (i) On calcule les sommes des carrés

```
SCE=sum(erreurs^ 2)
SCT=sum((y-mean(y))^ 2)
SCM=sum((yajust-mean(y))^ 2)
```

- (ii) On peut vérifier que $SCT = SCM + SCE$.
(iii) On calcule le coefficient détermination

```
SCM/SCT
```

et on vérifie qu'il est égal au carré du coefficient de corrélation

```
cor(x,y)^ 2
```

3.4 distribution de β_1

- (i) On se propose de simuler cent séries X et Y du même modèle pour voir comment varie $\hat{\beta}_1$. On simulera 30000 valeur de X selon une loi uniforme discrète sur $[40;56]$ que l'on découpe en 100 échantillons :

```
age=sample(40:56,replace=TRUE,30000)
simx=matrix(age,nrow=100)
```

et 30000 erreurs de loi normale centrée et de variance $SCE/(n-2)$ que l'on découpe en 100 échantillons :

```
err=rnorm(30000,0,sqrt(SCE/(length(x)-2)))
simerr=matrix(err,nrow=100)
```

On simule `simy`

```
simy=beta1*simx+beta0+simerr
```

- (ii) On calcule les valeurs des estimations de β_1 sur chaque échantillon

```
simbeta=1:100
for (i in 1:100){
  simbeta[i]=cov(simx[i,],simy[i,])/var(simx[i,])
}
```

- (iii) On peut comparer la distribution des simulations de $(\beta_1 - \bar{\beta}_1)/\sigma_{\beta_1}$, avec la loi de Student à $n-2$ d.d.l.

```
plot(density((simbeta-mean(simbeta))/sqrt(var(simbeta))))
discr=seq(-3,3,0.1)
lines(discr,dt(discr,298))
```

3.5 intervalle de confiance de β_1

On rappelle l'intervalle de confiance à 95% pour β_1 :

$$\hat{\beta}_1 + t_{n-2;0,025}\hat{\sigma}_{\beta_1} \leq \beta_1 \leq \hat{\beta}_1 - t_{n-2;0,025}\hat{\sigma}_{\beta_1}.$$

- (i) Calculer les bornes de cet intervalle.

```
sbeta1=sqrt(SCE/(398*sum((x-bar(x))^2)))
binf=beta1+qt(0.025,298)*sbeta1
bsup=beta1+qt(0.975,298)*sbeta1
```

- (ii) Chercher les valeurs de `simbeta` en dehors de cet intervalle.

```
simbeta[simbeta>bsup|simbeta<binf]
```

On peut s'attendre à voir apparaître cinq valeurs. Sinon, on peut avancer un élément de doute : la machine a du mal à produire des tirages totalement indépendants. Il faut bien avoir conscience que l'aléa et l'indépendance sont des choses compliquées dans l'électronique.

4 Tests de la régression linéaire (Commun)

4.1 Test de Fischer et ANOVA

On a vu que le coefficient d'amélioration était en dessous de 0,8 et ainsi, le modèle explique moins de 80% de la variance de Y . Pour autant, il faut se poser la question de si X explique significativement la variable Y ce qui équivaut à exclure l'hypothèse que β_1 vaut zéro. C'est cette hypothèse que nous testons dans les lignes à venir.

- (i) On peut demander le tableau d'ANOVA de deux façons :

```
anova(lm(y~x))
```

ou

```
summary(aov(y~x))
```

On observe que le p-value ($\Pr(>F)$) est proche de zéro, on rejette la nullité de β_1 . La variable X explique la variable Y significativement.

- (ii) On peut retrouver SCE et SCM dans les éléments de ce tableau d'ANOVA.
(iii) On rappelle que la variable du test est $SCM/(SCE/298)$.

```
F=298*SCM/SCE
```

On la retrouve dans le tableau d'ANOVA.

- (iv) On peut faire le test *à la main*, la p-value est suffisamment faible pour oser un test à 5% et comparer F à `qf(0.95,1,298)`. Avec cette méthode, on rejette également l'hypothèse de nullité.
(v) On peut retrouver (ou presque) la p-value :

```
1-pf(876.3,1,298)
```

(vi) On peut enfin obtenir un résumé de l'ANOVA en bas de

```
summary(lm(y~x))
```

On y voit d'ailleurs le résultat du test de Student, dont la valeur de la variable de test 29,60 prise au carré est égale à la valeur de la variable du test de Fisher (normal connaissant le cours !). Il est donc tout à fait normal d'obtenir la même p-value et de conclure au même résultat.

5 Prévision (énoncé)

On peut prévoir la tension artérielle d'un homme de 50 ans. On souhaite surtout (vu le coefficient de détermination) un intervalle de confiance à 95%. On rappelle que la formule des bornes de cet intervalle est est :

$$\hat{Y}_0 \pm t_{n-2;0.05/2} \sqrt{s_\epsilon^2 \left(1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum (X_i - \bar{X})^2} \right)}.$$

(i) Rappelons l'estimation de s_ϵ^2 :

```
se2=SCE/298
```

(ii) Faire la prévision de $\hat{Y}_0$:

(iii) Calculer les bornes de l'intervalle.

(iv) (Re-)tracer le nuage de point et représenter l'intervalle.

(v) Tracer tous les intervalles de confiance autour de la droite de régression (avec une boucle et en reprenant le code précédent).

5.1 Prévision (corrigé)

On peut prévoir la tension artérielle d'un homme de 50 ans. On souhaite surtout (vu le coefficient de détermination) un intervalle de confiance à 95%. On rappelle que la formule des bornes de cet intervalle est est :

$$\hat{Y}_0 \pm t_{n-2;0.05/2} \sqrt{s_\epsilon^2 \left(1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum (X_i - \bar{X})^2} \right)}.$$

(i) Rappelons l'estimation de s_ϵ^2 :

```
se2=SCE/298
```

(ii) On fait la prévision de $\hat{Y}_0$:

```
Y0=beta1*50+beta0
```

(iii) On calcule les bornes de l'intervalle

```
bsup=Y0+qt(0.975,298)*sqrt(se2*(1+1/300+((50-mean(x))^2)/(sum((x-mean(x))^2))))
binf=Y0-qt(0.975,298)*sqrt(se2*(1+1/300+((50-mean(x))^2)/(sum((x-mean(x))^2))))
```

(iv) On (re-)trace le nuage de point et on représente l'intervalle

```
plot(x,y)
abline(beta0,beta1)
lines(c(50,50),c(binf,bsup),lwd=3)
```

(v) Tracé des intervalles de confiance autour de la droite de régression

```
plot(x,y)
discr=40:56
predicted=beta1*discr+beta0
bsup=predicted+qt(0.975,298)*sqrt(se2*(1+1/300+((discr-mean(x))^2)/(sum((x-mean(x))^2))))
binf=predicted-qt(0.975,298)*sqrt(se2*(1+1/300+((discr-mean(x))^2)/(sum((x-mean(x))^2))))
for(i in 1:length(discr)){
  lines(c(discr[i],discr[i]),c(binf[i],bsup[i]),lwd=3)}
```

6 Régression linéaire multiple (commun)

Pour mesurer les performances auditives d'un individu, on le soumet à un signal sonore d'une fréquence donnée dont l'intensité va croissante. On note alors le seuil à partir duquel le signal est perçu. Ce seuil, exprimé en décibel, mesure la performance d'audition à partir du seuil moyen. Ainsi, un seuil haut correspond à un trouble de l'audition pour la fréquence.

Les données représentent les mesures obtenues pour quatre fréquences (500Hz, 1000Hz, 2000Hz et 4000Hz). On prendra le seuil maximal pour l'oreille gauche et l'oreille droite pour 1000 personnes de plus de 39 ans. On ajoutera la donnée *globale* qui est une auto-évaluation par le patient.

Le tableau `audition2.csv` donne les valeurs des 1000 relevés auditifs.

L'enjeu est de prédire *globale* par les variables *A5*, *A10*, *A20*, *A40* et de savoir si le patient peut prédire lui-même l'état de son audition.

6.1 Import des données

Importons les données et stockons les dans les variables du même nom.

```
audition=read.csv2("audition2.csv")
A5=audition$A5
A10=audition$A10
A20=audition$A20
A40=audition$A40
globale=audition$globale
```

6.2 Les coefficients de la régression linéaire

Donner l'équation de la régression linéaire multiple et discuter de l'effet des variables explicatives sur la variable expliquée.

```
> lm(globale~A5+A10+A20+A40)

Call:
lm(formula = globale ~ A5 + A10 + A20 + A40)

Coefficients:
(Intercept)          A5          A10          A20          A40
    4.1423      0.7082      0.8602      0.6355      0.5106
```

Ainsi, on peut lier les variables par l'équation

$$globale = 4,14 + 0,7A5 + 0,86A10 + 0,64A20 + 0,51A40.$$

On voit que le niveau d'audition globale évalué par le sujet augmente quand chaque seuil augmente avec sensiblement la même importance.

6.3 Tests statistiques

Faire les tests statistiques classiques de la régression linéaire et conclure.

```
> summary(lm(globale~A5+A10+A20+A40))

Call:
lm(formula = globale ~ A5 + A10 + A20 + A40)

Residuals:
    Min       1Q   Median       3Q      Max
-1.63918 -0.19985  0.04163  0.27016  0.72287

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   4.14226     0.01274   325.10  <2e-16 ***
A5             0.70820     0.01808    39.17  <2e-16 ***
A10            0.86024     0.01948    44.17  <2e-16 ***
A20            0.63553     0.01439    44.17  <2e-16 ***
A40            0.51059     0.01333    38.30  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3613 on 995 degrees of freedom
Multiple R-squared:  0.9653,    Adjusted R-squared:  0.9651
F-statistic: 6911 on 4 and 995 DF,  p-value: < 2.2e-16
```

- Le test de Fisher (ANOVA), donné dans la dernière ligne du résumé, montre que, dans leur globalité, les variables explicatives ont un effet significatif sur **globale**.
- Tous les tests de Student amènent à dire que les coefficients de la régression linéaire multiple sont significativement non nuls. Chaque variable explique significativement la variable **globale**.
- De plus, le coefficient R^2 vaut 0,97. Ainsi, 97% de la variance de **globale** est expliquée par le modèle linéaire. Ainsi, il semble que la prévision soit proche de l'évaluation par le sujet. On peut penser qu'il a une évaluation lucide de son état d'audition.

Part III

Séance de TP 3

Le but de l'étude statistique de cette séance est de s'éclairer sur le lien potentiel entre abolition de la peine de mort et taux de criminalité.

En annexe 1, on trouvera des données issues du site du FBI. Elle donnent le nombre de meurtres dans les différents états des États Unis en 2009 ainsi que la population.

Afin de s'affranchir des différences de tailles de populations dans chaque état, nous contruisons le taux de criminalité pour 1 000 habitants.

À partir des colonnes 2 et 3 de l'annexe, nous avons calculé la variable **Nombre de meurtres pour 1000 hab** en divisant terme à terme **Total murder** par **population**.

7 Acquisition des données

Enregistrer le fichier **murderusa.csv** et sélectionner le dossier dans lequel il est enregistré comme répertoire de travail dans R (Fichier => changer le répertoire courant).

```
data=read.csv2("murderusa.csv").
```

Affectons les variables **txcrime09** et **PDMabolie09** dans notre environnement R.

```
txcrime09=data$tauxmeurtres  
PDMabolie09=data$PDMabolie09
```

Nous allons créer deux variables **abolie09** et **nonabolie09** contenant la liste des taux de criminalité dans les états ayant aboli la peine de mort dans la première liste et les taux de criminalité dans les états n'ayant pas aboli la peine de mort dans la seconde.

- Pour **abolie09**, on ne garde que les valeurs de **txcrime09** pour lesquelles la **PDMabolie09** vaut "oui"

```
abolie09=txcrime09[PDMabolie09=="oui"]
```

- Pour **nonabolie09**, on ne garde que les valeurs de **txcrime09** pour lesquelles la **PDMabolie09** vaut "non"

```
nonabolie09=txcrime09[PDMabolie09=="non"]
```

- Il se peut qu'on soit passé en chaîne de caractères, nous devons réassigner des valeurs numériques

```
abolie09=as.numeric(abolie09)  
nonabolie09=as.numeric(nonabolie09)
```

8 Effet de l'abolition de la peine de mort sur le taux de meurtres (énoncé)

8.1 Statistiques descriptives

- (i) Tracer les boîtes de distribution de deux séries `abolie09` et `nonabolie09` côte à côte.
Que peut-on déduire de ce graphe ?
- (ii) Calculer les moyennes de `abolie09` et `nonabolie09`. Comparer. Que peut-on en conclure ?
- (iii) Peut-on déduire un lien de cause à effet avec ce type d'étude ?

8.2 Anova

On peut se demander si la différence entre les valeurs est significative en fonction de l'abolition ou non de la peine de mort et donc, si ce paramètre a un effet significatif sur le taux de mortalité. Pour cela, on va faire un tableau d'ANOVA.

```
summary(aov(txcrime09~PDMabolie09))
```

On peut également obtenir ce tableau par

```
anova(lm(txcrime09~PDMabolie09))
```

en remarquant que le modèle d'ANOVA reste un modèle linéaire.

Observer la p -value et conclure sur un lien significatif entre abolition de la peine de mort et taux de criminalité.

8.3 Retrouver les résultats du tableau

- (i) Calculer SCM. On rappelle la quantité SCM (somme des carrés due au modèle),

$$SCM = \sum_{i=1}^2 n_i (\bar{X}_i - \bar{X})^2.$$

- (ii) Calculer SCE. On rappelle la quantité SCE (somme des carrés des écarts)

$$SCE = \sum_{i=1}^2 \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2.$$

- (iii) La variable du test est

$$F_{obs} = \frac{SCM/(2-1)}{SCE/(50-2)}.$$

Calculer F_{obs} . La variable du test suit une loi de Fisher. Préciser les degrés de liberté et calculer la p -value.

9 Effet de l'abolition de la peine de mort sur le taux de meurtres (corrigé)

9.1 Statistiques descriptives


On va tracer les boîtes de distribution des deux séries `abolie09` et `nonabolie09` côte à côte pour avoir une meilleure vision de leur distribution.

```
boxplot(abolie09,nonabolie09,main="Taux de criminalité",col=c("orange","red"),
names=c("abolie09","nonabolie09")).
```

On peut également demander directement

```
boxplot(txcrime09~PDMabolie09).
```

Il est très intéressant de tracer le boxplot qu'on reproduit ci-dessous.



On voit alors que tous les indicateurs (médiane, quartiles...) sont plus bas dans les états ayant aboli la peine de mort. On en déduit que globalement, le taux de criminalité est plus bas dans les états ayant aboli la peine de mort.

On peut en déduire qu'en moyenne, il y a un taux de criminalité plus élevé dans les états n'ayant pas aboli la peine de mort.

On restera prudent sur le fait qu'avec des statistiques descriptives élémentaires, aucun lien de cause à effet ne peut être dégagé (est-ce l'abolition qui fait baisser le taux de criminalité, est-ce un taux de criminalité bas qui permet d'abolir, est-ce qu'il n'y a aucun lien ?).

On peut néanmoins se permettre d'affirmer que l'abolition de la peine de mort ne fait pas exploser le taux de criminalité, sinon, ce serait visible sur ce graphique.

9.2 Anova

On peut se demander si la différence entre les valeurs est significative en fonction de l'abolition ou non de la peine de mort et donc, si ce paramètre a un effet significatif sur le taux de mortalité. Pour cela, on va faire un tableau d'ANOVA.

```
summary(aov(txcrime09~PDMabolie09))
```

On peut également obtenir ce tableau par

```
anova(lm(txcrime09~PDMabolie09))
```

en remarquant que le modèle d'ANOVA reste un modèle linéaire.

On s'aperçoit que la p -value est trop grande pour rejeter l'égalité des moyennes des deux groupes. Il vient qu'on ne peut pas affirmer qu'il y a un lien significatif entre abolition de la peine de mort et taux de criminalité.

9.3 Retrouver les résultats du tableau

- (i) Rappelons la quantité SCM (somme des carrés due au modèle),

$$SCM = \sum_{i=1}^2 n_i (\bar{X}_i - \bar{X})^2.$$

On peut calculer

```
SCM= length(abolie09)*(mean(abolie09)-mean(txcrime09))^2  
+ length(nonabolie09)*(mean(nonabolie09)-mean(txcrime09))^2
```

- (ii) Rappelons la quantité SCE (somme des carrés des écarts)

$$SCE = \sum_{i=1}^2 \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2.$$

On peut calculer

```
SCE= sum((abolie09-mean(abolie09))^2)  
+ sum((nonabolie09-mean(nonabolie09))^2)
```

- (iii) La variable du test est

$$F_{obs} = \frac{SCM/(2-1)}{SCE/(50-2)}.$$

On calcule

```
Fobs=SCM/(SCE/48)
```

- (iv) La variable du test suit une loi de Fisher $\mathcal{F}_{1,48}$. On calcule la p -value :

```
1-pf(Fobs,1,48)
```

Annexe 1

State	Population (en milliers)	Total murders (2009)	Nombre de meutres pour 1000 habitants	Peine de Mort abolie en 2009
Vermont	622	7	0,011	oui
Iowa	3 008	34	0,011	oui
Minnesota	5 266	72	0,014	oui
North Dakota	647	9	0,014	oui
Hawaii	1 295	21	0,016	oui
Maine	1 318	26	0,020	oui
Wisconsin	5 655	144	0,025	oui
Rhode Island	1 053	31	0,029	oui
Alaska	698	22	0,031	oui
New Jersey	8 708	319	0,037	oui
West Virginia	1 820	76	0,042	oui
Michigan	9 970	625	0,063	oui
New Mexico	2 010	144	0,072	oui
Florida	18 538			
New Hampshire	1 325	10	0,008	
Utah	2 785	37	0,013	
South Dakota	812	11	0,014	
Idaho	1 546	22	0,014	
Wyoming	544	11	0,020	
Oregon	3 826	83	0,022	
Nebraska	1 797	40	0,022	
Washington	6 664	169	0,025	
Massachusetts	6 594	169	0,026	
Montana	975	28	0,029	
Connecticut	3 518	107	0,030	
Colorado	5 025	167	0,033	
Illinois	12 910	479	0,037	
Kentucky	4 314	170	0,039	
New York	19 541	779	0,040	
Kansas	2 819	118	0,042	
Ohio	11 543	502	0,043	
Virginia	7 883	347	0,044	
Indiana	6 423	293	0,046	
Delaware	885	41	0,046	
Arizona	6 596	328	0,050	
Mississippi	2 952	151	0,051	
North Carolina	9 381	480	0,051	
Pennsylvania	12 605	658	0,052	
California	36 962	1 972	0,053	
Texas	24 782	1 325	0,053	
Georgia	9 829	543	0,055	
Nevada	2 643	156	0,059	
Arkansas	2 889	171	0,059	
Oklahoma	3 687	225	0,061	
South Carolina	4 561	286	0,063	
Missouri	5 988	381	0,064	
Alabama	4 709	318	0,068	
Tennessee	6 296	461	0,073	
Maryland	5 699	438	0,077	
Louisiana	4 492	486	0,108	
District of Columbia	600	144	0,240	

10 Et en 2016 ?

Pour rappel, nous avons montré des résultats similaires en 2016 en L2.

11 Beignets et matière grasse

Nous utilisons des données vues en cours. Il s'agit de la variable "quantité de matière grasse" absorbée par des beignets durant leur cuisson. En effet, pendant leur cuisson les beignets absorbent de la matière grasse en quantité variable.

- La quantité absorbée dépend de la matière grasse utilisée.
- Pour chacune des quatre matières grasses, on a constitué six fournées de 24 beignets chacune.
- Les données : les quantités de matière grasse absorbées, par fournée.
- On a simplifié les calculs en leur soustrayant 100 g. Les données de ce genre constituent une classification à une seule entrée, ou à une seule voie ou classification simple, on dit aussi à un (seul) facteur, chaque matière grasse représentant une classe, ou niveau du facteur.

11.0.1 Acquisition des données

- (i) On peut commencer par vider R de son archive de variables précédentes (à ne faire que si vous ne tenez pas à ce qui est en mémoire)

```
rm(list=ls())
```

- (ii) On importe fichier de données `beignets.txt`

```
donnees <- read.table("beignets.txt",header=TRUE)
```

- (iii) Il comporte 25 lignes, incluant la ligne donnant le nom des variables. Voici le contenu des 6 premières lignes du fichier :

```
head(donnees)
```

- (iv) On affecte les variables

```
X=donnees[, "Gras"]  
Groupe=factor(donnees[, "Gr"])
```

- (v) Bien que codée de 1 à 4, la variable **Groupe** n'est pas numérique, c'est un facteur. C'est pour cela que nous l'avons spécifié dans la dernière ligne de code.

Le nombre de groupes correspond au nombre de modalités de la variable **Groupe**. `(levels(Groupe))` donne les modalités de la variable qualitative. Le nombre de groupes correspond au nombre de modalités de la variable **Groupe**.

11.0.2 Normalité

Testons la normalité de la variable **X** sur chaque niveau du facteur

```
tapply(X,Groupe,shapiro.test)
```

On ne rejette la normalité sur aucun groupe. On peut utiliser l'ANOVA.

11.0.3 Tableau d'ANOVA

Afficher et commenter le tableau d'Anova, et conclure au rejet de l'égalité des moyennes et ainsi conclure qu'il y a un effet significatif du type de graisse sur l'absorption.

11.0.4 Contrastes

On se propose de tester un contraste du type

$$\sum_i \lambda_i \mu_i = 0.$$

On nommera `lambda.i` le vecteur de coefficients λ de la combinaison linéaire.

Dans notre contexte, les deux premières matières grasses sont d'origine animale ; les deux dernières sont d'origine végétale. Nous aimerions tester l'hypothèse que les deux types de matière grasse sont absorbées en moyenne de la même façon.

Le contraste s'écrit de la manière suivante :

$$\frac{\mu_1 + \mu_2}{2} = \frac{\mu_3 + \mu_4}{2} \iff \mu_1 + \mu_2 - \mu_3 - \mu_4 = 0.$$

Ainsi, $\lambda_1 = 1, \lambda_2 = 1, \lambda_3 = -1, \lambda_4 = -1$.

```
lambda.i=c(1,1,-1,-1)
```

On va utiliser la fonction `tapply`. Pour chaque sous-ensemble d'une trame de données, elle applique une fonction et combine les résultats dans une trame de données. Nous l'utilisons avec les fonctions R suivantes, `mean`, `var` et `sum`. Si vous ne connaissez pas ces fonctions, consultez l'aide de R. On commence par les moyennes.

```
xbar.i=tapply(X,Groupe,mean)
```

En ce qui concerne le nombre d'observations par groupe, il y a une astuce. On applique la fonction `sum` à un vecteur de "1", à chacun des groupes.

```
n=length(X)
n.i=tapply(rep(1,n),Groupe,sum)
```

Cela nous donne évidemment la taille des groupes et on calcule maintenant le nombre de groupes

```
a=length(levels(Groupe))
```

On peut maintenant faire les calculs de variations dans chaque groupe pour obtenir la somme des carrés moyens des erreurs.

```
Q.i=tapply(X,Groupe,var)*(n.i-1)
SCE=sum(Q.i)
dl=n-a
CME=SCE/dl
```

Calculons le contraste `phi`, son écart-type et effectuons le test de Student associé. On soignera l’affichage.

```
phi=sum(xbar.i*lambda.i)
s.phi=sqrt(CME*sum(lambda.i^2/n.i))
tvalue=phi/s.phi
pvaleur=pt(tvalue,dl)
pvaleur=2*min(pvaleur,1-pvaleur)
list(c(phi.hat=phi,s.phi=s.phi),c(t=tvalue,p.value= pvaleur),dl=dl)
```

On en déduit que la nature de la matière grasse a une influence significative.

Si on le souhaite, on peut reprendre le code sous forme d’une fonction

```
contrast.test=function(X,Groupe,lambda.i,phi0=0){
  xbar.i=tapply(X,Groupe,mean)
  n=length(X)
  a=length(levels(Groupe))
  n.i=tapply(rep(1,n),Groupe,sum)
  Q.i=tapply(X,Groupe,var)*(n.i-1)
  SCE=sum(Q.i)
  dl=n-a
  CME=SCE/dl
  phi=sum(xbar.i*lambda.i)
  s.phi=sqrt(CME*sum(lambda.i^2/n.i))
  tvalue=(phi-phi0)/s.phi
  pvaleur=pt(tvalue,dl)
  pvaleur=2*min(pvaleur,1-pvaleur)
  return(list(c(phi.hat=phi,s.phi=s.phi),c(t=tvalue,p.value= pvaleur),dl=dl)) }
```

On appelle la fonction

```
contrast.test(X,Groupe,c(1,1,-1,-1),phi0=0)
```

11.1 Construction du tableau d’ANOVA

(i) On pose

```
a <- length(levels(Groupe))
n <- length(X)
```

(ii) On va utiliser la fonction `tapply`. Pour chaque sous-ensemble d’une trame de données, elle applique une fonction et combine les résultats dans une trame de données. Nous l’utilisons avec les fonctions R suivantes : `mean`, `var` et `sum`. Si vous ne connaissez pas ces fonctions, consultez l’aide de R. En ce qui concerne le nombre d’observations par groupe, il y a une astuce. On applique la fonction `sum` à un vecteur de “1”, à chacun des groupes. Cela nous donne évidemment la taille des groupes. On peut maintenant faire tous les calculs :

- Obtention du nombre d'observations dans chacun des groupes:

```
n.i <- tapply(rep(1,n),Groupe,sum)
```

- Obtention des moyennes de chacun des groupes:

```
xbar.i <- tapply(X,Groupe,mean)
```

- Obtention de la variation dans chacun des groupes:

```
Q.i <- tapply(X,Groupe,var) * (n.i - 1)
```

- On a tout pour faire les calculs

```
SCT <- (n-1)*var(X)
SCE <- sum(Q.i)
SCM <- SCT-SCE
dlE <- n-a
dlM <- a-1
CMM <- SCM/dlM
CME <- SCE/dlE
F.obs <- CMM/CME
seuil.crit <- 1-pf(F.obs,dlM,dlE)
```

- On crée la matrice par colonne

```
Anova.tableau <- matrix(
  c(SCM,SCE,SCT,dlM,dlE,NA,CMM,CME,NA,F.obs, NA,NA,seuil.crit,NA,NA),
  nrow=3,dimnames=list(c("Inter groupe","Intra groupe","Totale"),
  c("SC","dl","CM","F.obs","Pr(F)"))
) # fin de list
) # fin de matrix
```

- On affiche !

```
Anova.tableau
```

Part IV

Séance de TP 4

12 Simulations et ANOVA à 1 facteur

Le test d'ANOVA (Fisher) pour un facteur est sensé tester l'égalité entre les moyennes. La variable du test est

$$F_{obs} = \frac{CMM}{CME}.$$

On voit que c'est un rapport entre la variance due au modèle et la variance due aux erreurs dans le modèle

$$X_{ij} = \bar{X}_i + \epsilon_{ij}.$$

En fait, plus la variance de l'erreur est faible, plus on a de chances de rejeter l'égalité des moyennes. On se propose donc de jouer avec l'ANOVA en simulant des séries de valeurs dont on fera augmenter la variance du terme d'erreur jusqu'à faire virer la p-value.

- (i) On suppose que le facteur prend trois niveaux et qu'il y a 20 observations par niveau. On peut poser les moyennes 15,20,25. On donne le vecteur des 60 valeurs données par le modèle :

```
x=c(rep(15,20),rep(20,20),rep(25,20))
```

- (ii) On définit le facteur aux modalités a,b,c

```
a=c(rep("a",20),rep("b",20),rep("c",20))
```

On peut faire une ANOVA sur ce modèle sans erreur

```
anova(lm(x~a))
```

Oups ! R a vu que je me payais sa tête :

Warning message:

In anova.lm(lm(x~a)) :

les tests F d'ANOVA sur un ajustement pratiquement parfait ne sont pas fiables

- (iii) On introduit de l'erreur, on commence par un vecteur d'erreur "canonique" normales et indépendantes centrées réduites :

```
err=rnorm(60)
```

- (iv) On ajoute l'erreur multipliée par l'écart-type souhaité (on commence par 0.5) qui fera augmenter directement la quantité CME

```
xe=x+0.5*err
```

On lance l'ANOVA

```
anova(lm(xe~a))
```

- (v) On peut maintenant faire une fonction qui pour un vecteur d'observations **x**, un vecteur facteur **a** et un écart-type d'erreur **sigma** rend la p-value de l'ANOVA pour la construction précédente.

```
anovalue=function(x,a,sigma){  
  err=rnorm(length(x))  
  xe=x+sigma*err  
  return(anova(lm(xe~a))$Pr)}  
}
```

- (vi) Pour nos **x** et **a**, faites varier la valeur **sigma**. Près du passage de la p-value au dessus de 5%, relancez plusieurs fois la fonction pour ces mêmes valeurs. En effet, puisque l'erreur aléatoire est générée à chaque appel de la fonction, la p-value change à chaque fois.

Voilà ! Vous savez pondre des études bidon maintenant !

13 Anova à deux facteurs

La vitesse de pénétration de 4 marques de mèches en acier est comparée dans une expérience utilisant 5 types d'acier. Les temps sont mesurés en secondes et sont données dans le tableau suivant :

Blocs	Traitement				
	Mèche 1	Mèche 2	Mèche 3	Mèche 4	Moyenne
Dureté 1	12	20	13	11	14
Dureté 2	2	14	7	5	7
Dureté 3	8	17	13	10	12
Dureté 4	1	12	8	3	6
Dureté 5	7	17	14	6	11
Moyenne	6	16	11	7	10

Les données de ce genre constituent une classification à deux entrées, ou double. On dit aussi que l'on a des mesures répétées. Chaque bloc de métal sera perforé avec chacune des mèches. Le fichier de données comporte 20 lignes, en plus de la ligne donnant le nom des variables. Voici comment obtenir le contenu des 6 premières lignes du fichier `dureteMeche.txt` :


```
options(OutDec=",")  
durtVit <- read.table("dureteMeche.txt",header=TRUE)  
head(durtVit)
```

On voit qu'il y a trois variables : Y, D et M . La première est la réponse , c'est-à-dire la vitesse de pénétration de la mèche dans le bloc de métal. La seconde est le type de métal auquel correspond une dureté spécifique. Elle prend une valeur dans l'ensemble {1; 2; 3; 4; 5}. Il s'agit d'un facteur à cinq modalités. La troisième est le type de mèche. Elle prend valeur dans l'ensemble {1; 2; 3; 4}. Il s'agit d'un facteur à quatre modalités. Afin de lire les données et d'en faire une trame de données en R on utilise la commande `read.table`. Les variables D et M ne sont pas des variables quantitatives, bien qu'elles soient codées avec des entiers. C'est pour cette raison qu'on force les variables D et M à être qualitatives. Ce sont des variables qualitatives qui nous donnent la valeur des modalités.


```
Y=durtVit$Y
D=factor(durtVit$D)
M=factor(durtVit$M)
```

On peut s'éclairer de manière descriptive avec le graphe des interactions

```
interaction.plot(M,D,Y,main="interaction plot")
```



On peut voir que les lignes ne se croisent pas vraiment. L'interaction des deux facteurs influence peu la variable Y.

13.0.1 Table d'ANOVA sans interaction

On peut demander le modèle d'ANOVA où l'on teste l'effet de 2 facteurs sans leur interaction (on pense que l'interaction des deux n'influence pas Y).

```
summary(aov(Y~D+M))
```

On s'aperçoit alors que chaque facteur influence significativement Y.

Lorsqu'on demande l'ANOVA sur l'interaction,

```
summary(aov(Y~D*M))
```

ou plutôt

```
anova(lm(Y~D*M))
```

R renvoie ce message d'erreur,

les tests F d'ANOVA sur un ajustement pratiquement parfait ne sont pas fiables

en refusant de faire le test de Fisher. Comme dans la première partie de ce TP, R considère qu'il y a trop peu de variation de nos valeurs (sans doute trop peu nombreuses et trop peu liées à l'interaction des facteurs) pour faire un test fiable. Cela nous conforte dans l'idée que l'interaction des deux facteurs n'influence pas Y.

13.0.2 Note : Pas d'ANOVA à un facteur sur un tel jeu de données !

Il est fondamental de noter que pris seul, un facteur ne suffit pas à expliquer Y . En effet, demandons les ANOVA à un facteur :

```
summary(aov(Y~M))  
summary(aov(Y~D))
```

On voit alors que, si le facteur M semble expliquer significativement Y , ce n'est pas le cas de D et pourtant ce n'est pas ce que nous disait l'ANOVA à deux facteurs. C'est bien dans leur action jointe, que ces facteurs expliquent chacun Y significativement. Vouloir faire une ANOVA à un facteur sur ce jeu de données, c'est oublier que nous allons tester la vitesse de perçage en fonction de la dureté, mais avec différentes marques de forets. C'est bien évidemment une mauvaise démarche.

13.0.3 Anova avec interaction

On peut recommencer avec un peu plus de données et un peu plus marquées par l'interaction des facteurs. Télécharger et importer le fichier `engraisRégions.txt`. Stocker les variables (en forçant les facteurs à être considérés comme qualitatifs et non numériques sinon, R fait des ANOVA sur régression linéaire multiple)

```
engrais=read.table("engraisRegion.txt",header=TRUE)  
Y=engrais$Y  
R=factor(engrais$R)  
E=factor(engrais$E)
```

On demande l'ANOVA sur les deux facteurs ainsi que sur leur interaction.

```
anova(lm(Y~R*E))
```

On observe que seul le facteur E n'explique pas significativement Y , par contre R explique Y , ainsi que l'interaction $R:E$. On peut observer l'analogie avec

```
anova(lm(Y~R+E))
```

dans laquelle, l'interaction des facteurs n'est pas étudiée. On peut tracer le graphe d'interaction et observer graphiquement ces informations

```
interaction.plot(R,E,Y,main="interaction plot")
```

14 Tests non paramétriques

On va s'amuser des tests non paramétriques. Il en existe toujours un grand nombre pour tester une même hypothèse. Le choix d'un test ou d'un autre n'est pas toujours évident et il est des situations où leur réponse différent. Il faut alors essayer de comprendre pourquoi la statistique de tel ou tel test est aveugle face à une caractéristique de la distribution, plutôt que d'utiliser le critère, certes démocratique, de donner raison au plus grand nombre de tests ayant la même conclusion.

14.1 Test de Wilcoxon contre Test du χ^2 – round 1

14.1.1 Énoncé

- (i) On va simuler une variable uniforme de taille 100 prenant 100 valeurs

```
x=sample(1:100,100,replace=TRUE)
```

Créer une variable **X** avec les valeurs extérieures aux quartiles et **Y** avec les valeurs intérieures aux quartiles.

- (ii) **Test du χ^2 .** Faire une matrice **table**

	$\leq Q1$	$Q1 \leq \dots \leq Q3$	$\geq Q3$
X			
Y			

Faire le test du χ^2

```
chisq.test(table)
```

La p-value est proche de 0, on rejette $\mathcal{H}_0$, on rejette l'adéquation des distributions.

- (iii) **Le test de Wilcoxon.** Notre premier but est de faire une matrice contenant les valeurs de X et de Y dans l'ordre croissant, une seconde ligne indiquant si c'est une valeur de X ou de Y enfin une troisième ligne avec le rang dans le classement.

On rappelle que la statistique du test de Wilcoxon est

$$W = \sum R_i,$$

où les R_i sont les rangs des observations de X dans la matrice ci-dessus. Calculer W .

Conclusion du test. L'hypothèse H_0 d'équidistribution sera rejetée au seuil α si

$$\left| W - \frac{n_X(n+1)}{2} \right| > q_{\alpha/2} \sqrt{\frac{n_X n_Y (n+1)}{12}},$$

où $q_{\alpha/2}$ est le quantile théorique de la loi normale $\mathcal{N}(0;1)$:

$$P(\mathcal{N}(0;1) > q_{\alpha/2}) = \frac{\alpha}{2}.$$

Conclure au seuil 5% et comparer le résultat avec le calcul de la p-value.

- (iv) Bref, le test de Wilcoxon n'a pas vu l'entourloupe, 1-0 pour le test du χ^2 .

14.1.2 Corrigé

- (i) On va simuler une variable uniforme de taille 100 prenant 100 valeurs

```
x=sample(1:100,100,replace=TRUE)
```

On observe les quantiles et on stock les Q1 et Q3

```
quantile(x)
Q1=quantile(x)[2]
Q3=quantile(x)[4]
```

On va ensuite créer une variable **X** avec les valeurs extérieures aux quartiles et **Y** avec les valeurs intérieures aux quartiles.

```
X=x[x<Q1|x>Q3]
Y=x[x>Q1&x<Q3]
```

On rajoute un peu d'aléa pour le test du χ^2 (il faut des effectifs plus grands que 5, encore que le test accepte des effectifs nuls) :

```
X=c(X,sample(Q1:Q3,5))
Y=c(Y,sample(1:Q1,5),sample(Q3:100,5))
```

On ordonne X et Y.

```
X=sort(X)
Y=sort(Y)
```

(ii) **Test du χ^2 .** On fait une matrice

	$\leq Q1$	$Q1 \leq \dots \leq Q3$	$\geq Q3$
X			
Y			

Pour être pédagogue, on va affecter la matrice valeur par valeur

```
table=rbind(c(1,1,1),c(1,1,1))
table[1,1]=length(X[X<Q1])
table[1,2]=length(X[X>Q1&X<Q3])
table[1,3]=length(X[X>Q3])
table[2,1]=length(Y[Y<Q1])
table[2,2]=length(Y[Y>Q1&Y<Q3])
table[2,3]=length(Y[Y>Q3])
```

Si vous voyez plus rapide, n'hésitez pas ! On fait le test du χ^2

```
chisq.test(table)
```

La p-value est proche de 0, on rejette $\mathcal{H}_0$, on rejette l'adéquation des distributions.

(iii) **Le test de Wilcoxon.** Notre premier but est de faire une matrice contenant les valeurs de X et de Y dans l'ordre croissant, une seconde ligne indiquant si c'est une valeur de X ou de Y enfin une troisième ligne avec le rang dans le classement.

```
matX=rbind(X,rep(1,length(X)))
matY=rbind(Y,rep(0,length(Y)))
matXY=cbind(matX,matY)
```

On ordonne matXY par rapport aux premières valeurs

```
mat=matXY[,order(matXY[1,])]
```

On rajoute les rangs.

```
data=rbind(mat,1:length(mat[1,]))
```

On rappelle que la statistique du test de Wilcoxon est

$$W = \sum R_i,$$

où les R_i sont les rangs des observations de X dans la matrice ci-dessus.

```
rang=data[3,]
W=sum(rang[data[2,]==1])
```

Conclusion du test. L'hypothèse H_0 d'équidistribution sera rejetée au seuil α si

$$\left| W - \frac{n_X(n+1)}{2} \right| > q_{\alpha/2} \sqrt{\frac{n_X n_Y (n+1)}{12}},$$

où $q_{\alpha/2}$ est le quantile théorique de la loi normale $\mathcal{N}(0;1)$:

$$P(\mathcal{N}(0;1) > q_{\alpha/2}) = \frac{\alpha}{2}.$$

On calcule

```
U=W-length(X)*(length(X)+length(Y)+1)/2
```

et on compare à `qnorm(0.975,0,sqrt(length(X)*length(Y)*(length(X)+length(Y)+1)/12))`.
Au seuil 5%, on ne rejette pas l'adéquation.

Avec une p-value

```
1-pnorm(abs(U),0,sqrt(length(X)*length(Y)*(length(X)+length(Y)+1)/12))
```

égale à 0.2455 (selon mes simulations personnelles, donc qui peut fluctuer), on ne rejette pas non plus significativement. (si U est négatif, il ne faut pas oublier de prendre la valeur absolue pour pouvoir comparer au quantile positif)

(iv) Bref, le test de Wilcoxon n'a pas vu l'entourloupe, 1-0 pour le test du χ^2 .

14.2 Test de Wilcoxon contre Test du χ^2 – round 2

On recommence les mêmes tests avec la même variable x découpée comme suit

```
X=x[c(1:12,25:36,49:60,73:84)]
Y=x[c(13:24,37:48,61:72,85:96)]
```

Recommencer le même test du χ^2 , avec les mêmes modalités, et le test de Wilcoxon en calculant la p-value

```
1-pnorm(abs(U),0,sqrt(length(X)*length(Y)*(length(X)+length(Y))/12))
```

(cette fois-ci, U est négatif, il ne faut pas oublier de prendre la valeur absolue pour pouvoir comparer au quantile positif). Il est à noter que U tombe presque pile sur le quantile $q_{0.975}$, ce qui est rare et brouille un peu la décision du test, on préfère donc la p-value.

Ici, c'est le test de Wilcoxon qui exclut l'adéquation des lois. 1 partout !

14.3 ANOVA contre tests non paramétriques

La pollution de l'air constitue actuellement une des préoccupations majeures de santé publique. De nombreuses études épidémiologiques ont permis de mettre en évidence l'influence sur la santé de certains composés chimiques comme le dioxyde de soufre (SO_2), le dioxyde d'azote (NO_2), l'ozone (O_3) ou des particules en suspension. Des associations de surveillance de la qualité de l'air (Air Breizh en Bretagne depuis 1994) existent sur tout le territoire métropolitain et mesurent la concentration des polluants. Elles enregistrent également les conditions météorologiques comme la température, la nébulosité, le vent, les chutes de pluie en relation avec les services de Météo France. L'une des missions de ces associations est de construire des modèles de prévision de la concentration en ozone du lendemain à partir des données disponibles du jour : observations et prévisions de Météo France. Plus précisément, il s'agit d'anticiper l'occurrence ou non d'un dépassement légal du pic d'ozone ($180 \mu g/m^3$) le lendemain afin d'aider les services préfectoraux à prendre les décisions nécessaires de prévention : confinement des personnes à risque, limitation du trafic routier. Plus modestement, l'objectif de cette étude est de mettre en évidence l'influence de certains paramètres sur la concentration d'ozone (en $\mu g/m^3$) et différentes variables observées ou leur prévision. Les 112 données étudiées ont été recueillies à Rennes durant l'été 2001. Les 13 variables observées sont :

- **maxO3** : maximum de concentration d'ozone observé sur la journée en $\mu g/m^3$,
- **T9**, **T12**, **T15** : température observée à 9, 12 et 15h,
- **Ne9**, **Ne12**, **Ne15** : nébulosité observée à 9, 12 et 15h,
- **Vx9**, **Vx12**, **Vx15** : composante E-O du vent à 9, 12 et 15h,
- **MaxO3v** : teneur maximum en ozone observée la veille,
- **vent** : orientation du vent à 12h,
- **pluie** : occurrence ou non de précipitations.

(i) Lecture des données.

```
ozone=read.table("ozone.txt",sep=" ",dec=".",header = T)
```

(ii) Investigons, si le vent affecte significativement la concentration en ozone "maxO3".

- Acquisition des données

```
head(ozone)
vent=ozone$vent
maxO3=ozone$maxO3
```

- Par une Anova :

```
anova(lm(maxO3~vent))
```

On aurait tendance à penser que le vent influence significativement la concentration en ozone.

- **Test de normalité.** Il est indispensable de savoir si les échantillons sont gaussiens (les erreurs aussi par conséquent) pour faire une ANOVA. On va utiliser rapidement le test de Shapiro-Wilk. On rappelle que l'hypothèse nulle est "l'échantillon suit une loi normale". Par conséquent si la p-value du test est significative, l'échantillon ne suit pas une loi normale.

```
tapply(maxO3,vent,shapiro.test)
```

On s'aperçoit que certains de ces échantillons ne sont pas gaussien. On devrait éviter de faire une ANOVA.

- **Avec un test non paramétrique de Kruskal–Wallis.** Pour faire court, le test de Kruskal–Wallis est un analogue³ à l'ANOVA, mais sans hypothèse de normalité. En ce sens, il est non paramétrique. L'hypothèse nulle est, sans surprise, “ les k échantillons sont confondus et proviennent d'un même échantillon (combiné) d'une population”.

```
kruskal.test(max03~vent)
```

On obtient la même conclusion, avec une p-value plus faible.

- (iii) Test de corrélation de rang de Spearman. On se pose la question de dire si la température et la composante E-O du vent observées à 9h sont indépendantes.

- Acquisition de la variable **Vx9** :

```
Vx9=ozone$Vx9  
T9=ozone$T9
```

Avec `head(Vx9)`, on observe que la série est quantitative.

- À la main. Les rangs de **Vx9** et **T9** sont disponibles via la fonction `rank()`. On observe que la statistique du test est le coefficient de corrélation des rangs

```
Rstar=cor(rank(Vx9),rank(T9))
```

La quantité `abs(Rstar)` est à comparer au quantile 0.975 (test bilatéral) d'une loi normale $\mathcal{N}(0, \sqrt{1/(n-1)})$:

```
qnorm(0.975,0,sqrt(1/(length(T9)-1)))
```

On rejette alors l'hypothèse nulle de nullité de la corrélation des rangs, on rejette donc l'indépendance des variables au seuil 5%.

- Avec la fonction `R`.

```
cor.test(Vx9,T9,method="spearman")
```

On retrouvera `Rstar` sous le nom de `rho` et une p-value qui confirme la réponse précédente.

³La statistique du test est la même que pour l'ANOVA, mais en utilisant les rangs plutôt que les observations. Cette variable suit une loi du χ^2 . Il généralise le test de Wilcoxon utilisé plus haut, qui est utilisé pour comparer seulement deux groupes.