

TP2 – Régressions Linéaires

HAMLIL Mohamed

2025-01-15

Table des matières

Introduction	1
1. Régression Linéaire Simple	2
1.1 Statistiques descriptives	2
1.2 Résidus	5
1.3 Somme des carrés	8
1.4 Distribution de $\hat{\beta}_1$	10
1.5 Intervalle de confiance de β_1	11
2. Tests de la Régression Linéaire	12
2.1 Test de Fisher et ANOVA	12
3. Préviation	14
Visualisation avec intervalle de confiance	15
Bande de confiance complète	16
4. Régression Linéaire Multiple	17
4.1 Contexte	17
4.2 Import des données	17
4.3 Coefficients de la régression	17
4.4 Tests statistiques	18
Résumé	19

Introduction

Dans ce TP, on étudie la relation entre la **tension artérielle** et l'**âge** des individus. Les données ont été simulées à partir de *BOUYER et al. (1995) Épidémiologie. Principes et méthodes*

quantitatives, Les éditions INSERM.

Objectif : Déterminer si l'âge a une influence sur la tension artérielle et éventuellement **prédire** la tension en fonction de l'âge.

1. Régression Linéaire Simple

1.1 Statistiques descriptives

(i) Identification des variables :

- **Variable explicative** (indépendante) : l'âge (x)
- **Variable expliquée** (dépendante) : la tension artérielle (y)

(ii) Importation des données :

```
data = read.csv("tension.csv", header = TRUE, sep = ";", dec = ",")
head(data)
x = data$age
y = data$tension
head(x)
head(y)
```

A data.frame : 6×2


	age <int>	tension <dbl>
1	44	136.1
2	44	132.0
3	55	148.8
4	44	127.5
5	41	130.2
6	51	136.7

1. 44
2. 44
3. 55
4. 44
5. 41
6. 51

1. 136.1
2. 132
3. 148.8
4. 127.5
5. 130.2
6. 136.7

(iii) Nuage de points :

```
plot(x, y,  
     main = "Tension artérielle en fonction de l'âge",  
     xlab = "Âge (années)", ylab = "Tension (mmHg)",  
     pch = 19, col = "steelblue")
```



Commentaire : Le nuage est relativement rectiligne. La régression linéaire a du sens et donnera une tendance moyennement précise de y en fonction de x .

(iv) Coefficient de corrélation linéaire :

```
r = cor(x, y)
cat("Coefficient de corrélation r =", round(r, 4))
```

Coefficient de corrélation r = 0.8638

Sa valeur confirme la tendance linéaire observée graphiquement.

(v) Calcul des coefficients de la droite de régression :

On cherche $y = \hat{\beta}_1 x + \hat{\beta}_0$ par la méthode des **moindres carrés** :

$$\hat{\beta}_1 = \frac{\text{Cov}(x, y)}{\text{Var}(x)}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

```
beta1 = cov(x, y) / var(x)
beta0 = mean(y) - beta1 * mean(x)
cat("beta1 =", round(beta1, 4), "\nbeta0 =", round(beta0, 4))
```

```
beta1 = 1.5994
beta0 = 59.127
```

(vi) Vérification avec lm :

```
lm(y ~ x)
```

Call:


```
lm(formula = y ~ x)
```

Coefficients:

(Intercept)	x
59.127	1.599

(vii) Tracé de la droite de régression :

```
plot(x, y,
     main = "Régression linéaire : Tension ~ Âge",
     xlab = "Âge", ylab = "Tension",
     pch = 19, col = "steelblue")
abline(beta0, beta1, col = "red", lwd = 2)
legend("topleft", legend = "Droite de régression", col = "red", lwd = 2)
```



1.2 Résidus

Les résidus (erreurs) mesurent l'écart entre les valeurs observées et les valeurs prédites par le modèle.

(i) Calcul à la main :

```
yajust = beta1 * x + beta0  
erreurs = y - yajust
```


(ii) Avec la fonction `lm` :

```
model = lm(y ~ x)  
beta0 = model$coefficients[1]  
beta1 = model$coefficients[2]
```

```
yajustes = model$fitted.values
erreurs = model$residuals
```

(iii) Résidus en fonction des valeurs ajustées :

```
plot(yajustes, erreurs,
     main = "Résidus vs Valeurs ajustées",
     xlab = "Valeurs ajustées", ylab = "Résidus",
     pch = 19, col = "darkgreen")
abline(h = 0, col = "red", lty = 2)
```



(iv) Structure des résidus ?

Il ne semble pas y avoir de structure particulière des erreurs. C'est ce qu'on attend : dans une régression linéaire, les erreurs doivent être distribuées selon $\mathcal{N}(0, \sigma)$ et être indépendantes de la variable explicative.


(v) Densité des résidus :

```

plot(density(erreurs),
     main = "Densité des résidus",
     col = "blue", lwd = 2)

# Comparaison avec la densité gaussienne
discr = -15:15
norm = dnorm(discr, 0, sqrt(var(erreurs)))
lines(discr, norm, col = "red", lwd = 2, lty = 2)
legend("topright", legend = c("Résidus", "Gaussienne"),
     col = c("blue", "red"), lwd = 2, lty = c(1, 2))

```




(vi) QQ-plot et test de Shapiro-Wilk :

```

qqnorm(erreurs, main = "QQ-plot des résidus")
qqline(erreurs, col = "red")

```



```
shapiro.test(erreurs)
```

Shapiro-Wilk normality test

data: erreurs

W = 0.99749, p-value = 0.9296

Conclusion : Avec une p-value supérieure à 5%, on **ne rejette pas** la normalité des résidus.

1.3 Somme des carrés

Rappel des trois sommes fondamentales :

— **SCE** (Somme des Carrés des Erreurs) : $\sum (y_i - \hat{y}_i)^2$

- **SCT** (Somme des Carrés Totale) : $\sum (y_i - \bar{y})^2$
- **SCM** (Somme des Carrés du Modèle) : $\sum (\hat{y}_i - \bar{y})^2$

(i) Calcul :

```
SCE = sum(erreurs^2)
SCT = sum((y - mean(y))^2)
SCM = sum((yajustes - mean(y))^2)
cat("SCE =", round(SCE, 2), "\nSCT =", round(SCT, 2), "\nSCM =", round(SCM, 2))
```

```
SCE = 5785.65
SCT = 22798.4
SCM = 17012.76
```

(ii) Vérification de la décomposition :

$$SCT = SCM + SCE$$

```
cat("SCM + SCE =", round(SCM + SCE, 2), "\nSCT =", round(SCT, 2))
```

```
SCM + SCE = 22798.4
SCT = 22798.4
```

(iii) Coefficient de détermination R^2 :

```
R2 = SCM / SCT
cat("R² =", round(R2, 4))
cat("\ncor(x,y)² =", round(cor(x, y)^2, 4))
```

```
R² = 0.7462
cor(x,y)² = 0.7462
```

On vérifie que $R^2 = r^2$ (carré du coefficient de corrélation).

1.4 Distribution de $\hat{\beta}_1$

Pour comprendre la variabilité de l'estimateur $\hat{\beta}_1$, on simule 100 échantillons du même modèle.

(i) Simulation de 100 échantillons :

```
set.seed(42)
age_sim = sample(40:56, replace = TRUE, 30000)
simx = matrix(age_sim, nrow = 100)

err_sim = rnorm(30000, 0, sqrt(SCE / (length(x) - 2)))
simerr = matrix(err_sim, nrow = 100)


simy = beta1 * simx + beta0 + simerr
```

(ii) Calcul de $\hat{\beta}_1$ pour chaque échantillon :

```
simbeta = numeric(100)
for (i in 1:100) {
  simbeta[i] = cov(simx[i, ], simy[i, ]) / var(simx[i, ])
}
```

(iii) Comparaison avec la loi de Student :

```
plot(density((simbeta - mean(simbeta)) / sqrt(var(simbeta))),
     main = "Distribution de  $\hat{\beta}_1$  standardisé",
     col = "blue", lwd = 2)
discr = seq(-3, 3, 0.1)
lines(discr, dt(discr, 298), col = "red", lwd = 2, lty = 2)
legend("topright", legend = c("Simulations", "Student(298)"),
     col = c("blue", "red"), lwd = 2, lty = c(1, 2))
```



1.5 Intervalle de confiance de β_1

L'intervalle de confiance à 95% pour β_1 est :

$$\hat{\beta}_1 + t_{n-2;0.025} \cdot \hat{\sigma}_{\beta_1} \leq \beta_1 \leq \hat{\beta}_1 - t_{n-2;0.025} \cdot \hat{\sigma}_{\beta_1}$$

```
sbeta1 = sqrt(SCE / (398 * sum((x - mean(x))^2)))
binf = beta1 + qt(0.025, 298) * sbeta1
bsup = beta1 + qt(0.975, 298) * sbeta1
cat("Intervalle de confiance à 95% pour      : [", round(binf, 4), " ; ", round(bsup, 4), " ]")
```

Intervalle de confiance à 95% pour : [1.5074 ; 1.6914]

Valeurs de `simbeta` en dehors de l'intervalle :

```
hors_ic = simbeta[simbeta > bsup | simbeta < binf]
cat("Nombre de valeurs hors IC :", length(hors_ic))
cat("\nValeurs :", round(hors_ic, 4))
```

Nombre de valeurs hors IC : 7

Valeurs : 1.707 1.4998 1.7587 1.4931 1.7066 1.5028 1.5061

On s'attend à environ 5 valeurs (5% de 100). Si c'est très différent, l'aléa informatique peut en être la cause.

2. Tests de la Régression Linéaire

2.1 Test de Fisher et ANOVA

Le coefficient de détermination R^2 est inférieur à 0.8, mais cela ne signifie pas que X n'explique pas Y . On teste l'hypothèse $H_0 : \beta_1 = 0$ (le modèle n'apporte rien).

(i) **Tableau d'ANOVA :**

```
anova(lm(y ~ x))
```

A anova : 2×5

	Df <int>	Sum Sq <dbl>	Mean Sq <dbl>	F value <dbl>	Pr(>F) <dbl>
x	1	17012.758	17012.75752	876.2722	9.777196e-91
Residuals	298	5785.647	19.41492	NA	NA

Ou de manière équivalente :

```
summary(aov(y ~ x))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
x	1	17013	17013	876.3	<2e-16 ***
Residuals	298	5786	19		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Interprétation : La p-value ($\text{Pr}(>F)$) est proche de zéro $\rightarrow$ on **rejette** la nullité de β_1 . La variable X explique Y de manière **significative**.

(ii) **Retrouver SCE et SCM :** on les reconnaît dans les colonnes Sum Sq du tableau.

(iii) **Statistique de Fisher :**

$$F = \frac{SCM}{SCE/(n-2)} = \frac{298 \times SCM}{SCE}$$

```
F_stat = 298 * SCM / SCE
cat("F observé =", round(F_stat, 2))
```

F observé = 876.27

(iv) **Comparaison au seuil 5% :**

```
cat("Quantile F(0.95, 1, 298) =", round(qf(0.95, 1, 298), 4))
```

Quantile F(0.95, 1, 298) = 3.8729

(v) **p-value :**

```
cat("p-value =", 1 - pf(F_stat, 1, 298))
```

p-value = 0

(vi) **Résumé complet du modèle :**

```
summary(lm(y ~ x))
```

```

Call:
lm(formula = y ~ x)

Residuals:
    Min       1Q   Median       3Q      Max
-11.4981  -3.0256   0.0987   2.9247  13.0025

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  59.12702    2.63496   22.44  <2e-16 ***
x             1.59941    0.05403   29.60  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.406 on 298 degrees of freedom
Multiple R-squared:  0.7462,    Adjusted R-squared:  0.7454
F-statistic: 876.3 on 1 and 298 DF,  p-value: < 2.2e-16

```

On observe que la statistique du test de Student au carré est égale à la statistique de Fisher.
C'est normal : les deux tests sont équivalents ici !

3. Prév́ision

On veut prédire la tension artérielle d'un homme de **50 ans** avec un **intervalle de confiance à 95%**.

La formule de l'intervalle de prév́ision est :

$$\hat{Y}_0 \pm t_{n-2;0.025} \sqrt{s_e^2 \left(1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum (X_i - \bar{X})^2} \right)}$$

```

se2 = SCE / 298
Y0 = beta1 * 50 + beta0
cat("Prév́ision de la tension pour un homme de 50 ans : Ŷ =", round(Y0, 2), "mmHg")

```


Prév́ision de la tension pour un homme de 50 ans : $\hat{Y} = 139.1$ mmHg

```
bsup_prev = Y0 + qt(0.975, 298) * sqrt(se2 * (1 + 1/300 + (50 - mean(x))^2 / sum((x - mean(x))^2)))
binf_prev = Y0 - qt(0.975, 298) * sqrt(se2 * (1 + 1/300 + (50 - mean(x))^2 / sum((x - mean(x))^2)))
cat("Intervalle de prévision : [", round(binf_prev, 2), ";", round(bsup_prev, 2), "])")
```

Intervalle de prévision : [130.41 ; 147.78]

Visualisation avec intervalle de confiance

```
plot(x, y,
     main = "Régression avec intervalle de prévision",
     xlab = "Âge", ylab = "Tension",
     pch = 19, col = "gray70")
abline(beta0, beta1, col = "blue", lwd = 2)
lines(c(50, 50), c(binf_prev, bsup_prev), col = "red", lwd = 3)
points(50, Y0, pch = 19, col = "red", cex = 1.5)
```




Bande de confiance complète

```
plot(x, y,
     main = "Droite de régression avec bandes de prévision",
     xlab = "Âge", ylab = "Tension",
     pch = 19, col = "gray70")
abline(beta0, beta1, col = "blue", lwd = 2)

discr = 40:56
predicted = beta1 * discr + beta0
bsup_band = predicted + qt(0.975, 298) * sqrt(se2 * (1 + 1/300 + (discr - mean(x))^2 / sum((
binf_band = predicted - qt(0.975, 298) * sqrt(se2 * (1 + 1/300 + (discr - mean(x))^2 / sum((

for (i in 1:length(discr)) {
  lines(c(discr[i], discr[i]), c(binf_band[i], bsup_band[i])), lwd = 3, col = "orange")
}
```



4. Régression Linéaire Multiple

4.1 Contexte

Pour mesurer les performances auditives d'un individu, on le soumet à un signal sonore de fréquence donnée. On mesure le **seuil** (en décibel) à partir duquel le signal est perçu. Un seuil élevé indique un trouble de l'audition.

Les données contiennent les mesures pour 4 fréquences (500Hz, 1000Hz, 2000Hz, 4000Hz) et une auto-évaluation **globale** pour 1000 personnes de plus de 39 ans.

L'enjeu : Prédire **globale** par A5, A10, A20, A40.

4.2 Import des données

```
audition = read.csv2("audition2.csv")
head(audition)
A5 = audition$A5
A10 = audition$A10
A20 = audition$A20
A40 = audition$A40
globale = audition$globale
```

A data.frame : 6×5

	A5 <dbl>	A10 <dbl>	A20 <dbl>	A40 <dbl>	globale <dbl>
1	0.01285502	0.9663823	0.87514354	-0.9128070	5.142168
2	0.12055133	-0.3726908	1.11712729	1.4278677	5.615904
3	-0.11320012	0.1210239	0.03302541	0.8079420	4.522749
4	2.05565754	2.0908744	0.36550190	-1.0883933	6.654767
5	1.44488695	0.9841622	0.45854632	-0.2759891	6.623146
6	0.60567511	1.0954039	1.95068690	2.1028709	7.228318

4.3 Coefficients de la régression

```
lm(globale ~ A5 + A10 + A20 + A40)
```

```
Call:
lm(formula = globale ~ A5 + A10 + A20 + A40)
```

```
Coefficients:
(Intercept)      A5      A10      A20      A40
    4.1423    0.7082    0.8602    0.6355    0.5106
```

L'équation de la régression est :

$$\text{globale} = 4.14 + 0.71 \times A5 + 0.86 \times A10 + 0.64 \times A20 + 0.51 \times A40$$

On voit que le niveau d'audition évalué par le sujet augmente quand chaque seuil augmente, avec sensiblement la même importance.

4.4 Tests statistiques

```
summary(lm(globale ~ A5 + A10 + A20 + A40))
```

```
Call:
lm(formula = globale ~ A5 + A10 + A20 + A40)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-1.63918 -0.19985  0.04163  0.27016  0.72287
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.14226    0.01274  325.10  <2e-16 ***
A5           0.70820    0.01808   39.17  <2e-16 ***
A10          0.86024    0.01948   44.17  <2e-16 ***
A20          0.63553    0.01439   44.17  <2e-16 ***
A40          0.51059    0.01333   38.30  <2e-16 ***
---

```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.3613 on 995 degrees of freedom
Multiple R-squared:  0.9653,    Adjusted R-squared:  0.9651
F-statistic: 6911 on 4 and 995 DF,  p-value: < 2.2e-16
```

Interprétation :

- Le **test de Fisher** (dernière ligne) montre que les variables explicatives ont, dans leur globalité, un effet **significatif** sur **globale**.
 - Tous les **tests de Student** sont significatifs → chaque variable contribue significativement.
 - Le coefficient $R^2 \approx 0.97 \rightarrow 97\%$ de la variance de **globale** est expliquée par le modèle linéaire.
 - On peut penser que le patient a une évaluation **lucide** de son état d'audition.
-

Résumé

Concept	Description	Fonction R
Régression simple	$y = \beta_1 x + \beta_0$	<code>lm(y ~ x)</code>
Résidus	Écarts entre observé et prédit	<code>model\$residuals</code>
SCE, SCT, SCM	Décomposition de la variance	Calcul manuel
R^2	Part de variance expliquée	SCM/SCT ou <code>summary()</code>
Test de Fisher	$\beta_1 = 0 ?$	<code>anova(lm())</code>
Prévision	Prédiction avec IC	Formule manuelle
Régression multiple	Plusieurs variables explicatives	<code>lm(y ~ x1 + x2 + ...)</code>